

Predicción del volumen de pesca de langosta en San Quintin, Baja California

Javier Orcazas

JORCAZAS@ITAM.MX

Estudiante de Licenciatura en Ciencia de Datos

Instituto Tecnológico Autónomo de México

Ciudad de México, México

Editor: -

Abstract

Este paper explora el desarrollo de modelos de pronóstico aplicados a la pesca en comunidades de San Quintín, Baja California. El conocimiento de las condiciones oceanográficas y meteorológicas de la región ayuda a desarrollar estrategias preventivas que permitan a las comunidades pesqueras optimizar sus recursos. La ONG mexicana COBI colabora con estas comunidades y busca capitalizar los datos recopilados por sus propios sensores de monitoreo oceanográfico para predecir la pesca de las siguientes temporadas. El estado del arte en esta aplicación incluye modelos de Estadística, Aprendizaje de Máquina (Machine Learning) y Aprendizaje Profundo (Deep Learning). Este trabajo se centra en la identificación del modelo más adecuado —donde los contendientes son XGBoost, LGBM, LSTM, GRU, ARIMA, SARIMA y Prophet— para abordar esta tarea específica y su implementación operativa para generar un impacto tangible en las comunidades pesqueras.

Keywords: Pronóstico, Pesca, Langosta, Baja California, Oceanografía, Aprendizaje de Máquina, Estadística, Aprendizaje Profundo

1 Introducción

La pesca en Baja California tiene gran importancia económica y cultural. Con más de 1,500 kilómetros de litorales y una biodiversidad marina privilegiada, el estado se ubica entre los principales productores pesqueros de México tanto en volumen como en valor, y sus flotas se componen principalmente de embarcaciones menores de pesca ribereña. En 2016, Baja California registró la producción de 45 especies entre pesca y acuacultura, donde sobresalen la sardina, el atún, el erizo, la langosta, el calamar y el camarón. Esta actividad económica genera numerosos empleos en las cadenas de captura, procesamiento y distribución. No obstante, el sector enfrenta problemas por la incertidumbre en el otorgamiento de permisos, la pesca ilegal y la insuficiente infraestructura.

La Organización No Gubernamental (ONG) COBI reconoce la importancia de los datos oceanográficos como la temperatura del mar, el pH, la salinidad, el viento, la marea, entre otros, para comprender las dinámicas de las especies que se pescan. Consideran que predecir los patrones de movimiento de las especies marinas en las regiones cercanas a las zonas de pesca, basándose en estas variables, es una medida que puede beneficiar significativamente a los pescadores y promover prácticas pesqueras sostenibles, pues les permitiría optimizar sus recursos y esfuerzos, canalizándolos en regiones donde la pesca sea abundante.

Por ello, este trabajo tiene por objetivo encontrar el mejor modelo para predecir el volumen de capturas pesqueras por temporada en regiones costeras de la Costa Oeste de Baja California, utilizando datos oceanográficos (temperatura, salinidad, pH, etc.) y de arribos pesqueros (volumen total de pesca por día desde 2017 hasta 2022) proporcionados por los pescadores de la región de San Quintín en Baja California más una base de datos extraída del proyecto oceanográfico internacional GlobColour, que cuenta con datos de 15 variables también oceanográficas (agregan claridad del agua, nivel de plankton, nivel de clorofila, materia suspendida, entre otras) en las zonas de interés. La disponibilidad temporal y geográfica de los datos enfoca este esfuerzo en la región de San Quintín para la Langosta. En el futuro, con acceso a datos de otras regiones y de más especies, el esfuerzo podría replicarse.

La pregunta que guía esta investigación es: ¿Cuál es el mejor modelo para predecir el volumen de capturas pesqueras en esta región dados los datos con los que contamos? Nuestra hipótesis es que es posible desarrollar un modelo de aprendizaje de máquina o de aprendizaje profundo aplicable a diferentes especies y zonas pesqueras, que prediga del volumen de capturas para las regiones costeras de Baja California.

La metodología consistirá en probar distintos modelos de pronóstico para determinar cuál predice de manera más precisa el volumen de capturas pesqueras en Baja California, usando variables oceanográficas y ambientales como datos de entrada.

Se entrenarán y compararán los siguientes modelos:

- Modelos de aprendizaje de máquina y aprendizaje profundo: Extreme Gradient Boost (XGBoost), Light Gradient Boosting Machine (LGBM) y Redes Neuronales Recurrentes, en particular Long-Short Term Memory (LSTM).
- Modelos estadísticos autorregresivos o baseline: Modelo autorregresivo integrado de media móvil (ARIMA por sus siglas en inglés) y Prophet.

Los modelos serán evaluados con base en su capacidad predictiva mediante una muestra independiente de datos de validación que no se utilizaron para el entrenamiento. Adicionalmente, se establecerán criterios de desempeño mínimo que los modelos de aprendizaje de máquina y aprendizaje profundo deberán superar respecto a los modelos estadísticos para ser candidatos para seleccionarse como el modelo final. El modelo final seleccionado será aquel que tenga mejor capacidad predictiva de acuerdo a las métricas establecidas, siendo los modelos estadísticos establecidos como baseline aquellos que marcarán el desempeño mínimo a superar.

2 Revisión Bibliográfica

La pregunta de investigación planteada busca determinar el mejor modelo para predecir el volumen de capturas pesqueras en Baja California a partir de variables oceanográficas. Para ello, es pertinente conocer algunos estudios previos donde se hayan aplicado técnicas de modelado y pronóstico similares en contextos pesqueros. A continuación, se presentan trabajos similares que sirvieron de guía y referencia:

Yoon et al. (21) compararon modelos de máquina de vectores de soporte, bosques aleatorios y redes neuronales profundas para predecir capturas de Caballa, Anchoa y Calamar

en zonas de pesca de Corea del Sur, utilizando datos de satélite, oceánicos y climáticos integrados en una cuadrícula geográfica con tamaño unitario de 15kmx15km. Contaban con 4,000 registros de captura entre 2014 y 2016. Los mejores resultados los obtuvieron con DNN, sugiriendo su utilidad para tareas predictivas pesqueras con datos limitados.

Otros autores como Zhao et al.(22) y Adibi et al.(1) han explorado técnicas como redes neuronales convolucionales y bosques aleatorios en contextos pesqueros. El trabajo de Zhao et al. se desarrolló en el Mar de China Oriental; utilizaron datos de un Sistema de Monitoreo de Buques para estudiar su comportamiento a través de las trayectorias que siguen al pescar. Su análisis espaciotemporal de las distribuciones del esfuerzo pesquero les ayuda a hacer predicciones a corto plazo; se basan en el descubrimiento de relaciones cronológicas de pesca entre buques para predecir distribuciones, aprovechando las relaciones cronológicas entre buques —el buque que sale primero da la pauta a los buques que salen después—. Usan los comportamientos de las primeras embarcaciones del día como indicadores para las predicciones a corto plazo. A pesar de ser una idea interesante, nosotros no tenemos datos de trayectorias de las embarcaciones, pero podríamos explorar esta posibilidad en el futuro.

Por otra parte, el trabajo de Adibi et al. fue en el norte del Adriático. Se utilizó una cuadrícula con unidades de 5kmx5km y los datos de desembarque procedían de la lonja de Chioggia. Tomaron en cuenta una distribución ponderada de las capturas, ya que las zonas con más buques pesqueros durante determinados periodos tenían más probabilidades de obtener mayores índices de capturas. Para predecir las capturas por unidad de esfuerzo (CPUE), emplearon el modelo Random Forest, con una previsión ingenua de referencia a modo de comparación. Los resultados mostraron una mejora del 13% con respecto al modelo de referencia.

Existen también propuestas recientes enfocadas en optimizar arquitecturas de redes recurrentes como LSTM (5) y de redes de atención (19) para procesamiento de series de tiempo, las cuales podrían ser opciones viables dada la naturaleza secuencial de los datos pesqueros.

Finalmente, establecer modelos estadísticos autorregresivos como ARIMA y SARIMA como baseline o referencia, ha mostrado ser una estrategia útil en estudios previos como el de Makwinja et al.(13) para evaluar el valor predictivo agregado de técnicas más complejas de machine learning y deep learning. El trabajo de Makwinja et al. en el lago Malombe, en Malawi, usa solamente datos de arribos pesqueros, ya que ARIMA es un modelo autorregresivo y para su ajuste no necesita las variables oceanográficas y meteorológicas.

Un hallazgo bibliográfico posterior resultó crítico para interpretar los resultados de este trabajo. Villaseñor-Derbez, Arafteh-Dalmai y Micheli (20) documentan que las olas de calor marinas (Marine Heatwaves, MHW) redujeron las capturas de langosta, erizo y pepino de mar en la península de Baja California entre un 15% y un 58% durante las últimas dos décadas, con impactos mayores cerca de los quiebres biogeográficos como San Quintín. Este trabajo utiliza la metodología estándar de detección y categorización de MHW propuesta por Hobday et al. (7), basada en una climatología de referencia de 30 años y el percentil 90 de la temperatura superficial del mar. La existencia de este mecanismo ambiental sugiere que un índice de MHW debería incorporarse como variable explicativa para modelar la variabilidad interanual de las capturas, y ofrece una hipótesis concreta sobre la caída atípica de la temporada 2021-2022 que se discute en la sección de Resultados.

En conjunto, estos trabajos previos proveen contexto y sustento metodológico para el estudio que se propone. Se evaluarán diversas técnicas de modelado predictivo y se compararán contra métodos estadísticos simples que sirvan de baseline

3 Metodología

La metodología propuesta consiste de 5 etapas, cada una diseñada para evaluar y comparar la eficacia de diferentes modelos de pronóstico.

1. Selección de Modelos:

- Se considerarán y evaluarán modelos representativos de aprendizaje de máquina y aprendizaje profundo, específicamente XGBoost, LGBM y LSTM. Estos modelos son conocidos por su capacidad para manejar datos complejos y no lineales. Además, se aprovechará su capacidad de ajustar modelos multivariados. Se probarán las versiones univariadas (sólo tomando en cuenta la fecha) y las versiones multivariadas; se espera que las versiones multivariadas tengan un mejor desempeño puesto que eso mostraría que las variables oceanográficas son relevantes para este estudio.
- Modelos estadísticos autorregresivos, que servirán como baseline para la comparación, incluirán ARIMA y Prophet. Estos modelos establecerán el rendimiento mínimo esperado que los modelos de aprendizaje automático y profundo deben superar. Al ser autorregresivos, pueden considerarse modelos ingenuos, por lo que superar su desempeño no debería suponer un problema para los modelos informados de las variables oceanográficas, suponiendo que son significativas.

Table 1: Selección de modelos y sus características

Modelo	Descripción
Aprendizaje de Máquina y Profundo	
XGBoost	Modelo representativo de aprendizaje de máquina con capacidad para manejar datos complejos y no lineales.
LGBM	Modelo de aprendizaje de máquina optimizado para conjuntos de datos grandes y complejos.
LSTM	Red Neuronal Recurrente con celdas de memoria especializadas para captar dependencias a largo plazo en datos secuenciales.
Estadísticos Autorregresivos (Baseline)	
ARIMA	Modelo estadístico autorregresivo que puede manejar datos estacionarios con componentes autorregresivos y de media móvil.
Prophet	Modelo de previsión de series temporales desarrollado por Facebook, diseñado para manejar datos con estacionalidad y tendencias.

2. Preprocesamiento de Datos:

- A partir de este punto, se llamará a las variables oceanográficas como las variables X, y a la variable objetivo, es decir el volumen de pesca por día, se le llamará Y. Se llevará a cabo un preprocesamiento de datos para garantizar su calidad y la coherencia. Con el fin de homogeneizar las pruebas, se optó por un proceso estándar para todos los modelos, el cual incluye la normalización y la imputación de valores faltantes en las variables X. En esta etapa se decidió omitir la ingeniería de características o ‘feature engineering’, dado que es relevante entender cuáles son las variables que un modelo sin contexto considera relevantes.

3. Entrenamiento y Validación:

- Los modelos seleccionados se entrenarán utilizando un conjunto de datos que contiene X y Y para los modelos multivariados, y sólo Y con Fecha para los modelos univariados o autorregresivos.

La validación durante el entrenamiento y/o ajuste de los modelos se hará con dos conjuntos de datos, i.e. conjunto de entrenamiento y conjunto de validación o ‘train test’ y ‘validation test’, independientes del conjunto de datos que se utilizará para evaluar el resultado de los modelos, i.e. conjunto de prueba o ‘test set’. Esto garantizará una evaluación imparcial de la capacidad predictiva de

cada modelo y evitará la fuga de datos o ‘data leakage’. Dada la naturaleza temporal de los datos, la división entre los tres conjuntos de datos se hará de la siguiente manera: Para dividir el conjunto de prueba, se hará un corte temporal en la fecha 01-junio-2021, pues esto nos deja con un 80% (antes del corte) de datos para entrenar y un 20% (después del corte) para probar.

- Para dividir los conjuntos de entrenamiento y validación se usará una ventana temporal, es decir, se dividirán los datos de entrenamiento en n-divisiones o ‘splits’ diferentes, donde cada una tendrá datos para entrenar y datos para validar, separadas por un corte temporal también; los ‘splits’ están diseñados de tal manera que cada uno es un superconjunto del anterior, y la cantidad de datos a entrenar es creciente mientras que la cantidad de datos para validar es fija. En la Figura 1 se explica el procedimiento visualmente.




Figure 1: División del conjunto de entrenamiento en 5 ‘splits’ usando el método propuesto

4. Establecimiento de Criterios de Desempeño:

- Las métricas definidas para evaluar la capacidad predictiva de cada modelo son el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual en la suma del total de pesca de una temporada. Las temporadas comienzan el 15-septiembre y terminan el 15-febrero del año siguiente.

Los criterios de desempeño mínimo que los modelos de aprendizaje automático y profundo deben superar en comparación con los modelos estadísticos baseline son los resultados de estas tres métricas en los mejores estimadores para los modelos baseline.

5. Selección del Modelo Final:

- El modelo final será seleccionado basándose en su capacidad para superar los criterios de desempeño establecidos. El énfasis recaerá en la precisión y robustez de las predicciones. Los modelos estadísticos baseline servirán como referencia, y solo los modelos de aprendizaje automático y profundo que superen significativamente su desempeño serán considerados.
- Para hacer el entrenamiento o ajuste de los modelos, se usará Grid Search para encontrar los mejores parámetros de los modelos baseline; Bayesian Search para encontrar los mejores hiperparámetros de los modelos de aprendizaje de máquina y de aprendizaje profundo.

Esta metodología permitirá la evaluación de la capacidad predictiva de cada modelo, proporcionando una base sólida para la selección del modelo final que mejor se ajuste a los objetivos de la investigación.

4 Datos

La descripción completa de cada una de las variables se encuentra en el Anexo B.

1. Procesamiento

- Se crearon procesos o ‘pipelines’ automatizados de ingesta, transformación y carga (ETL en inglés) para obtener datos de GlobColour. El proceso de ingesta utiliza el protocolo FTP al conectarse a los servidores remotos con una clave privada solicitada directamente a los administradores del proyecto por correo electrónico. El acceso es público, pero debe hacerse esa solicitud justificando su uso. El proceso de transformación se encargó de convertir los archivos .nc (no legibles por humanos) en archivos .csv tabulares. Cada uno de los archivos .nc contenía información de una sola variable en una fecha en particular en varios puntos geográficos (con coordenadas). El proceso de transformación se encargó entonces de agrupar estos archivos por variable, por zona y por fecha, para que después se consolidaran en una tabla que puede exportarse como .csv.



Figure 2: ETL de datos de GlobColour y COBI

- Para homogeneizar el ajuste y entrenamiento de los modelos, se hizo un procesamiento adicional en donde se hace un desplazamiento de 3 meses de las variables X hacia adelante. Esto con el fin de utilizar las variables X de hoy para predecir 3 meses en el futuro. El desplazamiento se decidió debido a que es un periodo de tiempo acordado con COBI para que los pescadores consideren el modelo útil.
- Para obtener los datos de los sensores de COBI, quienes los recopilan cada 6 meses, se utiliza una conexión directa a OneDrive para recuperar sus datos en formato .csv.




Figure 3: Ejemplo ilustrativo del desplazamiento para una variable, en este caso el desplazamiento es hacia atrás. En azul los datos originales y en amarillo los datos desplazados

- Una vez cargados los datos se realizó una agregación espacial y temporal, agrupando por promedio todas las observaciones de la misma fecha y de las regiones cercanas a San Quintín que corresponden a la zona de pesca de la unidad económica LITORAL DE BAJA CALIFORNIA S DE PR DE RL. Esta decisión se tomó debido a la disponibilidad de datos para esta unidad económica sobre la pesca de Langosta.

Los datos finales se almacenan en una tabla donde cada observación corresponde al agregado por promedio de todas las variables explicativas para una fecha en particular en toda la zona de interés.

Para reducir el ruido inducido por los meses de veda, donde a pesar de que las condiciones del mar pueden ser normales pero no hay pesca, decidimos reducir el conjunto de entrenamiento y prueba a sólo los días de temporada de pesca de Langosta: del 15 de septiembre de cada año al 15 de febrero del año siguiente.

2. Limitaciones Hay diferentes limitaciones que debemos tomar en cuenta cuando el proyecto se extienda a otras regiones y se escale:

- A pesar de que los datos que usamos son públicos —a excepción de los de COBI, sobre los cuales tenemos derechos por convenio—, dependemos de su disponibilidad y del correcto funcionamiento de sus propios procesos de publicación.
- Además, los datos oceanográficos obtenidos de COBI están limitados en cuanto a su disponibilidad temporal y geográfica. Los sensores de COBI se recuperan cada 6 meses y su uso está limitado a zonas cercanas.
- Una limitación más es la escasez de datos sobre arrubos pesqueros (de donde obtenemos nuestra variable objetivo): A pesar de tener más de 90 mil observaciones, al agregar los datos por especie y por unidad económica (a cada unidad




Figure 4: Zona de pesca designada a la unidad económica LITORAL DE BAJA CALIFORNIA S DE PR DE RL

económica le corresponde una zona de pesca en particular), las observaciones se reducen drásticamente. El ejercicio de este proyecto se enfoca en la especie Langosta y en la unidad económica LITORAL DE BAJA CALIFORNIA S DE PR DE RL debido a que aquí es donde encontramos más de 400 observaciones útiles (el número máximo comparado con las demás especies y unidades económicas). En futuras implementaciones de este proyecto, esperamos contar con el apoyo de las unidades económicas para aumentar los datos disponibles.

- Por último, los arribos pesqueros en general son muy limitados y son información valiosa para cada comunidad. Esperamos que este trabajo sea un incentivo a seguir generando estos datos para mejorar los modelos de predicción en el futuro.

5 Resultados

Después de la optimización de hiperparámetros y parámetros de cada modelo, y de la toma de decisión de arquitectura en el caso de LSTM, se llegó a los siguientes modelos representativos:

Modelo	Arquitectura / Parámetros
LSTM	(*)
Prophet	changepoint prior scale: 0.016, seasonality prior scale: 750.108
LGBM	colsample bytree: 0.64, learning rate: 0.10, max depth: 6, n estimators: 63, num leaves: 67
XGBoost	colsample bytree: 0.37, learning rate: 0.02, max depth: 10, n estimators: 190
ARIMA	d: 0, p: 29, q: 24, trend: c

Table 2: Modelos seleccionados y su composición

(*) La arquitectura y los hiperparámetros del modelo LSTM elegido son:

5.1 Arquitectura

- Capa de entrada con dimensiones de entrada (batch size, time steps, features) igual a (None, 10, 17).
- Capa LSTM con 2700 unidades, activación 'relu', función de activación recurrente 'sigmoid', y una tasa de dropout del 30%. Esta capa regresa secuencias y no estados.
- Capa de dropout con una tasa de dropout del 30%, aplicada a la salida de la capa LSTM.
- Capa LSTM con 800 unidades, activación 'relu', función de activación recurrente 'sigmoid', y una tasa de dropout del 30%. Esta capa no retorna secuencias, solo el estado final.
- Capa de dropout con una tasa de dropout del 30%, aplicada a la salida de la segunda capa LSTM.
- Capa densa con 1 unidad y activación 'relu'.

5.2 Hiperparámetros:

- Unidades en la primera capa LSTM: 2700.
- Unidades en la segunda capa LSTM: 800.
- Tasa de dropout: 30%.
- Función de activación en las capas LSTM: 'relu'.
- Función de activación recurrente en las capas LSTM: 'sigmoid'.
- Se utiliza la inicialización de pesos GlorotUniform para las capas LSTM y Dense.
- Se utiliza la inicialización de pesos Orthogonal para los pesos recurrentes de las capas LSTM.
- Las capas LSTM no son stateful y no se desenrollan en el tiempo.
- Se utiliza la implementación 2 para las capas LSTM.

- La capa densa tiene 1 unidad de salida.

Los resultados de las métricas a evaluar de cada modelo se muestran en las Tablas 3, 4 y 5.

Modelo	Real	Predicción	Error temp. (%)	RMSE	MAE
XGBoost + LSTM	106333.0	115583.97	8.7%	623.7	407.87
XGBoost	106333.0	95654.32	12%	354.42	304.34
LGBM	106333.0	137245.0	36%	494.9	380.2
Prophet	106333.0	174790.93	164%	135.01	105.76
ARIMA	106333.0	104482.56	338%	467.52	344.13

Table 3: Comparación de RMSE, MAE y Error de pesca por temporada. Resultados para la temporada 2020-2021

Modelo	Real	Predicción	Error temp. (%)	RMSE	MAE
XGBoost + LSTM	30912.0	59351.04	92%	345.66	313.40
XGBoost	30852	50490.34	16.3%	386.42	284.26
LGBM	30912.0	145028.25	36%	494.9	380.2
Prophet	30852	536030.88	1737%	135.01	105.76
ARIMA	106133.0	90003.27	142%	467.52	344.13

Table 4: Comparación de RMSE, MAE y Error de pesca por temporada. Resultados para la temporada 2021-2022

Modelo	Real	Predicción	Error temp. (%)	RMSE	MAE
XGBoost + LSTM	137245.0	154949.60	12.9%	527.31	368.97
XGBoost	137245.0	117299.43	14.5%	450.67	312.6
LGBM	137245.0	106133.0	36.4.7%	494.9	380.2
LSTM	137245.0	11899.4	61%	183.13	104.9
Prophet	137245.0	1043231.40	761%	135.01	105.76
ARIMA	137245.0	150	142%	467.52	344.13

Table 5: Comparación de RMSE, MAE y Error de pesca por temporada. Resultados para las dos temporadas 2020-2021 y 2021-2022

Se optó por ensamblar XGBoost, el mejor modelo para predecir la tendencia, junto con LSTM: primero se hace la predicción con XGBoost y ese vector de y se introduce en LSTM como un regresor más. Los resultados del ensamble son los mejores, con un error de

captura del 8.7% para la primera temporada y un error global del 12.9%. A pesar de esto, los resultados para la segunda temporada no son nada favorables.

Además, los RMSE y MAE son elevados, lo cual implica que las predicciones diarias son poco precisas, a pesar de que la suma de toda la temporada se predice con poco error. Esto puede significar un reto para confiar en el modelo, pero es consecuencia de la falta de granularidad en los datos de entrenamiento.

En general, todos los modelos sobreestimaron la pesca de la segunda temporada debido a que podría tratarse de un caso atípico. Si comparamos esta temporada con el resto, el total de pesca es menos de la mitad. Por esta razón se decidió optar por predecir la temporada 2020-2021 también, pues es similar a las demás.

No obstante, debemos poner atención a la causa de la reducción de la pesca en la temporada 2021-2022. Inicialmente se planteó la hipótesis de un efecto económico externo (el último año de la pandemia de Covid-19); sin embargo, la extensión de este trabajo (Sección 6) atribuye la caída a un mecanismo ambiental: las olas de calor marinas que afectaron a Baja California entre 2019 y 2021 (20). Esto explica por qué los modelos que solo usan el historial de capturas —o las variables oceanográficas sin un índice de anomalía térmica de largo plazo— sobreestiman sistemáticamente esa temporada.

Los próximos pasos de este esfuerzo son conseguir datos de otras regiones y de otras especies para replicar este procedimiento y verificar si los modelos elegidos tienen resultados similares.

6 Extensión 2026: índice de olas de calor marinas y modelos multi-especie

Como continuación del trabajo anterior, se reconstruyó el flujo de datos de forma reproducible y se incorporó una variable ambiental que no se había considerado: un índice de olas de calor marinas (MHW). Esta extensión persigue dos objetivos: (i) explicar el bache de la temporada 2021-2022 que todos los modelos previos sobreestimaron, y (ii) sentar las bases metodológicas para escalar el pronóstico a más especies y unidades económicas.

6.1 Datos y ETL actualizados

Se reescribió el proceso ETL de forma modular y reproducible. Los arribos pesqueros se ingieren con granularidad de una fila por (fecha, especie, unidad económica) uniendo dos fuentes complementarias: el export histórico de COBI (2016-2021) y los avisos de cosecha (“AVISOS MAYORES/MENORES DE COSECHA”) de CONAPESCA (2022-2026). La unión se resuelve por prioridad temporal —COBI hasta el 31-diciembre-2021 y CONAPESCA a partir de 2022, cada archivo acotado a su propio año— de modo que no hay doble conteo en la costura de 2021. El lector de CSV autodetecta el encabezado (el preámbulo de los avisos varía entre 2 y 4 líneas) y la limpieza acepta rangos de fecha explícitos. El conjunto consolidado cubre así 2017-2026, casi duplicando las temporadas disponibles de langosta en San Quintín (de ~5 a ~9). Como fuente de temperatura superficial del mar (SST) se adoptó el producto reprocesado L4 de Copernicus Marine Service (OSTIA, METOFFICE-GLO-SST-L4-REP-OBS-SST), con cobertura diaria global desde 1981; se descargó la serie 1982-2025 y se promedió sobre el bounding box costero de cada unidad económica. Esta fuente reemplaza al cliente `motuclient` —descontinuado en 2024— por el

nuevo SDK `copernicusmarine`, y provee la profundidad histórica necesaria para construir una climatología de referencia de 30 años.

6.2 Índice de olas de calor marinas (MHW)

Se implementó el índice de MHW siguiendo la metodología de Hobday et al. (7): para cada día del año se calcula una climatología y su percentil 90 sobre el periodo base 1982-2011; un evento MHW es un tramo de al menos 5 días consecutivos con SST por encima de ese umbral (fusionando eventos separados por huecos de ≤ 2 días), y se clasifica en categorías I-IV según cuántos múltiplos de la diferencia (umbral – media) alcanza la anomalía. El dataset consolidado incorpora tres columnas nuevas: `sst_anomaly` (siempre), `mhw_category` (0-4) y `mhw_intensity` (definida durante eventos).

Como validación, el índice reproduce con nitidez los eventos conocidos del Pacífico nororiental: el llamado “Blob” de 2014-2016 (con 231, 293 y 102 días de MHW respectivamente en la zona de San Quintín) y el régimen cálido de 2019-2021 (Figura 5). Esta validación es relevante porque conecta directamente con el mecanismo documentado por (20).




Figure 5: Serie diaria de SST en el bbox de San Quintín (negro) contra su climatología (azul continuo) y el umbral del percentil 90 (azul discontinuo), con baseline 1982-2011 (Hobday et al. 2016). Las áreas sombreadas marcan los eventos de ola de calor marina. Destacan el “Blob” de 2014-2016 y el régimen cálido de 2019-2021 que precede al colapso de la captura de langosta de la temporada 2021-2022.

6.3 El bache de la temporada 2021-2022 se explica por olas de calor

Las sumas de captura de langosta en San Quintín, reconstruidas a partir de los arribos, muestran una caída pronunciada tras el régimen cálido 2019-2021: aproximadamente 173 t en 2019-2020, 106 t en 2020-2021 y 39.5 t en 2021-2022 (una reducción cercana al 77% respecto al máximo). Es más, la unión con CONAPESCA revela que la captura *no se recuperó* en las temporadas siguientes, sino que se estabilizó en niveles bajos: 24.4 t en 2022-2023, 18.5 t en 2023-2024 y 17.0 t en 2024-2025 (una décima parte del máximo).

Esta magnitud iguala o supera el rango de 15-58% de reducción de capturas atribuido a las MHW en Baja California (20), coherente con que los impactos son mayores cerca de quiebres biogeográficos como San Quintín; y resuelve la pregunta abierta de la sección de Resultados: la caída no obedece principalmente a un efecto económico, sino a un forzamiento ambiental que los modelos originales no podían anticipar por carecer de una variable de anomalía térmica de largo plazo.

Un detalle de la reconstrucción merece mención, porque valida la unión de fuentes: el registro de COBI termina el 31-diciembre-2021, a mitad de la temporada 2021-2022, de modo que por sí solo la truncaba (solo ~ 31 t hasta diciembre). La unión con CONAPESCA recupera el tramo enero-febrero de 2022 y completa la temporada en 39.5 t. El empalme es limpio: no hay fechas duplicadas entre fuentes, y la transición es continua —diciembre de 2021 (COBI, 6.3 t) y enero de 2022 (CONAPESCA, 6.5 t) reportan a escalas compatibles—, lo que da confianza en que comparar temporadas anteriores (COBI) con posteriores (CONAPESCA) no introduce un artefacto de fuente.

6.4 Re-entrenamiento del baseline y modelo con covariables

Sobre los datos reales reconstruidos (langosta $\times$ San Quintín, corte de prueba 01-julio-2020) se re-entrenaron los modelos baseline y un modelo con las nuevas covariables oceanográficas (SST y MHW desplazadas 90 días, respetando la convención del proyecto y evitando fuga de datos). La Tabla 6 resume el desempeño.

Modelo	MAE	RMSE	sMAPE (%)	Err. 2020-21	Err. 2021-22
ARIMA(3,0,3)	345	463	138	−26%	+291%
Prophet	372	576	129	+62%	+418%
XGBoost (SST+MHW)	327	558	126	+53%	+368%

Table 6: Baseline re-derivado sobre datos reales y modelo con covariables SST/MHW. Todos sobreestiman fuertemente la temporada del bache (2021-2022).

Los modelos autorregresivos (ARIMA, Prophet), que solo usan el historial de y , sobreestiman la temporada 2021-2022 por factores de 3 a 4, pues no “ven” la ola de calor. El modelo XGBoost con covariables sí selecciona las variables de MHW entre sus más importantes (por ejemplo, la media móvil de anomalía de SST y de categoría MHW del año previo), pero con únicamente tres temporadas de entrenamiento no logra aún corregir la sobreestimación. Esto confirma el diagnóstico del trabajo original: el cuello de botella no es la complejidad del modelo, sino la escasez de temporadas.

6.5 Color del océano y selección de variables con SHAP

Para enriquecer el conjunto de regresoras se integraron seis variables ópticas y biológicas de color del océano, re-distribuidas por Copernicus Marine a partir del acervo GlobColour: clorofila (CHL), coeficiente de atenuación difusa (KD490), materia particulada en suspensión (SPM), profundidad de disco de Secchi (ZSD), retrodispersión de partículas (BBP) y materia orgánica coloreada disuelta y detritos (CDM). Al igual que la SST se desplazan 90 días

y se agregan medias móviles, con lo que el conjunto crece a unas 35 variables. Sin embargo, añadirlas al modelo de una sola serie *empeora* el desempeño (MAE de 327 a 424; error de la temporada 2021-2022 de +368% a +399%): un caso claro de sobreajuste con 35 variables y solo tres temporadas.

Para verificar si el problema era el exceso de variables, se aplicó una selección basada en valores SHAP (12) (*TreeExplainer*): se ordenaron las variables por su importancia media absoluta $|\text{SHAP}|$ y se conservaron las que aportaban al menos el 1% del total, reduciendo de 35 a 16. El ordenamiento es coherente y físicamente interpretable —dominan el calendario (`doy_sin`, `in_season`), seguido de la retrodispersión de partículas rezagada (`bbp_roll190_lag90`), el rezago anual de y y variables de SST/color del océano—, lo que indica que las variables tienen sentido. No obstante, podar *no* corrige el sobreajuste (Tabla 7): el modelo reducido es incluso ligeramente peor.

Modelo	N. variables	MAE	RMSE	sMAPE (%)	Error temp. 2021-22
Completo	35	423.6	659.7	116.0	+398.7%
Podado (SHAP)	16	444.7	695.5	120.3	+446.6%

Table 7: Selección de variables con SHAP sobre langosta $\times$ San Quintín (corte 01-julio-2020). Podar a las 16 variables de mayor $|\text{SHAP}|$ no mejora el desempeño: el cuello de botella no es *cuáles* variables se usan, sino el volumen de datos.

La conclusión metodológica es importante: la selección de variables por sí sola no resuelve el sobreajuste, porque el factor limitante no es la dimensionalidad sino la cantidad de temporadas. Esto refuerza que la palanca real está en *sumar datos* —más unidades económicas y más temporadas—, motivando el modelo global de la siguiente sección.

6.6 Modelo global multi-especie y multi-unidad económica

Para atacar la escasez de datos por serie se entrenó un único modelo global sobre varias series (especie, unidad económica), con codificación one-hot de especie y de unidad económica y la oceanografía compartida, y se comparó contra modelos específicos entrenados por serie. Se incorporó una segunda unidad económica, Isla Cedros ($\sim 28^\circ\text{N}$), además de San Quintín ($\sim 30.5^\circ\text{N}$), lo que introduce variación a lo largo del gradiente biogeográfico. La Tabla 8 muestra la comparación por serie.

De aquí surgen dos hallazgos. Primero, hay *transferencia positiva dentro de una misma especie entre unidades económicas*: la langosta de Isla Cedros, con menos datos, mejora ligeramente al agruparse con la de San Quintín. Segundo, el agrupamiento indiscriminado de todas las especies en un solo modelo se ve *confundido por la escala*: la langosta (capturas de cientos de kilogramos) domina la función de pérdida frente al abulón (unidades de kilogramos), degradando las predicciones de este último. La conclusión metodológica es que conviene agrupar por especie entre unidades económicas —o normalizar la variable objetivo por serie— en lugar de un pooling total, es decir, avanzar hacia un modelo jerárquico o de *partial pooling*.

Serie (especie @ unidad económica)	RMSE global	RMSE específico	Gana
langosta @ Isla Cedros	893.6	898.7	global
langosta @ San Quintín	618.9	558.3	específico
abulón negro @ San Quintín	24.6	52.8	global
abulón azul @ San Quintín	24.1	6.0	específico
abulón rojo @ San Quintín	24.0	8.9	específico

Table 8: Modelo global vs. modelos específicos, por serie (RMSE diario, kg). El global gana o empata en 2 de 5 series.

6.7 Normalización de la variable objetivo por serie

La hipótesis anterior se puso a prueba directamente. Antes de agrupar, se transformó la variable objetivo de cada serie con $\log(1 + y)$ —una transformación global, invertible y sin parámetros estimados— de modo que las series de mayor volumen dejaran de dominar la función de pérdida; también se probó una estandarización (z -score) por serie con media y desviación calculadas únicamente sobre el conjunto de entrenamiento, para evitar fuga de información. La Tabla 9 compara, por serie, el modelo específico contra el pooling sobre la variable cruda y contra el pooling sobre $\log(1 + y)$; todas las predicciones se invierten a kilogramos antes de medir el RMSE.

Serie (especie @ UE)	específico	pooling crudo	pooling $\log(1+y)$
abulón negro @ San Quintín	52.0	35.4	7.0
abulón azul @ San Quintín	6.7	32.7	4.6
abulón rojo @ San Quintín	7.3	34.9	3.5
langosta @ Isla Cedros	914.1	889.0	1131.4
langosta @ San Quintín	659.7	742.2	544.4

Table 9: Pooling con la variable objetivo normalizada por serie vs. modelos específicos (RMSE diario, kg, tras invertir la transformación). El pooling sobre $\log(1 + y)$ gana o empata en 4 de 5 series; la estandarización por serie (z -score, no mostrada) resulta inferior (1 de 5). En negrita, la mejor de cada fila.

El resultado confirma la hipótesis: al normalizar el objetivo, el pooling *sí* supera a los modelos específicos, ganando o empatando en 4 de 5 series con la transformación $\log(1 + y)$, frente a solo 2 de 5 del pooling crudo. El efecto es más marcado en las series de escala pequeña —el abulón, cuyo RMSE cae de ~ 33 – 35 (pooling crudo, dominado por la langosta) a 3.5 – 7.0 kg, por debajo incluso de su modelo específico— y también mejora la serie insignia de langosta en San Quintín (544 vs. 659 kg). La única serie que empeora es la langosta de Isla Cedros, la de mayor escala, donde el logaritmo comprime en exceso. La estandarización por serie queda por detrás del logaritmo, previsiblemente porque con pocas temporadas las estadísticas de escala por serie son ruidosas. La conclusión operativa

es que el *partial pooling con la variable objetivo en escala logarítmica* es el modelo global a consolidar y el candidato natural a envolver en un esquema de predicción probabilística (regresión cuantílica conformalizada) en la siguiente fase.

6.8 Pronóstico probabilístico con regresión cuantílica conformalizada

Con tres temporadas, cualquier pronóstico puntual es ruidoso; lo honesto —y lo útil para una cooperativa que planea insumos— es entregar un *rango* calibrado en lugar de un solo número. Se envolvió el modelo global $\log(1 + y)$ en una regresión cuantílica conformalizada (CQR, 15): regresores cuantílicos de gradient boosting en escala logarítmica y una corrección conformal de conjunto de calibración, con las cotas invertidas a kilogramos. La calibración se hace *por serie* (variante de Mondrian) y *solo con días en temporada*: los días fuera de temporada, con captura nula y cuantiles base cercanos a cero, tienen residuo de conformidad nulo y, por su abundancia, anulaban la corrección; restringir la calibración a la temporada la vuelve informativa. La partición temporal es estricta (calibración anterior al corte de prueba 01-julio-2020).

La Tabla 10 muestra la cobertura empírica y el ancho de los intervalos. La cobertura marginal queda cerca del nivel nominal (86% para el intervalo nominal del 90%, 81% para el del 80%), y la variante *normalizada* (ensanchamiento proporcional a la dispersión local) es ligeramente mejor que la de corrección constante. Es notable que la cobertura se mantiene durante las olas de calor marinas (0.89 en días de MHW frente a 0.85 fuera): el intervalo sigue siendo honesto precisamente en el régimen anómalo que hacía fracasar al pronóstico puntual.

Intervalo nominal	Cobertura empírica	Cobertura en días de MHW
80%	80.8%	—
90%	85.9%	89.1% (vs. 85.4% fuera de MHW)

Table 10: Cobertura empírica de la CQR (modelo global $\log(1 + y)$, por serie, calibrada en temporada; corte 01-julio-2020). Cercana al nivel nominal y estable durante olas de calor marinas.

La cobertura marginal, sin embargo, promedia series heterogéneas: el abulón sobre-cubre (cerca del 99%) mientras que la langosta de San Quintín sub-cubre (alrededor del 53%), porque la caída post-MHW de 2021-2022 lleva las capturas por debajo de la cota inferior calibrada con años previos —un recordatorio de que, con una sola temporada de calibración, un cambio de régimen queda fuera de la distribución aprendida. La otra limitación honesta es que la cota superior de los días pico sigue siendo ancha: eso lo determina el modelo cuantílico base (el cuantil 0.95 en escala logarítmica, amplificado al exponenciar), no la envoltura conformal. Un intento de endurecer los cuantílicos base con optimización bayesiana de hiperparámetros (Optuna sobre la pérdida pinball) mejoró la validación pero empeoró notoriamente el test en las series de gran escala, al sobreajustar el periodo de validación: confirma que estrechar el intervalo requiere *más temporadas*, no más maquinaria.

Aun así, el producto —un rango calibrado de captura por especie y unidad económica— es directamente entregable a las cooperativas y constituye el resultado operativo de esta fase.

6.9 La hipótesis de datos, puesta a prueba: más unidades y más temporadas

Todos los experimentos anteriores convergen en el mismo diagnóstico —el factor limitante es el volumen de datos, no la sofisticación del modelo—, pero lo enuncian sin demostrarlo causalmente. La forma directa de ponerlo a prueba es *sumar datos* y medir si la calibración mejora. Se hizo en dos frentes.

Primero, se amplió la cobertura espacial en dos tandas. Un clúster de cinco cooperativas de El Rosario ($\sim 29.6\text{--}30.4^\circ\text{N}$) llevó la langosta de 2 a 7 series (especie, unidad económica): con el corte canónico de 01-julio-2020 el RMSE del *pooling* de langosta en San Quintín cae de 659 a 313 kg y el ancho del percentil 90 de los días pico se estrecha de $\sim 9\,776$ a $\sim 3\,812$ kg —transferencia positiva dentro de la especie. Una segunda tanda añadió tres cooperativas de la costa norte con historia completa 2017-2026 —Punta Canoas ($\sim 29.4^\circ\text{N}$), El Pabellón de San Quintín y Rocas de San Martín ($\sim 30.4\text{--}30.5^\circ\text{N}$)—, llevando la langosta a 10 series: en el corte de 2024 el CRPS marginal baja de 150 a 123 kg y el de la propia langosta de San Quintín de 124 a 95 kg. Sumar zonas vecinas y de régimen térmico parecido —la señal más clara de transferencia positiva dentro de la especie— afina el pronóstico; más adelante se verá que sumar zonas del extremo cálido del rango ya no lo hace.

Segundo, y de mayor impacto, se desbloquearon las temporadas 2022-2026 mediante la unión con los avisos de cosecha de CONAPESCA (Sección 6), lo que permite mover el corte de prueba a 01-junio-2024 y dejar el bache post-MHW y las temporadas posteriores de captura reducida *dentro* del entrenamiento y la calibración. Con ese corte la CQR queda bien calibrada y —lo crucial— de forma *estable*: la langosta de San Quintín cubre 96.2% (cobertura marginal 96.6% para el intervalo nominal del 90%), las series de langosta cubren entre 96% y 100%, y el intervalo sigue honesto durante las olas de calor (92.5% en días de MHW frente a 96.1% fuera).

Una tercera tanda puso a prueba la *robustez* del producto ante la composición del pool. Se añadieron cuatro grandes cooperativas FEDECOOP de la península de Vizcaíno (Bahía Tortugas, Punta Eugenia, Isla Natividad y Bahía Asunción, $\sim 27.1\text{--}27.9^\circ\text{N}$, unos 2° al sur de San Quintín), llevando la langosta a 14 series. Como estas solo tienen historia de CONAPESCA (2022–2026, apenas dos temporadas de entrenamiento antes del corte de 2024), lo que se mide es estabilidad: la calibración de la langosta de San Quintín quedó *intacta* (96.2% en el corte de 2024, idéntica a la del pool de 10 series). La cobertura marginal se mantuvo cerca del nominal (96.1% en 2024). Las nuevas series, de historia corta, se calibran razonablemente (91–93% en el corte de 2024) y elevan el CRPS *marginal* por su gran escala en kilogramos —son las de mayor tonelaje del pool, con Bahía Tortugas en ~ 767 t—, no por peor calidad probabilística. Es, una vez más, la firma de que la palanca es acumular temporadas, no añadir zonas de historia corta.

Una cuarta tanda extendió el pool $\sim 1^\circ$ más al sur, al clúster de Punta Abreojos–La Purísima ($\sim 26.2\text{--}27.0^\circ\text{N}$, cuatro cooperativas), lo que obligó a ampliar la descarga oceanográfica de Copernicus hacia el sur y el este. Con ello la langosta llegó a 18 series y el patrón de *estabilidad* se repitió: la calibración de la langosta de San Quintín siguió

Pool de langosta	Langosta @ SQ, cob. 90%		Marginal	CRPS
	Corte 2020 (bache fuera)	Corte 2024 (bache dentro)	2024 cob. 90%	marg. 2024
7 series (El Rosario)	40.6%	96.7%	96.1%	149.8
10 series (+costa norte)	40.6%	96.2%	96.6%	123.0
14 series (+Vizcaíno)	40.6%	96.2%	96.1%	229.6
18 series (+Abreojos– Purísima)	40.5%	96.2%	96.0%	239.4
21 series (+Bahía Magdalena)	99.9%	96.2%	95.8%	216.8

Table 11: Estabilidad de la calibración de la langosta de San Quintín frente al corte de prueba y a la composición del pool, al expandir de 7 a 21 series. Con el corte de 2024 (el bache post-ola-de-calor *dentro* del entrenamiento) la cobertura del buque insignia es *invariante* a añadir zonas: se mantiene en 96.2% a lo largo de toda la expansión, y la cobertura marginal cerca del nominal ($\sim 96\%$). Con el corte de 2020 (bache *fuera* del entrenamiento) la cobertura es en cambio *inestable* respecto a la composición del pool —se mantuvo en $\sim 41\%$ hasta 18 series y saltó a $\sim 100\%$ solo al añadir Bahía Magdalena—, lo que confirma que ese corte es poco fiable (régimen fuera de distribución) y que el corte de referencia es el de 2024. El CRPS marginal sube al añadir las cooperativas de Vizcaíno y del Pacífico BCS —las de mayor tonelaje, y el CRPS está en kg— por un efecto de *escala*, no de calidad: la cobertura por serie de las nuevas se mantiene alta (Bahía Magdalena 95–97%).

intacta (96.2% en el corte de 2024), la cobertura marginal cerca del nominal (96.0%), y las nuevas cooperativas se calibraron entre 89% y 100%.

Una quinta tanda llevó el pool al extremo sur del rango de la langosta roja: tres cooperativas de Bahía Magdalena (Puerto San Carlos, Bahía Magdalena y Puerto Chalé, ~ 24.1 – 25.0°N), en el borde biogeográfico cálido donde la SST media supera en $\sim 4^\circ\text{C}$ a la de San Quintín; incorporarlas obligó a extender de nuevo la descarga de Copernicus hacia el sur (hasta 24°N). Con ellas la langosta llegó a 21 series. De nuevo la calibración de San Quintín quedó intacta en el corte de 2024 (96.2%) y las nuevas series —pese a su historia corta— se calibraron bien (95–97%). Pero esta tanda marca también el *límite honesto* de la transferencia entre zonas: añadir el borde térmico cálido *no* afina el pronóstico de San Quintín —su CRPS incluso empeora, de 90 a 123 kg en el corte de 2024—, a diferencia de las zonas vecinas y de régimen similar de las primeras tandas. La transferencia positiva dentro de la especie opera entre regímenes parecidos, no desde el extremo cálido del rango. El hallazgo refuerza el diagnóstico central: lo que estabiliza la calibración es acumular *temporadas* (llevar el bache al entrenamiento), más que sumar *zonas* indiscriminadamente. La Figura 6 lo muestra serie por serie para las veintiuna unidades.

El contraste con el corte de 2020 es revelador, pero no como un simple “antes mal, después bien”. Cuando el bache queda *fuera* del entrenamiento, la cobertura por serie de la langosta de San Quintín es sencillamente *poco fiable*: a lo largo de la expansión se mantuvo



Figure 6: Intervalos de la CQR (bandas 80% y 90% + mediana) frente al observado (puntos) para las veintiuna series de langosta, en el corte 01-junio-2024. Con el bache post-ola-de-calor dentro del entrenamiento y la calibración, el observado cae dentro de las bandas de forma consistente (cobertura empírica anotada por panel, 88–100%; las cooperativas nuevas de Vizcaino, de solo dos temporadas de entrenamiento, en el extremo inferior), incluida la langosta de San Quintín (96.2%). El eje y de cada panel se recorta a $3 \times$ su máximo observado, pues la cota superior del 90% se dispara en los días pico al invertir la transformación logarítmica.

en $\sim 41\%$ desde 7 hasta 18 series y saltó a 99.9% solo con 21 —de la sub-cobertura severa a la sobre-cobertura severa— sin que la serie ni su conjunto de calibración cambien, solo la composición del pool que fija el ancho del cuantil base. Es la firma de un régimen fuera de distribución: el intervalo se apoya sobre el filo de la navaja respecto a las capturas del crash. Con el bache *dentro* del entrenamiento (corte 2024) la cobertura es estable (96.7% con 7 series y 96.2% con 10, 14, 18 y 21). Lo que compran las temporadas adicionales, entonces, no es solo un buen número de cobertura sino una calibración *reproducible* —invariante a cuántas zonas haya en el pool—, y ese es el argumento de fondo: ni la poda por SHAP ni la optimización bayesiana de los cuantílicos dieron una calibración fiable de la serie insignia; llevar el régimen anómalo al entrenamiento sí.

6.10 Comparativa de modelos puntuales sobre datos unidos: el efecto de las temporadas de entrenamiento

Las tablas anteriores del piso (Tablas 6 y 7) son una fotografía *previa* a la unión con CONAPESCA: se calcularon con tres temporadas de entrenamiento y solo dos de prueba (2020-2022), que era todo lo que había. Con el conjunto unido 2017-2026 podemos re-entrenar los modelos puntuales de una sola serie (langosta $\times$ San Quintín) y, sobre todo, comparar de frente los dos cortes: el canónico 01-julio-2020 (~ 3 temporadas de entrenamiento, prueba 2020-2026 abarcando el bache y las temporadas posteriores de baja captura) contra 01-junio-2024 (~ 7 temporadas, con el bache *dentro* del entrenamiento, prueba = temporadas recientes de baja captura). La diferencia entre columnas aísla el efecto de *cuántas temporadas* ve el modelo. La Tabla 12 lo resume.

Modelo	Corte 2020-07-01 (~ 3 temp.)			Corte 2024-06-01 (~ 7 temp.)		
	MAE	RMSE	sMAPE	MAE	RMSE	sMAPE
ARIMA	330.8	383.8	153.3	177.8	191.5	147.1
Prophet	454.7	685.1	158.8	190.3	332.0	64.4
LGBM	401.9	668.8	136.7	153.8	236.2	124.0
XGBoost (35 vars)	459.0	712.3	153.0	145.4	212.0	97.1
XGBoost (SHAP, ~ 16 vars)	387.5	673.0	132.1	103.5	155.6	64.1
LSTM	290.7	457.7	78.4	499.4	628.7	131.5
XGBoost+LSTM (ensamble)	236.4	408.7	59.2	561.7	746.6	115.2

Table 12: Modelos puntuales de langosta $\times$ San Quintín re-entrenados sobre el conjunto unido 2017-2026, en los dos cortes de prueba (MAE, RMSE y sMAPE diarios, kg). En negrita, el mejor modelo de cada corte. Pasar de 3 a 7 temporadas de entrenamiento reduce el error diario a aproximadamente la mitad en los modelos tabulares —y *invierte* el orden entre ellos y los recurrentes. El ensamble XGBoost+LSTM es el del borrador original (la predicción de XGBoost entra a la LSTM como regresor extra), aquí con esa columna construida fuera de muestra en el entrenamiento.




Figure 7: Langosta $\times$ San Quintín, observado (negro) vs. pronosticado por el XGBoost completo (35 vars, rojo) y el podado por SHAP (~ 16 vars, verde), en los dos cortes. Con el entrenamiento corto (arriba, hasta jun-2020) el modelo extrapola el régimen pre-bache y sobre-predice todas las temporadas post-2021; con el entrenamiento largo (abajo, hasta may-2024, con el bache incluido) sigue las temporadas recientes de captura reducida. Eje y recortado a $3\times$ el máximo observado.

Cuatro lecturas se desprenden de la comparación (visibles en la Figura 7). Primero, mover el corte de 2020 a 2024 —es decir, meter el bache post-ola-de-calor al entrenamiento— reduce el MAE diario a la mitad en todos los modelos *tabulares* (ARIMA 331 $\rightarrow$ 178, Prophet 455 $\rightarrow$ 190, XGBoost 459 $\rightarrow$ 145, LGBM 402 $\rightarrow$ 154): al dejar de extrapolar un régimen pre-bache sobre las temporadas posteriores, los pronósticos dejan de dispararse. Es el análogo puntual del salto de cobertura de la CQR.

Segundo, el orden de los modelos se invierte. Con tres temporadas, el XGBoost con covariables (459) es *peor* que ARIMA (331): 35 variables sobreajustan tan poco dato. Con siete temporadas, el mismo XGBoost (145) *supera* a ambos baselines autorregresivos: las covariables de SST/MHW por fin rinden cuando hay suficientes temporadas para aprender la relación ola-de-calor $\rightarrow$ captura.

Tercero, y de forma reveladora, la poda por SHAP cambia de signo. En la fotografía previa a la unión (Tabla 7) podar de 35 a 16 variables *empeoraba* el modelo (MAE 424 $\rightarrow$ 445); sobre los datos unidos *ayuda* en ambos cortes, y de forma marcada en el de 2024 (145

→ 104, un 29% menos de MAE). La misma regularización que era contraproducente con tres temporadas generaliza bien con siete: evidencia directa de que el sobreajuste original era un problema de *volumen de datos*, no de selección de variables. El mejor modelo puntual refrescado —XGBoost con variables seleccionadas por SHAP en el corte de 2024, MAE 103.5 y sMAPE 64.1%— es un salto cualitativo frente a los baselines ciegos al bache del trabajo original, y complementa a los intervalos calibrados de la CQR como entregable.

Cuarto, y es la lectura que más corrige al trabajo original: *el ensamble XGBoost+LSTM —el mejor modelo del borrador— no sobrevive al refresco*. Con el corte de 2020 sigue encabezando la tabla (MAE 236.4 frente a 459.0 del XGBoost), pero la Figura 8 muestra que esa ventaja no viene de acertar la forma de la serie sino de *amortiguarla*: con tres temporadas de entrenamiento todos los modelos extrapolan el régimen previo al bache y sobre-predicen las temporadas posteriores, y los recurrentes —que producen una meseta suave en vez de los picos de apertura— simplemente sobre-predicen menos. La razón entre la desviación del pronóstico y la del observado lo cuantifica: 1.58 para la LSTM y el ensamble frente a 2.37 del XGBoost, con una correlación con el observado que *no* es mejor (0.61–0.67 en los cuatro modelos). Es el mismo diagnóstico que el borrador ya había anotado cualitativamente —que el ajuste de la LSTM “no seguía la tendencia de los datos reales” pese a tener el menor error— ahora medido.

Con el bache *dentro* del entrenamiento el orden se invierte por completo: la LSTM pasa a MAE 499.4 y el ensamble a 561.7, ambos peores que el ARIMA (177.8) y casi cinco veces peores que el XGBoost podado por SHAP (103.5); y ahora sobre-reaccionan (razón de desviaciones 3.26 y 4.06). Es más, ambos predicen captura durante agosto, con la veda todavía abierta y semanas antes del arranque de la temporada: la LSTM aprende una rampa suave hacia el pico en lugar del salto del 15 de septiembre, y ni siquiera respeta la estructura de temporada que el calendario le da como covariable. El error en la suma de la temporada 2024-2025, la métrica que le importa a la cooperativa, es de +626% y +704% para los recurrentes frente a +174% del XGBoost. La conclusión del borrador —que la combinación de LSTM y XGBoost era el modelo a seguir, con un error de temporada del 12.9%— estaba condicionada a una partición con tres temporadas y dos de prueba; con siete temporadas no se sostiene. Las $\sim 10^3$ observaciones por serie siguen siendo uno o dos órdenes de magnitud menos de lo que una red recurrente necesita, y el veredicto anticipa exactamente el de la prueba de techo con el TFT de la Sección 6.11: la palanca no es la arquitectura.

6.11 Prueba de techo: un Transformer de fusión temporal (TFT)

Toda la extensión sostiene que el cuello de botella es el volumen de datos y no la sofisticación del modelo. La prueba más exigente de esa tesis es enfrentar al producto —XGBoost con envoltura conformal— contra una arquitectura de vanguardia y comprobar si la complejidad adicional *compra* algo. Se eligió el Temporal Fusion Transformer (TFT, 10), un modelo de atención multi-horizonte con *gating* de variables diseñado precisamente para series con covariables estáticas, conocidas y observadas. Se entrenó un TFT global cuantílico (`pytorch-forecasting`) sobre las 22 series especie×unidad económica, con las mismas covariables de color del océano y de olas de calor marinas y la misma rejilla de 11 cuantiles de la CQR. Para una comparación de cobertura *manzana con manzana* sus cuantiles se




Figure 8: Langosta $\times$ San Quintín en el corte 01-julio-2020: observado (negro) contra los cuatro modelos de aprendizaje del borrador. Los cuatro sobre-predicen las temporadas posteriores al bache; la LSTM y el ensamble lo hacen menos porque aplanan la serie en una meseta suave, no porque sigan mejor su forma —de ahí su menor MAE con una correlación equivalente. Eje y recortado a $3\times$ el máximo observado.

envolvieron en la *misma* corrección conformal de la Sección anterior (Mondrian por serie, calibrada en temporada, en escala logarítmica), previo reordenamiento monótono por fila para eliminar el cruce de cuantiles (3). Así lo que se mide es “TFT + conformal” frente a “XGBoost + conformal”, en los dos cortes de prueba.

El resultado es matizado y honesto (Tabla 13). *Marginalmente*, el TFT+conformal es competitivo: su CRPS global empata o supera ligeramente al del XGBoost en ambos cortes (90.6 vs. 114.8 en 2020; 117.8 vs. 130.8 en 2024), y tras el reordenamiento de cuantiles queda bien calibrado en distribución (91.2% para el intervalo nominal del 90% en el corte de 2024, frente a la sobre-cobertura conservadora del 96.7% del XGBoost). El reordenamiento importó: sin él los cuantiles del TFT se cruzaban y la cobertura resultaba no-monótona. Es decir, la *nitidez* probabilística cruda del Transformer no es peor que la del gradient boosting.

Método	Corte 2020-07-01 (bache fuera)			Corte 2024-06-01 (bache dentro)		
	Cob. 90%	Ancho (kg)	CRPS	Cob. 90%	Ancho (kg)	CRPS
TFT + conformal	82.5%	2.1	90.6	91.2%	1.5	117.8
XGBoost + CQR	97.9%	149.3	114.8	96.7%	137.8	130.8

Table 13: Prueba de techo: TFT y XGBoost, ambos con la misma envoltura conformal, en los dos cortes (intervalo nominal del 90%; cobertura empírica, ancho mediano y CRPS global). Marginalmente el TFT empata o mejora ligeramente el CRPS y, en distribución (corte 2024), queda mejor calibrado (91.2% frente a la sobre-cobertura del 96.7% del XGBoost); fuera de distribución (corte 2020) sub-cubre. El ancho mediano del TFT es minúsculo porque casi todos los días son fuera de temporada con captura nula.

Lo que descalifica al TFT como producto no es su nitidez marginal sino su *inestabilidad por serie*. La langosta de San Quintín —la serie insignia— oscila entre 40.6% (corte 2020) y 62.0% (corte 2024) de cobertura, con un CRPS que se dispara de 114 a 213, mientras que el XGBoost se mantiene estable (99.8% y 96.2%). Peor aún, en el corte de 2020 la serie de erizo de El Regasa reventó a un ancho mediano del orden de 10^8 kg por desborde numérico al invertir la transformación logarítmica sobre un cuantil base mal condicionado —un fallo que la envoltura conformal no cura porque hereda el cuantil del modelo base—. Cada corrida entrena un TFT nuevo y el ruido corrida a corrida en las series pequeñas es alto; entrenar más (8 vs. 30 épocas) no cambia el veredicto, la firma inconfundible de un problema limitado por *datos*, no por capacidad del modelo.

El veredicto de la prueba de techo confirma la tesis de fondo. Con entre ~ 200 y $\sim 1\,100$ días de captura por serie —uno a dos órdenes de magnitud por debajo del umbral (del orden de 10^4 observaciones por grupo) donde los Transformers suelen empezar a pagar— el TFT *no supera* al XGBoost+CQR: marginalmente están en paridad, pero para una cooperativa lo que importa es una calibración *estable y segura* por unidad económica, y ahí el XGBoost+CQR gana claramente por reproducibilidad y sobre-cobertura controlada. La capa conformal —no la arquitectura— es la que entrega la calibración. La palanca sigue siendo acumular temporadas y series, no añadir maquinaria. La justificación de diseño y esta hipótesis, enunciada *antes* de correr el experimento, quedan registradas en `docs/decisions/ADR-0002-tft.md`.

7 Conclusión

La evaluación de diversos modelos para predecir el volumen de capturas pesqueras en la temporada arrojó los siguientes resultados:

ARIMA, utilizado inicialmente en el contexto de todas las especies antes de ser descartado para la langosta, mostró un desempeño desfavorable. No obstante, este resultado se excluyó de la evaluación final debido a su falta de idoneidad.

Entre los modelos restantes, LSTM destacó como el más prometedor, exhibiendo el menor error absoluto medio y un error en la suma total de capturas de la temporada menor

a los demás. Sin embargo, al visualizar los valores predichos frente a los reales, se observó que el ajuste de LSTM no seguía la tendencia de los datos reales. En contraste, XGBoost y LGBM se aproximaron mejor a dicha tendencia, a pesar de tener errores más grandes. Prophet y ARIMA, con ajustes simples que no siguen la tendencia ni se acercan a los valores reales, resultaron ininterpretables.

El desempeño de los dos mejores modelos (LSTM y XGBoost) combinado superó a todos los demás, con un error porcentual en la suma total de pesca por temporada de 12.9%.

La escasez de datos de entrenamiento juega un papel importante en el mal desempeño de todos los modelos propuestos, por lo que no podemos pensar en modelos más complejos para mejorar los resultados, sino en aumentar la cantidad de datos y utilizar el mismo método para mejorar los resultados actuales.

En ese sentido, alcanzar un modelo aplicable a varias zonas de pesca y a varias especies depende de la disponibilidad de los datos para esos contextos; difícilmente los resultados de este trabajo nos acercan al resultado deseado, pero nos arrojan pistas de qué debemos hacer para alcanzarlo.

La extensión de 2026 refuerza y precisa estas conclusiones. En primer lugar, la caída atípica de la temporada 2021-2022 —que el trabajo original no lograba explicar y que sesgaba la evaluación de los modelos— se atribuye ahora a las olas de calor marinas de 2019-2021, un mecanismo ambiental documentado para Baja California (20) y reproducible con el índice de MHW que se incorporó al pipeline. De aquí se desprende una recomendación concreta: incluir siempre una variable de anomalía térmica de largo plazo (idealmente un índice de MHW) entre las covariables, pues es la señal que permite anticipar los años atípicos.

En segundo lugar, los experimentos con modelos multivariados y con un modelo global multi-especie confirman que el factor limitante sigue siendo la cantidad de temporadas y de series disponibles, no la sofisticación del modelo. La evidencia de transferencia positiva dentro de una misma especie entre unidades económicas es alentadora, y el enfoque jerárquico de *partial pooling* que señalaba el camino a seguir quedó validado: al normalizar la variable objetivo por serie con $\log(1 + y)$ —evitando que las series de mayor volumen dominen el ajuste— el modelo global pasa a ganar o empatar contra los modelos específicos en 4 de 5 series, rescatando en particular a las especies de escala pequeña. Escalar a más unidades económicas y acumular más temporadas —junto con el índice de MHW como covariable estándar y el objetivo en escala logarítmica— constituye la ruta más prometedora hacia un modelo operativo y transferible.

En tercer lugar, y como respuesta directa a esa escasez de datos, el pronóstico se reformuló en términos probabilísticos: una regresión cuantílica conformalizada sobre el modelo global entrega intervalos con cobertura cercana a la nominal y estable incluso durante las olas de calor marinas. Para una cooperativa pesquera, un rango calibrado de captura esperada es más accionable —y más honesto— que un único número puntual, y representa el producto operativo concreto de esta extensión.

Finalmente, la hipótesis que recorre todo el trabajo —que el cuello de botella es el volumen de datos y no la sofisticación del modelo— dejó de ser una conjetura y se puso a prueba. Al sumar diecinueve cooperativas de langosta (El Rosario, la costa norte, la península de Vizcaíno, el Pacífico de BCS y Bahía Magdalena, de 2 a 21 series) y desbloquear las temporadas 2022-2026 mediante la unión con los avisos de cosecha de CONAPESCA,

la langosta de San Quintín —cuya calibración ni la selección de variables por SHAP ni la optimización bayesiana de los cuantílicos habían hecho fiable— pasó a estar bien calibrada de forma *estable* (cobertura $\sim 96\%$) al llevar el bache post-ola-de-calor de 2021-2022 dentro del entrenamiento, e *invariante* a añadir zonas al pool; con el bache fuera del entrenamiento su cobertura era irreproducible, oscilando entre 40.6% y 99.9% según la composición del pool. La expansión también fijó el límite de esa transferencia: sumar zonas vecinas y de régimen térmico parecido afina el pronóstico, pero el extremo cálido del rango (Bahía Magdalena, $\sim 24^\circ\text{N}$) ya no lo hace —la palanca de fondo sigue siendo acumular temporadas, no zonas. Es la demostración más concreta de la tesis de fondo: la ruta hacia un modelo operativo y transferible pasa por acumular temporadas y unidades económicas —junto con el índice de MHW como covariable estándar y el objetivo en escala logarítmica— y no por más maquinaria estadística.

Esa hipótesis obligó también a revisar la conclusión del propio trabajo original. Al re-entrenar sobre el conjunto unido los modelos que allí ganaban —la LSTM y el ensamble XGBoost+LSTM— su ventaja se disuelve: con tres temporadas de entrenamiento encabezan la tabla, pero por amortiguar la serie (razón de desviaciones 1.58 frente a 2.37 del XGBoost, con la misma correlación), no por seguir su forma; y con siete temporadas quedan cerca de cinco veces por detrás del XGBoost podado por SHAP, con errores de suma de temporada de +626% y +704%. El error del 12.9% que el borrador reportaba para el ensamble era, entonces, un artefacto de aquella partición corta y no una propiedad del modelo.

Como prueba de techo de esa afirmación se enfrentó al producto contra un Transformer de fusión temporal (TFT) con idénticas covariables y envuelto en la misma corrección conformal. El TFT resultó marginalmente competitivo en nitidez (CRPS a la par o ligeramente a favor) pero *inestable por serie* —la langosta de San Quintín osciló entre 41% y 62% de cobertura, con desbordes numéricos ocasionales— y sin ganancia al entrenar más épocas. Que la arquitectura de vanguardia no supere al gradient boosting con estos datos, mientras que sumar temporadas sí volvió fiable la calibración, es la confirmación más nítida de que la complejidad del modelo no es el factor limitante: lo es el volumen de datos.

Apéndice A.

A continuación se muestran las gráficas de valores predichos contra los valores reales en cada uno de los modelos.




Figure 9: ARIMA: Predicción de ambas temporadas — Valores reales (azul) contra valores predichos (rojo)




Figure 10: Prophet: Predicción de ambas temporadas — Valores reales (azul) contra valores predichos (rojo)




Figure 11: XGBoost: Predicción de ambas temporadas — Valores reales (azul) contra valores predichos (naranja)




Figure 12: LGBM: Predicción de ambas temporadas — Valores reales (azul) contra valores predichos (naranja)




Figure 13: XGBoost + LSTM — Predicción temporada 2020-2021: Valores reales (azul) contra valores predichos (rojo)




Figure 14: XGBoost + LSTM — Predicción temporada 2021-2022: Valores reales (azul) contra valores predichos (rojo)




Figure 15: XGBoost + LSTM — Predicción temporadas 2020-2021 y 2021-2022: Valores reales (azul) contra valores predichos (rojo). Nota: Aquí no aparecen las fechas consideradas como veda (periodo entre temporadas)

Apéndice B.

.1 Descripción de los datos

El conjunto de datos utilizado está compuesto de fecha 'ds', variable objetivo 'y' y 16 variables regresoras 'xi', como se muestra en la tabla 4.

Table 14: Muestra de conjunto de datos

ds	y	x1	x2	x3	...	x16
15/12/17	500	0.1556	0.2067	17.6501	...	11.3717
16/12/17	598	0.2126	0.2732	12.5639	...	10.0574
17/12/17	1018	0.0677	0.1281	22.6158	...	14.8350
18/12/17	0	0.0520	0.0985	7.8426	...	12.2488
19/12/17	1568	0.0726	0.1186	9.8166	...	11.8934
19/12/17	1568	0.0726	0.1186	9.8166	...	11.8934
...	...	...	...	...	...	...
31/12/21	60	0.0648	0.1079	99.7545	...	12.0536

A continuación se describe cada una de las variables:

- **Variable ds — Fecha:** El conjunto de datos cuenta con observaciones diarias desde el 01 de enero de 2017 hasta el 31 de diciembre de 2022. La fecha tiene el formato d-m-y

- **Variable y — Volumen total de pesca:** Es la variable objetivo. Se trata del volumen total de pesca para la fecha dada; el valor es flotante y representa kilogramos.
- **Variable x1 — Aerosol Optical Thickness over Water:** Medida de la cantidad de aerosoles en la atmósfera sobre cuerpos de agua.
- **Variable x2 — Aerosol Optical Thickness over Water+Land:** Similar a la anterior, pero considera tanto agua como tierra en la medición de aerosoles atmosféricos.
- **Variable x3 — Cloud Fraction:** Fracción del cielo cubierta por nubes, expresada como un valor entre 0 y 1.
- **Variable x4 — Depth of the Bottom of the Euphotic Layer:** Profundidad a la que la luz del sol es suficiente para la fotosíntesis en el océano.
- **Variable x5 — Secchi Disk Depth:** Profundidad a la que un disco blanco (Secchi) es visible en el agua y se utiliza para medir la transparencia del agua.
- **Variable x6 — Heated Layer Depth:** Profundidad de la capa calentada en el agua, que puede afectar las propiedades térmicas.
- **Variable x7 — Particulate Backscattering Coefficient:** Medida de la cantidad de luz dispersada por partículas en el agua en dirección opuesta a la fuente de luz.
- **Variable x8 — Coloured Dissolved Detrital Organic Materials Absorption Coefficient:** Coeficiente de absorción de materiales orgánicos disueltos y detritales que dan color al agua.
- **Variable x9 — Diffuse Attenuation Coefficient:** Tasa de disminución de la luz a medida que se propaga a través del agua debido a la dispersión y absorción.
- **Variable x10 — Relative Excess of Radiance:** Diferencia entre la radiación observada y la radiación esperada en un entorno dado.
- **Variable x11 — Normalised Remote Sensing Reflectance:** Reflectancia normalizada utilizada en teledetección para caracterizar la cantidad de luz reflejada por una superficie.
- **Variable x12 — Normalised Fluorescence Line Height:** Altura normalizada de la línea de fluorescencia, que puede indicar la actividad biológica en el agua.
- **Variable x13 — Particulate Organic Carbon:** Concentración de carbono orgánico en partículas suspendidas en el agua.
- **Variable x14 — Particulate Inorganic Carbon:** Concentración de carbono inorgánico en partículas suspendidas en el agua.
- **Variable x15 — Inorganic Suspended Particulate Matter Concentration:** Concentración de materia particulada inorgánica suspendida en el agua.

- **Variable x16 — Photosynthetically Available Radiation:** Radiación disponible para la fotosíntesis, es decir, la cantidad de luz que puede ser utilizada por los organismos fotosintéticos.

En el documento de GlobColour (4), se proporciona información detallada sobre el procesamiento de cada variable.

Referencias

- [1] Adibi, P., et al. (2020). Predicting Fishing Effort and Catch Using Semantic Trajectories and Machine Learning. In: Tserpes, K., Renso, C., Matwin, S. (eds) Multiple-Aspect Analysis of Semantic Trajectories. MASTER 2019. Lecture Notes in Computer Science, vol 11889. Springer, Cham. https://doi.org/10.1007/978-3-030-38081-6_7
- [2] Chen, T., Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. arXiv:1603.02754 [cs.LG]. <https://doi.org/10.48550/arXiv.1603.02754>
- [3] Chernozhukov, V., Fernández-Val, I., Galichon, A. (2010). Quantile and Probability Curves Without Crossing. *Econometrica*, 78(3), 1093-1125. <https://doi.org/10.3982/ECTA7880>
- [4] GlobColour. (2020). *Product User Guide* (Ref: GC-UM-ACR-PUG-01, Version 4.2.1). Retrieved from https://www.globcolour.info/CDR_Docs/GlobCOLOUR_PUG.pdf
- [5] Greff, K., et al. (2017). LSTM: A Search Space Odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, 28(10), 2222-2232. <https://doi.org/10.1109/TNNLS.2016.2582924>
- [6] Ho, S.L., Xie, M. (1999). The use of ARIMA models for reliability forecasting and analysis. The Centre for Quality, Ngee Ann Polytechnic, Singapore. Available online 28 June 1999. [https://doi.org/10.1016/S0360-8352\(98\)00066-7](https://doi.org/10.1016/S0360-8352(98)00066-7)
- [7] Hobday, A.J., et al. (2016). A hierarchical approach to defining marine heatwaves. *Progress in Oceanography*, 141, 227-238. <https://doi.org/10.1016/j.pocean.2015.12.014>
- [8] Hyndman, R.J., Athanasopoulos, G. (2021) *Forecasting: principles and practice*, 3rd edition, OTexts: Melbourne, Australia. OTexts.com/fpp3. Accessed on November 10, 2023 <https://otexts.com/fpp3/>
- [9] Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. <https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>
- [10] Lim, B., Arık, S.Ö., Loeff, N., Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748-1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>
- [11] Lindemann, B., et al. (2021). A survey on long short-term memory networks for time series prediction. Institute of Industrial Automation and Software Engineering, University of Stuttgart. Available online 3 May 2021. <https://doi.org/10.1016/j.procir.2021.03.088>

- [12] Lundberg, S.M., Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. In Advances in Neural Information Processing Systems 30 (NIPS 2017). <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>
- [13] Makwinja, R., et al. (2021). Modeling of Lake Malombe Annual Fish Landings and Catch per Unit Effort (CPUE). *Forecasting*, 3(1), 39-55. <https://doi.org/10.3390/forecast3010004>
- [14] Petropoulos, F., et al. (2022). *Forecasting: theory and practice*. Available online 20 January 2022. <https://doi.org/10.1016/j.ijforecast.2021.11.001>
- [15] Romano, Y., Patterson, E., Candès, E.J. (2019). Conformalized Quantile Regression. In Advances in Neural Information Processing Systems 32 (NeurIPS 2019). <https://doi.org/10.48550/arXiv.1905.03222>
- [16] Shi, Z., et al. (2022). Attention-based CNN-LSTM and XGBoost hybrid model for stock prediction. *arXiv:2204.02623 [q-fin.ST]*. <https://doi.org/10.48550/arXiv.2204.02623>
- [17] Staudemeyer, R.C., Morris, E.R. (2019). Understanding LSTM – a tutorial into Long Short-Term Memory Recurrent Neural Networks. *arXiv:1909.09586 [cs.NE]*. <https://doi.org/10.48550/arXiv.1909.09586>
- [18] Taylor, S.J., Letham, B. (2017). Forecasting at scale. *PeerJ Preprints* 5:e3190v2. <https://doi.org/10.7287/peerj.preprints.3190v2>
- [19] Vaswani, A., et al. (2023). Attention Is All You Need. [eprint]. *arXiv*. <https://arxiv.org/abs/1706.03762>
- [20] Villaseñor-Derbez, J.C., Arafeh-Dalmau, N., Micheli, F. (2024). Past and future impacts of marine heatwaves on small-scale fisheries in Baja California, Mexico. *Communications Earth & Environment*, 5, 623. <https://doi.org/10.1038/s43247-024-01696-x>
- [21] Yoon, Y.-J., et al. (2020). An Artificial Intelligence Method for the Prediction of Near- and Off-Shore Fish Catch Using Satellite and Numerical Model Data. *Korean Journal of Remote Sensing*, 36(1), 41–53. <https://doi.org/10.7780/KJRS.2020.36.1.4>
- [22] Zhao, Z., et al. (2021). Short-term prediction of fishing effort distributions by discovering fishing chronology among trawlers based on VMS dataset. *Expert Systems with Applications*, 184, 115512. <https://doi.org/10.1016/j.eswa.2021.115512>