

INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO

**Pronóstico calibrado del volumen de captura
de langosta roja en Baja California:
olas de calor marinas, modelos globales
multi-especie e intervalos conformalizados**

TESIS

Que para obtener el título de

LICENCIADO EN CIENCIA DE DATOS

Presenta

JAVIER ORCAZAS

Asesor: _____

pendiente: nombre y grado del asesor

“Con fundamento en los artículos 21 y 27 de la Ley Federal del Derecho de Autor y como titular de los derechos moral y patrimoniales de la obra titulada *Pronóstico calibrado del volumen de captura de langosta roja en Baja California: olas de calor marinas, modelos globales multi-especie e intervalos conformalizados*, otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la Biblioteca Raúl Baillères Jr. autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una contraprestación.”

JAVIER ORCAZAS

Fecha

Firma

Agradecimientos

A Comunidad y Biodiversidad, A.C. (COBI), por abrir los datos de arribos que hacen posible este trabajo y por el contexto pesquero que ningún conjunto de datos contiene; y a las cooperativas de San Quintín y de la costa del Pacífico de Baja California, que son quienes generan esos registros día con día.

TODO: agradecimientos personales y al asesor.

Resumen

Las cooperativas pesqueras de Baja California necesitan anticipar el volumen de captura de la siguiente temporada para dimensionar insumos, tripulación y compromisos de venta. Esta tesis construye esa herramienta para la langosta roja (*Panulirus interruptus*) y la extiende a abulón y erizo, a partir de los arribos pesqueros registrados por Comunidad y Biodiversidad, A.C. (COBI) y por CONAPESCA, y de variables oceanográficas satelitales (temperatura superficial del mar y color del océano) del servicio Copernicus Marine.

El trabajo parte de una comparación de modelos de pronóstico —ARIMA, Prophet, XGBoost, LGBM, LSTM y su ensamble— sobre una sola serie (langosta en San Quintín), y muestra que ninguno explicaba la caída atípica de la temporada 2021-2022. La tesis identifica el mecanismo faltante: las olas de calor marinas. Se implementa un índice de olas de calor según la metodología de Hobday et al. (2016), que reproduce el evento “Blob” de 2014-2016 y el régimen cálido de 2019-2021, y se incorpora como covariable.

Sobre esa base se desarrollan tres aportaciones. Primero, un **modelo global** que agrupa las series de especie por unidad económica del conjunto (de 28 a 33 con datos suficientes, según el corte), con la variable objetivo en escala logarítmica, que gana o empata contra los modelos específicos en cuatro de cinco series y rescata a las de menor escala. Segundo, un **pronóstico probabilístico** mediante regresión cuantílica conformalizada, que entrega intervalos con cobertura empírica cercana a la nominal y estable incluso durante olas de calor: para una cooperativa, un rango calibrado es más accionable y más honesto que un número puntual. Tercero, una **prueba directa de la hipótesis de fondo** —que el factor limitante es el volumen de datos y no la sofisticación del modelo—: al pasar de 2 a 21 series de langosta y desbloquear las temporadas 2022-2026, la calibración de la serie insignia se vuelve estable e invariante a la composición del pool, mientras que ni la selección de variables por SHAP, ni la optimización bayesiana, ni un Temporal Fusion Transformer lo consiguen. El resultado se materializa en una aplicación de inferencia que sirve el intervalo calibrado por especie y unidad económica.

Palabras clave: pronóstico de series de tiempo, pesquerías, langosta roja, Baja Califor-

nia, olas de calor marinas, predicción conformal, modelos globales, interpretabilidad.

Abstract

Small-scale fishing cooperatives in Baja California need to anticipate next season’s catch volume in order to plan inputs, crew and sales commitments. This thesis builds that tool for red spiny lobster (*Panulirus interruptus*), extending it to abalone and sea urchin, using landings recorded by Comunidad y Biodiversidad, A.C. (COBI) and CONAPESCA together with satellite oceanographic covariates (sea surface temperature and ocean colour) from Copernicus Marine.

Starting from a comparison of forecasting models —ARIMA, Prophet, XGBoost, LGBM, LSTM and their ensemble— on a single series, we show that none of them explained the anomalous 2021-2022 season. We identify the missing mechanism as marine heatwaves, implement the Hobday et al. (2016) index —which recovers the 2014-2016 “Blob” and the 2019-2021 warm regime— and add it as a covariate.

Three contributions follow. A **global model** pooling the dataset’s species-by-cooperative series (28–33 with enough data, depending on the cut) with a log-scaled target matches or beats series-specific models in four of five series and rescues the small-scale ones. A **probabilistic forecast** based on conformalized quantile regression yields intervals whose empirical coverage stays close to nominal even during marine heatwaves; for a cooperative, a calibrated range is more actionable —and more honest— than a point estimate. Finally, a **direct test of the underlying hypothesis** —that the binding constraint is data volume rather than model sophistication—: expanding from 2 to 21 lobster series and unlocking the 2022-2026 seasons makes the flagship series’ calibration stable and invariant to pool composition, whereas SHAP-based feature selection, Bayesian hyperparameter search and a Temporal Fusion Transformer all fail to do so. The result is delivered as an inference application serving the calibrated interval per species and cooperative.

Keywords: time series forecasting, fisheries, red spiny lobster, Baja California, marine heatwaves, conformal prediction, global models, interpretability.

Índice general

Agradecimientos	v
Resumen	vii
Abstract	ix
1 Introducción	1
1.1 Contexto	1
1.2 Planteamiento del problema	2
1.3 Pregunta de investigación e hipótesis	2
1.4 Objetivos	3
1.5 Aportaciones	3
1.6 Estructura del documento	4
2 Revisión bibliográfica	5
2.1 Pronóstico de capturas pesqueras	5
2.2 La pesquería de langosta roja en Baja California	6
2.3 Olas de calor marinas y su efecto sobre las pesquerías	7
2.4 Modelos globales y agrupamiento parcial	8
2.5 Cuantificación de incertidumbre y predicción conformal	8
2.6 Interpretabilidad	9
3 Metodología	11
3.1 Planteamiento formal	11
3.2 Partición temporal y validación	12
3.3 Métricas	13
3.4 Modelos	15
3.4.1 Modelos de referencia	15
3.4.2 Ensamblados de árboles	15

3.4.3	Modelos recurrentes	15
3.4.4	Modelo global con la variable objetivo normalizada	15
3.4.5	Transformer de fusión temporal	16
3.5	Pronóstico probabilístico: regresión cuantílica conformalizada	16
3.6	Selección de hiperparámetros	17
3.7	Reproducibilidad	17
4	Datos	19
4.1	Fuentes	19
4.2	Consolidación	20
4.3	Tratamiento de la variable objetivo faltante	21
4.4	Zona de cada unidad económica	21
4.5	Índice de olas de calor marinas	22
4.6	Construcción de variables	24
4.7	El conjunto consolidado	25
4.8	Origen de la información de las figuras heredadas	27
5	Resultados	29
5.1	Primera iteración: comparación de modelos puntuales	29
5.2	El bache de la temporada 2021-2022 se explica por olas de calor	32
5.3	Re-entrenamiento del baseline y modelo con covariables	33
5.4	Color del océano y selección de variables con SHAP	33
5.5	Modelo global multi-especie y multi-unidad económica	35
5.6	Normalización de la variable objetivo por serie	36
5.7	¿Un modelo global o veintiocho modelos disfrazados?	37
5.8	Pronóstico probabilístico con regresión cuantílica conformalizada	38
5.9	La hipótesis de datos, puesta a prueba: más unidades y más temporadas	39
5.10	Comparativa de modelos puntuales sobre datos unidos: el efecto de las temporadas de entrenamiento	43
5.11	Prueba de techo: un Transformer de fusión temporal (TFT)	46
6	El producto operativo	51
6.1	Qué entrega y por qué así	51
6.2	Arquitectura	51
6.3	Lo que ve una cooperativa	52
6.4	Advertencias que el sistema declara	53

7 Conclusiones	55
7.1 Respuesta a las preguntas de investigación	55
7.2 Limitaciones	57
7.3 Trabajo futuro	59
A Gráficas de pronóstico de la primera iteración	61
B Descripción de las variables	65
Referencias	69

Índice de figuras

3.1	Esquema de validación con ventana expansiva. Cada partición de entrenamiento (azul) es un superconjunto de la anterior y el bloque de validación (naranja) siempre está en el futuro respecto a los datos con los que se ajusta el modelo.	13
4.1	Detalle de la zona costera (<i>bounding box</i>) asignada a la unidad económica LITORAL DE BAJA CALIFORNIA S DE PR DE RL, la cooperativa de San Quintín que sirve de serie insignia, sobre la SST media. El rectángulo cubre también tierra; los píxeles sobre tierra no tienen dato de SST y no entran al promedio espacial.	22
4.2	Zonas costeras asignadas a los clústeres de unidades económicas del conjunto consolidado, sobre la SST media de 2025. La península de Baja California aparece en blanco (sin dato de SST sobre tierra) y el agua cálida al oriente es el Golfo de California. El gradiente térmico a lo largo del rango es explícito: de $\sim 17^{\circ}\text{C}$ en San Quintín ($\sim 30.4^{\circ}\text{N}$) a $\sim 22^{\circ}\text{C}$ en Bahía Magdalena ($\sim 24.5^{\circ}\text{N}$).	23
4.3	Serie diaria de SST en el bbox de San Quintín (negro) contra su climatología (azul continuo) y el umbral del percentil 90 (azul discontinuo), con periodo base 1982-2011 (Hobday et al., 2016). Las áreas sombreadas marcan los eventos de ola de calor marina. Destacan el “Blob” de 2014-2016 y el régimen cálido de 2019-2021 que precede al colapso de la captura de langosta de la temporada 2021-2022.	24
4.4	El desplazamiento temporal de 90 días con la SST real de la zona de San Quintín (2019-2020): en azul la serie original y en amarillo la desplazada. La convención del proyecto usa el estado del océano en t para predecir la captura en $t + 90$ días.	25

4.5	Proceso de datos de la primera iteración del trabajo: ingesta de GlobColour por FTP y de los archivos de COBI, transformación de .nc a tablas y consolidación. El proceso vigente, descrito en la Sección 4.2, sustituye la ingesta por FTP por el SDK de Copernicus con recorte del lado del servidor.	27
5.1	Intervalos de la CQR (bandas 80% y 90% + mediana) frente al observado (puntos) para las veintiuna series de langosta, en el corte 01-junio-2024. Con el bache post-ola-de-calor dentro del entrenamiento y la calibración, el observado cae dentro de las bandas de forma consistente (cobertura empírica anotada por panel, 88–100%; las cooperativas nuevas de Vizcaíno, de solo dos temporadas de entrenamiento, en el extremo inferior), incluida la langosta de San Quintín (96.2%). El eje y de cada panel se recorta a $3\times$ su máximo observado, pues la cota superior del 90% se dispara en los días pico al invertir la transformación logarítmica.	42
5.2	Langosta $\times$ San Quintín, observado (negro) vs. pronosticado por el XGBoost completo (35 vars, rojo) y el podado por SHAP (~ 16 vars, verde), en los dos cortes. Con el entrenamiento corto (arriba, hasta jun-2020) el modelo extrapola el régimen pre-bache y sobre-predice todas las temporadas post-2021; con el entrenamiento largo (abajo, hasta may-2024, con el bache incluido) sigue las temporadas recientes de captura reducida. Eje y recortado a $3\times$ el máximo observado.	45
5.3	Langosta $\times$ San Quintín en el corte 01-julio-2020: observado (negro) contra los cuatro modelos de aprendizaje de la primera iteración. Los cuatro sobre-predicen las temporadas posteriores al bache; la LSTM y el ensamble lo hacen menos porque aplanan la serie en una meseta suave, no porque sigan mejor su forma —de ahí su menor MAE con una correlación equivalente. Eje y recortado a $3\times$ el máximo observado.	47
6.1	Intervalos calibrados servidos por la API para tres series de langosta roja en la temporada 2024-2025: la serie insignia de San Quintín, una zona de historia larga (El Rosario) y una de historia corta, incorporada solo con los avisos de CONAPESCA (Bahía Tortugas, Vizcaíno). Los puntos son la captura observada; las bandas, los intervalos del 80 y 90%; la línea, la mediana. La cobertura empírica en temporada se anota en cada panel. El ancho de la banda superior en los días de apertura es la limitación conocida del método: el cuantil alto en escala logarítmica se amplifica al invertir la transformación.	53

A.1	ARIMA: Predicción de ambas temporadas Valores reales (azul) contra valores predichos (rojo)	61
A.2	Prophet: Predicción de ambas temporadas Valores reales (azul) contra valores predichos (rojo)	62
A.3	XGBoost: Predicción de ambas temporadas Valores reales (azul) contra valores predichos (naranja)	62
A.4	LGBM: Predicción de ambas temporadas Valores reales (azul) contra valores predichos (naranja)	63
A.5	XGBoost + LSTM Predicción temporada 2020-2021: Valores reales (azul) contra valores predichos (rojo)	63
A.6	XGBoost + LSTM Predicción temporada 2021-2022: Valores reales (azul) contra valores predichos (rojo)	64
A.7	XGBoost + LSTM Predicción temporadas 2020-2021 y 2021-2022: Valores reales (azul) contra valores predichos (rojo). Nota: Aquí no aparecen las fechas consideradas como veda (periodo entre temporadas)	64

Índice de tablas

4.1	Series (especie $\times$ unidad económica) del conjunto consolidado 2017-2026. ‘Temp.’ cuenta las temporadas con al menos un día de captura; ‘Días’ son los días con captura; ‘Ton.’ las toneladas desembarcadas del periodo; la cobertura es la fracción de días con el valor oceanográfico disponible. . . .	25
5.1	Modelos seleccionados y su composición	30
5.2	Resultados de la primera iteración (borrador de 2023) por modelo: error en la suma de temporada (2020-2021, 2021-2022 y ambas) y RMSE/MAE diarios en kg. <i>Nota:</i> las cifras se transcriben tal cual del borrador, cuyo proceso de datos dependía de fuentes hoy inaccesibles y no es reproducible; contienen inconsistencias internas menores de transcripción (algunos errores porcentuales no cuadran exactamente con las sumas que los acompañaban), por lo que deben leerse como el registro histórico del punto de partida y no como cifras verificadas. La re-corrida verificable de estos mismos modelos sobre el conjunto unido 2017-2026 está en la Tabla 5.9.	31
5.3	Baseline re-derivado sobre datos reales y modelo con covariables SST/MHW. Todos sobreestiman fuertemente la temporada del bache (2021-2022). <i>Nota:</i> estas cifras son la fotografía <i>previa</i> a la unión con los avisos de CONAPESCA —tres temporadas de entrenamiento y dos de prueba, que era todo lo disponible en ese momento—; la Tabla 5.9 las refresca sobre el conjunto unido 2017-2026.	33
5.4	Selección de variables con SHAP sobre langosta $\times$ San Quintín (corte 01-julio-2020), <i>antes</i> de la unión con CONAPESCA. Podar a las 16 variables de mayor SHAP no mejora el desempeño: con tres temporadas el cuello de botella no es <i>cuáles</i> variables se usan, sino el volumen de datos. Sobre el conjunto unido el signo se invierte y la poda sí ayuda (Tabla 5.9). . . .	34

5.5	Modelo global vs. modelos específicos, por serie (RMSE diario, kg). El global gana o empata en 2 de 5 series. <i>Nota</i> : esta tabla y la Tabla 5.6 son instantáneas de corridas sucesivas del proceso en evolución, registradas en la bitácora del repositorio; la matriz de variables cambió entre ambas corridas, por lo que las celdas que comparten difieren ligeramente. La comparación válida es <i>dentro</i> de cada tabla, con pool, variables y semilla idénticos entre columnas.	35
5.6	Pooling con la variable objetivo normalizada por serie vs. modelos específicos (RMSE diario, kg, tras invertir la transformación). El pooling sobre $\log(1 + y)$ gana o empata en 4 de 5 series; la estandarización por serie (z -score, no mostrada) queda por detrás del logaritmo en las series clave. En negrita, la mejor de cada fila. <i>Nota</i> : instantánea de una corrida posterior a la de la Tabla 5.5 (ver la nota de aquella); las columnas de esta tabla sí son directamente comparables entre sí.	36
5.7	Cobertura empírica de la CQR sobre el modelo global $\log(1 + y)$, calibrada por serie (Mondrian) y solo con días en temporada, para las 21 series de langosta más las de abulón y erizo. La cobertura queda por encima del nominal en ambos cortes —el procedimiento es conservador— y se sostiene durante las olas de calor marinas.	38
5.8	Estabilidad de la calibración de la langosta de San Quintín frente al corte de prueba y a la composición del pool, al expandir de 7 a 21 series. Con el corte de 2024 (el bache post-ola-de-calor <i>dentro</i> del entrenamiento) la cobertura del buque insignia es <i>invariante</i> a añadir zonas: se mantiene en 96.2% a lo largo de toda la expansión, y la cobertura marginal cerca del nominal ($\sim 96\%$). Con el corte de 2020 (bache <i>fuera</i> del entrenamiento) la cobertura es en cambio <i>inestable</i> respecto a la composición del pool —se mantuvo en $\sim 41\%$ hasta 18 series y saltó a $\sim 100\%$ solo al añadir Bahía Magdalena—, lo que confirma que ese corte es poco fiable (régimen fuera de distribución) y que el corte de referencia es el de 2024. El CRPS marginal sube al añadir las cooperativas de Vizcaíno y del Pacífico BCS —las de mayor tonelaje, y el CRPS está en kg— por un efecto de <i>escala</i> , no de calidad: la cobertura por serie de las nuevas se mantiene alta (Bahía Magdalena 95–97%).	40

5.9	Modelos puntuales de langosta × San Quintín re-entrenados sobre el conjunto unido 2017-2026, en los dos cortes de prueba (MAE, RMSE y sMAPE diarios, kg). En negrita, el mejor modelo de cada corte. Pasar de 3 a 7 temporadas de entrenamiento reduce el error diario a aproximadamente la mitad en los modelos tabulares —y <i>invierte</i> el orden entre ellos y los recurrentes. El ensamble XGBoost+LSTM es el de la primera iteración original (la predicción de XGBoost entra a la LSTM como regresor extra), aquí con esa columna construida fuera de muestra en el entrenamiento.	44
5.10	Prueba de techo: TFT y XGBoost, ambos con la misma envoltura conformal y sobre el <i>mismo pool final</i> (33 series en el corte de 2020, 28 en el de 2024), con intervalo nominal del 90%: cobertura empírica, ancho mediano y CRPS global. El TFT gana el CRPS por poco en ambos cortes (116.2 vs. 132.8 y 210.9 vs. 216.8) pero <i>sub-cubre</i> en los dos (70.8% y 79.1% frente al 90% nominal), mientras que la CQR sobre XGBoost sobre-cubre de forma controlada (96.7% y 95.8%). Los anchos medianos son minúsculos porque la mayoría de los días son fuera de temporada, con captura nula.	48
B.1	Muestra de conjunto de datos	65

Capítulo 1

Introducción

1.1 Contexto

La pesca en Baja California tiene gran importancia económica y cultural. Con más de 1,500 kilómetros de litorales y una biodiversidad marina privilegiada, el estado se ubica entre los principales productores pesqueros de México tanto en volumen como en valor, y sus flotas se componen principalmente de embarcaciones menores de pesca ribereña (Instituto Mexicano de Investigación en Pesca y Acuacultura Sustentables, 2025). Su producción abarca decenas de especies entre pesca y acuacultura, donde sobresalen la sardina, el atún, el erizo, la langosta, el calamar y el camarón. Esta actividad económica genera numerosos empleos en las cadenas de captura, procesamiento y distribución. No obstante, el sector enfrenta problemas por la incertidumbre en el otorgamiento de permisos, la pesca ilegal y la insuficiente infraestructura.

La organización no gubernamental COBI (Comunidad y Biodiversidad, A.C.) colabora con las cooperativas de la región y reconoce la importancia de los datos oceanográficos —temperatura del mar, pH, salinidad, viento, marea— para comprender la dinámica de las especies que se capturan. Anticipar el volumen de captura de la siguiente temporada le permite a una cooperativa dimensionar insumos, tripulación y compromisos de venta: es una decisión operativa concreta, con un horizonte natural de unos tres meses, que hoy se toma con la experiencia acumulada de los pescadores y sin ninguna herramienta cuantitativa.

Este trabajo construye esa herramienta. Se concentra en la langosta roja (*Panulirus interruptus*) porque es la especie con el registro de arribos más largo y consistente en la zona, y la extiende a abulón y erizo cuando los datos lo permiten.

1.2 Planteamiento del problema

El problema tiene tres dificultades que lo hacen algo más que un ejercicio estándar de pronóstico de series de tiempo.

1. **Escasez de datos.** La unidad de análisis útil no es “la pesca de Baja California” sino la serie *especie* $\times$ *unidad económica*: cada cooperativa tiene su propia zona de captura y su propio comportamiento. Al desagregar así, cada serie se queda con del orden de 10^2 a 10^3 observaciones útiles —unas pocas temporadas— que es uno o dos órdenes de magnitud menos de lo que los modelos modernos de pronóstico suelen requerir.
2. **Cambios de régimen ambiental.** La serie de San Quintín registra una caída abrupta a partir de la temporada 2021-2022 que ningún modelo del planteamiento inicial anticipó, y que todos sobre-predijeron. Un modelo entrenado sobre el régimen previo extrapola un nivel de captura que ya no existe.
3. **Un pronóstico puntual no es lo que la decisión necesita.** La captura se concentra en pocos días de apertura de temporada, de modo que el error diario de cualquier modelo es grande aun cuando el agregado de la temporada sea razonable. Para decidir cuántos insumos comprar, un rango con cobertura conocida es más útil —y más honesto— que un número puntual acompañado de una métrica de error promedio.

1.3 Pregunta de investigación e hipótesis

La pregunta que guía el trabajo es: **¿cómo construir un pronóstico del volumen de captura por temporada que sea útil para una cooperativa pesquera, dado el volumen de datos realmente disponible?** De ella se desprenden tres preguntas subordinadas, que ordenan el documento:

1. ¿Qué mecanismo explica los años atípicos, y puede incorporarse como variable explicativa?
2. ¿Es el factor limitante la sofisticación del modelo o el volumen de datos?
3. ¿Puede el pronóstico entregarse con una medida de incertidumbre calibrada y verificable?

La **hipótesis central** es que el factor limitante es el *volumen de datos* —el número de temporadas y de series disponibles— y no la capacidad del modelo. La hipótesis es falsable, y el trabajo la somete a prueba en ambas direcciones: aumentando los datos (de 2 a 21 series de langosta y de ~ 5 a ~ 9 temporadas) y aumentando la capacidad del modelo (hasta un Transformer de fusión temporal), para observar cuál de las dos palancas mueve el resultado.

1.4 Objetivos

Objetivo general. Construir y evaluar un sistema de pronóstico del volumen diario de captura por especie y unidad económica, con incertidumbre calibrada, reproducible y entregable a las cooperativas pesqueras de Baja California.

Objetivos específicos.

1. Reconstruir de forma reproducible y probada el proceso de datos, uniendo las fuentes de arribos disponibles (COBI y CONAPESCA) con covariables oceanográficas satelitales.
2. Implementar un índice de olas de calor marinas según Hobday et al. (2016) y evaluar si explica los años atípicos de captura.
3. Comparar modelos estadísticos, de aprendizaje de máquina y de aprendizaje profundo sobre una partición temporal estricta, con métricas explícitas.
4. Evaluar si un modelo global multi-especie y multi-unidad económica transfiere señal entre series.
5. Producir un pronóstico probabilístico con cobertura empírica verificable.
6. Contrastar la hipótesis de datos contra una arquitectura de vanguardia (TFT).
7. Entregar el resultado como un producto operativo consultable.

1.5 Aportaciones

- Un **diagnóstico causalmente informado** del año atípico: el índice de olas de calor marinas conecta la caída de 2021-2022 con el régimen cálido de 2019-2021, mecanismo documentado para Baja California por Villaseñor-Derbez et al. (2024).

- Un **modelo global** sobre las series del conjunto consolidado (de 28 a 33 con datos suficientes, según el corte) con la variable objetivo en escala logarítmica, que supera o empata a los modelos específicos en cuatro de cinco series.
- Un **pronóstico probabilístico calibrado** por regresión cuantílica conformalizada, con cobertura estable incluso durante olas de calor marinas.
- Una **prueba explícita de la hipótesis de datos**, en las dos direcciones: añadiendo series y temporadas (sí mejora, y vuelve reproducible la calibración) y añadiendo capacidad de modelo (no mejora).
- Un **producto operativo** desplegable que sirve el intervalo calibrado por especie y unidad económica, y un repositorio reproducible con pruebas automatizadas.

1.6 Estructura del documento

El Capítulo 2 revisa la literatura de pronóstico pesquero, de olas de calor marinas y de predicción conformal. El Capítulo 3 plantea formalmente el problema, la partición temporal, las métricas y los modelos, incluido el procedimiento conformal. El Capítulo 4 describe las fuentes, el proceso de datos y el conjunto consolidado. El Capítulo 5 presenta los resultados, desde la comparación inicial de modelos puntuales hasta la prueba de techo con el TFT. El Capítulo 6 describe el producto operativo. El Capítulo 7 concluye, enumera las limitaciones y propone trabajo futuro.

Capítulo 2

Revisión bibliográfica

2.1 Pronóstico de capturas pesqueras

La pregunta de investigación planteada busca determinar el mejor modelo para predecir el volumen de capturas pesqueras en Baja California a partir de variables oceanográficas. Para ello, es pertinente conocer algunos estudios previos donde se hayan aplicado técnicas de modelado y pronóstico similares en contextos pesqueros. A continuación, se presentan trabajos similares que sirvieron de guía y referencia:

Yoon et al. (2020) compararon modelos de máquina de vectores de soporte, bosques aleatorios y redes neuronales profundas para predecir capturas de Caballa, Anchoa y Calamar en zonas de pesca de Corea del Sur, utilizando datos de satélite, oceánicos y climáticos integrados en una cuadrícula geográfica con tamaño unitario de $15\text{ km} \times 15\text{ km}$. Contaban con 4,000 registros de captura entre 2014 y 2016. Los mejores resultados los obtuvieron con DNN, sugiriendo su utilidad para tareas predictivas pesqueras con datos limitados.

Otros autores como Zhao et al. (2021) y Adibi et al. (2020) han explorado técnicas como redes neuronales convolucionales y bosques aleatorios en contextos pesqueros. El trabajo de Zhao et al. se desarrolló en el Mar de China Oriental; utilizaron datos de un Sistema de Monitoreo de Buques para estudiar su comportamiento a través de las trayectorias que siguen al pescar. Su análisis espaciotemporal de las distribuciones del esfuerzo pesquero les ayuda a hacer predicciones a corto plazo; se basan en el descubrimiento de relaciones cronológicas de pesca entre buques para predecir distribuciones, aprovechando las relaciones cronológicas entre buques —el buque que sale primero da la pauta a los buques que salen después—. Usan los comportamientos de las primeras embarcaciones del día como indicadores para las predicciones a corto plazo. A pesar de ser una idea intere-

sante, nosotros no tenemos datos de trayectorias de las embarcaciones, pero podríamos explorar esta posibilidad en el futuro.

Por otra parte, el trabajo de Adibi et al. fue en el norte del Adriático. Se utilizó una cuadrícula con unidades de $5\text{ km} \times 5\text{ km}$ y los datos de desembarque procedían de la lonja de Chioggia. Tomaron en cuenta una distribución ponderada de las capturas, ya que las zonas con más buques pesqueros durante determinados periodos tenían más probabilidades de obtener mayores índices de capturas. Para predecir las capturas por unidad de esfuerzo (CPUE), emplearon el modelo Random Forest, con una previsión ingenua de referencia a modo de comparación. Los resultados mostraron una mejora del 13% con respecto al modelo de referencia.

Existen también propuestas recientes enfocadas en optimizar arquitecturas de redes recurrentes como LSTM (Greff et al., 2017; Lindemann et al., 2021), así como en adaptar las redes de atención (Vaswani et al., 2017) al procesamiento de series de tiempo, las cuales podrían ser opciones viables dada la naturaleza secuencial de los datos pesqueros; el ensamble de una red recurrente con un modelo de *gradient boosting*, como el que se evalúa en el Capítulo 5, es una combinación usada en otros dominios de series cortas y ruidosas (Shi et al., 2022).

Finalmente, establecer modelos estadísticos autorregresivos como ARIMA y SARIMA como baseline o referencia, ha mostrado ser una estrategia útil en estudios previos como el de Makwinja et al. (2021) para evaluar el valor predictivo agregado de técnicas más complejas de aprendizaje de máquina y aprendizaje profundo. El trabajo de Makwinja et al. en el lago Malombe, en Malawi, usa solamente datos de arribos pesqueros, ya que ARIMA es un modelo autorregresivo y para su ajuste no necesita las variables oceanográficas y meteorológicas.

El mecanismo ambiental que resultó decisivo para interpretar estos resultados —las olas de calor marinas— se revisa por separado en la Sección 2.3.

En conjunto, estos trabajos previos proveen contexto y sustento metodológico para el estudio que se propone. Se evaluarán diversas técnicas de modelado predictivo y se compararán contra métodos estadísticos simples que sirvan de referencia (Ho and Xie, 1999; Hyndman and Athanasopoulos, 2021).

2.2 La pesquería de langosta roja en Baja California

La langosta roja (*Panulirus interruptus*) se distribuye a lo largo de la costa del Pacífico de la península de Baja California y sostiene una de las pesquerías ribereñas de mayor valor del noroeste de México, organizada en cooperativas con zonas de captura asignadas. Su

aprovechamiento está regulado por la Norma Oficial Mexicana NOM-006-SAG/PESC-2016 (Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación, 2016), que fija tallas mínimas, artes de pesca permitidas y la temporada de captura; el diagnóstico del estado del recurso se publica en la Carta Nacional Pesquera (Instituto Mexicano de Investigación en Pesca y Acuacultura Sustentables, 2025). La ventana de 15 de septiembre a 15 de febrero que estructura todo este trabajo proviene de ese marco regulatorio, no de una decisión de modelado.

Para el pronóstico importa que la especie es sensible a la variabilidad ambiental. Vega Velázquez (2003) documenta, con una serie de once años frente a la costa central de Baja California, que las estrategias reproductivas de *P. interruptus* —medidas por la proporción de hembras con espermatóforo y de hembras ovígeras— responden a la temperatura y a la intensidad de las surgencias. Esa dependencia térmica es el mecanismo que hace plausible usar variables oceanográficas rezagadas como predictoras de la captura meses después.

En el contexto mexicano existe además un antecedente directo de pronóstico sobre esta misma pesquería: Hernández-Casas et al. (2022) comparan redes neuronales artificiales (NAR y NARX) contra un modelo ARIMAX para pronosticar el *precio* de la langosta roja mexicana. La estructura del problema es la misma que aquí —serie corta, comparación contra un referente autorregresivo— aunque la variable objetivo es distinta: el precio de mercado en lugar del volumen desembarcado.

2.3 Olas de calor marinas y su efecto sobre las pesquerías

Una ola de calor marina (*marine heatwave*, MHW) es un periodo prolongado de temperatura superficial del mar anómalamente alta. Hobday et al. (2016) propusieron la definición que se ha vuelto estándar —al menos cinco días consecutivos por encima del percentil 90 de una climatología de referencia— y Hobday et al. (2018) la extendieron con un esquema de categorías (moderada, fuerte, severa, extrema) que permite comparar eventos entre regiones. Esa definición es la que se implementa en el Capítulo 4.

Estos eventos se han vuelto más frecuentes y más largos: Oliver et al. (2018) documentan un aumento sostenido durante el último siglo, y Frölicher et al. (2018) proyectan su intensificación bajo calentamiento global. El Pacífico nororiental —la región de este trabajo— vivió uno de los episodios mejor documentados, el llamado “Blob” de 2014-2016, cuya persistencia interanual analizan Di Lorenzo and Mantua (2016) y cuyos efectos

biológicos, desde el plancton hasta los mamíferos marinos, sintetizan Cavole et al. (2016).

El vínculo con la captura está documentado a dos escalas. Globalmente, Free et al. (2019) estiman que el calentamiento histórico ya redujo la productividad pesquera máxima sostenible, y Smith et al. (2021) revisan los impactos socioeconómicos de las MHW sobre las comunidades que dependen de la pesca. Localmente —y es el hallazgo que reorientó este trabajo— Villaseñor-Derbez et al. (2024) documentan que las olas de calor marinas redujeron las capturas de langosta, erizo y pepino de mar en la península de Baja California entre un 15% y un 58% durante las últimas dos décadas, con impactos mayores cerca de los quiebres biogeográficos como San Quintín. Esa evidencia es la que justifica incorporar un índice de MHW como covariable y la que ofrece una hipótesis concreta sobre la caída de la temporada 2021-2022.

2.4 Modelos globales y agrupamiento parcial

Cuando cada serie individual es corta, la alternativa a entrenar un modelo por serie es entrenar *uno solo* sobre todas ellas —un *modelo global*— de modo que los parámetros se estimen con la unión de las observaciones y las series cortas se apoyen en las largas. Montero-Manso and Hyndman (2021) muestran que los modelos globales no son mejores por ser más complejos sino porque el conjunto agrupado permite ajustar modelos con más capacidad sin sobreajustar, y que su ventaja no requiere que las series sean “parecidas”. Petropoulos et al. (2022) documentan el mismo fenómeno en la práctica del pronóstico. Este es exactamente el régimen de este trabajo: decenas de series de unas pocas temporadas cada una. La contraparte es que las series de mayor escala dominan la función de pérdida, un problema que se aborda normalizando la variable objetivo (Sección 3.4.4).

2.5 Cuantificación de incertidumbre y predicción conformal

La regresión cuantílica (Koenker and Bassett, 1978) estima directamente los cuantiles condicionales de la respuesta en lugar de su media, lo que permite construir intervalos sin suponer una forma de la distribución del error. Sus intervalos, sin embargo, no tienen garantía de cobertura en muestra finita: el modelo puede estar mal calibrado.

La *predicción conformal* (Vovk et al., 2005; Angelopoulos and Bates, 2023) corrige eso: a partir de un conjunto de calibración disjunto del de entrenamiento, ajusta los intervalos para garantizar cobertura marginal al nivel nominal bajo el único supuesto de

intercambiabilidad. Romano et al. (2019) combinan ambas ideas en la *regresión cuantílica conformalizada* (CQR), que hereda la adaptabilidad de los cuantiles condicionales y añade la garantía de cobertura; es el método que se adopta en este trabajo. Cuando los cuantiles estimados se cruzan —un artefacto frecuente al estimarlos por separado— se aplica el reordenamiento monótono de Chernozhukov et al. (2010). Para evaluar pronósticos probabilísticos se usa el CRPS (Gneiting and Raftery, 2007), una regla de puntuación propia que premia simultáneamente calibración y nitidez.

2.6 Interpretabilidad

Con decenas de covariables derivadas y pocas temporadas, saber *cuáles* variables usa el modelo es tan importante como su error. Los valores SHAP (Lundberg and Lee, 2017) atribuyen la predicción a cada variable con una formulación basada en la teoría de juegos cooperativos, y permiten podar el conjunto de variables con un criterio explícito en lugar de por prueba y error.

Capítulo 3

Metodología

Este capítulo fija la notación, la partición temporal, las métricas y los modelos. Todo lo que se reporta en el Capítulo 5 se define aquí.

3.1 Planteamiento formal

Sea $\mathcal{S}$ el conjunto de *series*, donde cada serie $s \in \mathcal{S}$ es un par (especie, unidad económica). Para cada serie y cada día t se observa

- $y_s(t) \in \mathbb{R}_{\geq 0}$: el volumen desembarcado en kilogramos (la variable objetivo), y
- $\mathbf{x}_s(t) \in \mathbb{R}^p$: el vector de covariables oceanográficas del día t en la zona de la unidad económica (temperatura superficial del mar, su anomalía, el índice de olas de calor y las variables de color del océano).

El horizonte de pronóstico es $h = 90$ días. Esta elección no es estadística sino operativa: es el plazo acordado con COBI para que una cooperativa pueda actuar sobre el pronóstico. La convención del proyecto es, por tanto, usar el estado del océano de hoy para predecir la captura de dentro de tres meses,

$$\hat{y}_s(t+h) = f(\mathbf{x}_s(t), \mathbf{z}_s(t), s), \quad (3.1)$$

donde $\mathbf{z}_s(t)$ agrupa las variables deterministas del calendario y los rezagos de la propia serie que son estrictamente pasados en t . En la implementación, la ecuación (3.1) se realiza desplazando las covariables oceanográficas h días hacia adelante, de modo que la fila del día t nunca contiene información posterior a $t-h$; los detalles de construcción están en la Sección 4.6.

Temporada. La temporada de langosta va del 15 de septiembre al 15 de febrero del año siguiente; fuera de ese rango rige la veda (Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación, 2016). Se define el indicador $\text{ens}_s(t) \in \{0, 1\}$ (*in season*) y la partición del calendario en temporadas $\mathcal{T}_1, \dots, \mathcal{T}_K$. El agregado que le interesa a la cooperativa es la suma de temporada $Y_s(\mathcal{T}_k) = \sum_{t \in \mathcal{T}_k} y_s(t)$.

Modelo específico y modelo global. Un *modelo específico* estima una función f_s por serie usando solo los datos de s . Un *modelo global* estima una única f sobre la unión $\bigcup_s \{(\mathbf{x}_s(t), y_s(t))\}$, con la identidad de la serie como covariable categórica. La comparación entre ambos es una de las preguntas del trabajo.

3.2 Partición temporal y validación

Toda partición respeta el orden cronológico: no se usa validación cruzada aleatoria, que en series de tiempo filtra el futuro hacia el pasado (Tashman, 2000; Bergmeir and Benítez, 2012).

Cortes de prueba. Se reportan sistemáticamente *dos* cortes:

- **01-julio-2020**, el corte canónico, elegido para ser comparable con la primera iteración del trabajo. Deja ~ 3 temporadas de entrenamiento y la caída post-ola-de-calor *fuera* del entrenamiento.
- **01-junio-2024**, que aprovecha las temporadas 2022-2026 incorporadas en este trabajo. Deja ~ 7 temporadas de entrenamiento y la caída *dentro* del entrenamiento.

Reportar ambos no es redundante: la diferencia entre columnas aísla el efecto de *cuántas temporadas* ve el modelo, que es precisamente la hipótesis bajo prueba. Cada experimento acepta el corte como parámetro (variable de entorno `FF_CUT_DATE`), de modo que las dos columnas provienen del mismo código.

Validación durante el ajuste. Dentro del conjunto de entrenamiento se usa una ventana expansiva: los datos se dividen en n bloques cronológicos y el bloque k se valida con un modelo ajustado sobre todo lo anterior, de manera que cada partición de entrenamiento es un superconjunto de la anterior y el bloque de validación siempre está en el futuro respecto al de ajuste (Figura 3.1).




Figura 3.1: Esquema de validación con ventana expansiva. Cada partición de entrenamiento (azul) es un superconjunto de la anterior y el bloque de validación (naranja) siempre está en el futuro respecto a los datos con los que se ajusta el modelo.

Ausencia de fuga de información. Se aplican tres reglas, verificadas con pruebas automatizadas:

1. Toda covariable oceanográfica es un desplazamiento de al menos h días, ya sea del valor o de una media móvil que termina en t y luego se desplaza.
2. Toda estadística agregada —medias y desviaciones de estandarización, estadísticas de imputación, los cuantiles del conformal— se calcula *únicamente* sobre el conjunto de entrenamiento (o de calibración) y se aplica al de prueba.
3. En el ensamble, la predicción de un modelo que alimenta a otro se construye fuera de muestra con la ventana expansiva; usar la predicción en muestra le daría al segundo modelo una señal que en prueba no existe con esa calidad.

3.3 Métricas

Sean $y_1, \dots, y_n$ las observaciones del conjunto de prueba y $\hat{y}_1, \dots, \hat{y}_n$ las predicciones puntuales.

Error diario.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.2)$$

El MAE está en kilogramos y es interpretable; el RMSE penaliza más los errores grandes, que en esta serie ocurren en los días de apertura.

Error porcentual simétrico. Como la escala varía en dos órdenes de magnitud entre unidades económicas, se agrega el sMAPE (Hyndman and Koehler, 2006), acotado en $[0, 200]$ y definido con la convención de que los términos 0/0 (día sin captura predicho como cero) cuentan como cero:

$$\text{sMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}. \quad (3.3)$$

Error en la suma de temporada. Es la métrica que le importa a la cooperativa:

$$e(\mathcal{T}_k) = 100 \cdot \frac{\sum_{t \in \mathcal{T}_k} \hat{y}(t) - \sum_{t \in \mathcal{T}_k} y(t)}{\sum_{t \in \mathcal{T}_k} y(t)}. \quad (3.4)$$

Se reporta con signo, porque sobre-predecir y sub-predecir tienen consecuencias operativas distintas.

Diagnóstico de forma. En una serie donde la mayoría de los días están en veda, un pronóstico casi plano obtiene un MAE bajo sin informar nada. Para distinguir el ajuste real del aplanamiento se reportan dos diagnósticos: la razón de dispersión $\text{sd}(\hat{y})/\text{sd}(y)$ —cercana a 0 delata un pronóstico plano, muy por encima de 1 un modelo que sobre-reacciona— y la correlación de Pearson entre $\hat{y}$ y y .

Métricas probabilísticas. Para un cuantil $\tau \in (0, 1)$ con predicción $\hat{q}_\tau$, la pérdida *pinball* es

$$L_\tau(y, \hat{q}_\tau) = \begin{cases} \tau(y - \hat{q}_\tau) & \text{si } y \geq \hat{q}_\tau, \\ (1 - \tau)(\hat{q}_\tau - y) & \text{en otro caso.} \end{cases} \quad (3.5)$$

El CRPS (Gneiting and Raftery, 2007) se aproxima a partir de una rejilla de m cuantiles mediante su descomposición en pérdidas pinball,

$$\text{CRPS} \approx \frac{2}{m} \sum_{j=1}^m L_{\tau_j}(y, \hat{q}_{\tau_j}), \quad (3.6)$$

y está en kilogramos, por lo que solo es comparable entre series de escala similar. Para un intervalo $[\ell_i, u_i]$ de nivel nominal $1 - \alpha$ se reportan la **cobertura empírica** y el **ancho medio**:

$$\widehat{C} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{\ell_i \leq y_i \leq u_i\}, \quad \overline{W} = \frac{1}{n} \sum_{i=1}^n (u_i - \ell_i). \quad (3.7)$$

Las dos se leen juntas: la cobertura sola se maximiza con un intervalo infinitamente ancho.

3.4 Modelos

3.4.1 Modelos de referencia

ARIMA (Box et al., 2015) y Prophet (Taylor and Letham, 2017) sirven de piso: son autorregresivos y no usan covariables oceanográficas, de modo que superarlos es la condición mínima para afirmar que las variables del océano aportan señal. Los órdenes (p, d, q) de ARIMA se eligen por AIC sobre el conjunto de entrenamiento en una rejilla acotada.

3.4.2 Ensamblados de árboles

XGBoost (Chen and Guestrin, 2016) y LightGBM (Ke et al., 2017) son las familias de referencia para datos tabulares: manejan no linealidades, interacciones y valores faltantes de forma nativa, lo que importa porque las covariables oceanográficas tienen huecos.

3.4.3 Modelos recurrentes

La LSTM (Hochreiter and Schmidhuber, 1997; Greff et al., 2017; Staudemeyer and Morris, 2019) procesa la serie como secuencia. Se usa una ventana de 10 pasos y dos capas apiladas con *dropout*. Al ser un modelo de la primera iteración del trabajo, se conserva su arquitectura para poder comparar contra ella.

3.4.4 Modelo global con la variable objetivo normalizada

El modelo global agrupa todas las series con la identidad de la serie codificada como variable categórica. El problema del agrupamiento directo es que la función de pérdida queda dominada por las series de mayor tonelaje. Para evitarlo se transforma la variable objetivo con

$$\tilde{y} = \log(1 + y), \tag{3.8}$$

una transformación global, invertible y *sin parámetros estimados* —por lo que no puede filtrar información del conjunto de prueba—, y se invierte con $\exp(\tilde{y}) - 1$ antes de calcular cualquier métrica en kilogramos. Se comparó también la estandarización por serie (*z-score* con media y desviación calculadas solo en entrenamiento), que resulta inferior al logaritmo en las series clave.

3.4.5 Transformer de fusión temporal

El TFT (Lim et al., 2021; Vaswani et al., 2017) es un modelo de atención multi-horizonte con selección de variables, diseñado para series con covariables estáticas, conocidas y observadas. Se incluye como *prueba de techo*: no como candidato a producto, sino para responder si la capacidad adicional compra algo con este volumen de datos.

3.5 Pronóstico probabilístico: regresión cuantílica conformalizada

El producto no es un número sino un intervalo con cobertura verificable. El procedimiento combina regresión cuantílica con predicción conformal por partición (*Mondrian*), y opera en la escala logarítmica de la Sección 3.4.4:

1. **Partición.** El conjunto anterior al corte se divide cronológicamente en *entrenamiento* $\mathcal{D}_{\text{tr}}$ y *calibración* $\mathcal{D}_{\text{cal}}$, disjuntos. La calibración se restringe a días en temporada, porque es el régimen en el que el intervalo se va a usar.
2. **Cuantiles base.** Sobre $\mathcal{D}_{\text{tr}}$ se ajusta un modelo global cuantílico (*gradient boosting* con pérdida pinball) para una rejilla de cuantiles $\tau_1 < \dots < \tau_m$, obteniendo $\hat{q}_\tau(\cdot)$. Si los cuantiles estimados se cruzan, se reordenan de forma monótona por fila (Chernozhukov et al., 2010).
3. **Puntuaciones de no conformidad.** Para el intervalo de nivel $1 - \alpha$ con cuantiles inferior $\tau_{\text{lo}} = \alpha/2$ y superior $\tau_{\text{hi}} = 1 - \alpha/2$, se calcula en cada punto de calibración

$$E_i = \max \{ \hat{q}_{\tau_{\text{lo}}}(\mathbf{x}_i) - \tilde{y}_i, \tilde{y}_i - \hat{q}_{\tau_{\text{hi}}}(\mathbf{x}_i) \}, \quad (3.9)$$

que es positiva cuando la observación cae fuera del intervalo y negativa cuando cae dentro con holgura (Romano et al., 2019).

4. **Corrección.** Sea $Q_{1-\alpha}(E)$ el cuantil empírico $(1 - \alpha)(1 + 1/|\mathcal{D}_{\text{cal}}|)$ de las puntuaciones. El intervalo conformalizado es

$$\left[\hat{q}_{\tau_{\text{lo}}}(\mathbf{x}) - Q_{1-\alpha}(E), \hat{q}_{\tau_{\text{hi}}}(\mathbf{x}) + Q_{1-\alpha}(E) \right], \quad (3.10)$$

que bajo intercambiabilidad tiene cobertura marginal de al menos $1 - \alpha$ en muestra finita. Se probó también una variante *normalizada*, en la que la corrección se ensancha proporcionalmente a la dispersión local en lugar de ser constante.

5. **Mondrian por serie.** Los pasos 3 y 4 se ejecutan *por serie*: cada especie $\times$ unidad económica tiene su propio $Q_{1-\alpha}(E)$. Esto es indispensable porque las escalas difieren en órdenes de magnitud, y además permite auditar la cobertura serie por serie —la cobertura marginal promedia y puede ocultar una serie mal calibrada, como se verá en la Sección 5.8.
6. **Regreso a kilogramos.** Los extremos se invierten con $\exp(\cdot) - 1$ y se truncan en cero. La inversión es monótona, de modo que preserva la cobertura.

3.6 Selección de hiperparámetros

Para los modelos estadísticos se usa búsqueda exhaustiva en una rejilla acotada con criterio AIC. Para los modelos de aprendizaje de máquina y profundo se usa optimización bayesiana con Optuna (Akiba et al., 2019), con un número limitado de ensayos para que el experimento sea reproducible en un tiempo razonable, y evaluando siempre sobre la ventana expansiva de validación descrita en la Sección 3.2, nunca sobre el conjunto de prueba. Toda componente estocástica —inicialización de pesos, submuestreo, semillas del optimizador— usa una semilla fija que se registra junto con las métricas del experimento.

3.7 Reproducibilidad

El trabajo se implementó como un paquete de Python —sobre `numpy` (Harris et al., 2020), `pandas` (McKinney, 2010), `scikit-learn` (Pedregosa et al., 2011) y `PyTorch` (Paszke et al., 2019)— con pruebas automatizadas (157 pruebas unitarias que cubren el proceso de datos, las métricas, la construcción de variables sin fuga de información y la envoltura conformal). Cada experimento:

- se ejecuta con *un* comando y acepta el corte de prueba como parámetro;
- escribe sus métricas en un archivo JSON versionado por corte, sus figuras en PNG y un resumen en Markdown, de modo que las cifras de este documento provienen de esos artefactos versionados o, en el caso de las instantáneas históricas señaladas como tales, de la bitácora de corridas del repositorio;
- fija y registra la semilla aleatoria.

Las decisiones de diseño no triviales —el tratamiento de la variable objetivo faltante y la justificación de la prueba de techo con el TFT— están registradas como ADR (*Ar-*

chitecture Decision Records) en el repositorio, escritas *antes* de correr los experimentos correspondientes.

Capítulo 4

Datos

Este capítulo describe de dónde vienen los datos, cómo se consolidan y qué contiene el conjunto resultante. La descripción variable por variable del acervo original de la primera iteración está en el Apéndice B; las variables vigentes se describen en las Secciones 4.1 y 4.6.

4.1 Fuentes

Arribos pesqueros. La variable objetivo proviene de dos fuentes complementarias. La primera es el registro histórico de COBI (2016-2021), obtenido por convenio, con granularidad de aviso de arribo. La segunda son los *avisos de cosecha* de CONAPESCA (“AVISOS MAYORES/MENORES DE COSECHA”, 2022-2026), publicados como datos abiertos (Comisión Nacional de Acuacultura y Pesca, 2026). La segunda fuente fue la que permitió duplicar el número de temporadas disponibles.

Oceanografía. La temperatura superficial del mar (SST) proviene del producto reprocesado L4 de Copernicus Marine Service (OSTIA, `METOFFICE-GLO-SST-L4-REP-OBS-SST`), con cobertura diaria global desde 1981. OSTIA es un análisis que combina observaciones satelitales e in situ en una malla libre de nubes (Donlon et al., 2012), en la configuración operativa descrita por Good et al. (2020). Las variables de color del océano —clorofila (CHL), coeficiente de atenuación difusa (KD490), materia particulada en suspensión (SPM), profundidad de disco de Secchi (ZSD), retrodispersión de partículas (BBP) y materia orgánica coloreada disuelta (CDM)— provienen del acervo GlobColour (Glo, 2020) redistribuido por Copernicus, a 4 km de resolución.

Nota sobre el acceso a GlobColour. La primera iteración de este trabajo descargaba GlobColour por FTP. Esa vía entrega archivos *globales sin recorte* (18 MB por variable y por día a 4 km, del orden de cientos de gigabytes para el periodo y las variables de interés), lo que la hace inviable. Se optó por la misma información redistribuida por Copernicus, que permite recortar del lado del servidor. Las variables atmosféricas del acervo original (POC, PIC, PAR, aerosoles, nubosidad) no están disponibles por esa vía y se omiten.

4.2 Consolidación

Se reescribió el proceso ETL de forma modular y reproducible. Los arribos pesqueros se ingieren con granularidad de una fila por (fecha, especie, unidad económica) uniendo dos fuentes complementarias: el export histórico de COBI (2016-2021) y los avisos de cosecha (“AVISOS MAYORES/MENORES DE COSECHA”) de CONAPESCA (2022-2026). La unión se resuelve por prioridad temporal —COBI hasta el 31-diciembre-2021 y CONAPESCA a partir de 2022, cada archivo acotado a su propio año— de modo que no hay doble conteo en la costura de 2021. El lector de CSV autodetecta el encabezado (el preámbulo de los avisos varía entre 2 y 4 líneas) y la limpieza acepta rangos de fecha explícitos. El conjunto consolidado cubre así 2017-2026, casi duplicando las temporadas disponibles de langosta en San Quintín (de ~ 5 a ~ 9). Como fuente de temperatura superficial del mar (SST) se adoptó el producto reprocesado L4 de Copernicus Marine Service (OSTIA, METOFFICE-GLO-SST-L4-REP-OBS-SST), con cobertura diaria global desde 1981; se descargó la serie 1982-2025 y se promedió sobre el bounding box costero de cada unidad económica. Esta fuente reemplaza al cliente `motuclient` —descontinuado en 2024— por el nuevo SDK `copernicusmarine`, y provee la profundidad histórica necesaria para construir una climatología de referencia de 30 años.

Consistencia del empalme. Como las dos fuentes de arribos se unen en la frontera de 2021, se verificó que la costura no introdujera un salto de escala. No hay fechas duplicadas; COBI termina el 31-diciembre-2021 —truncando la temporada 2021-2022 a unas 31 t— y la unión recupera enero y febrero de 2022, completando esa temporada a 39.5 t. La transición es continua: diciembre de 2021 según COBI (6.3 t) es comparable con enero de 2022 según CONAPESCA (6.5 t). La limitación honesta es que *no existe un periodo de solape* entre ambas fuentes que permita validar la escala de forma exhaustiva; el traspaso diciembre→enero es la evidencia disponible y es consistente.

Esquema. El conjunto consolidado tiene una fila por (fecha, especie, unidad económica) sobre el rango de fechas completo —no solo los días con registro—, con la variable objetivo, las covariables oceanográficas, el indicador de temporada, la temporada a la que pertenece el día, banderas de imputación y metadatos de trazabilidad del proceso. Se almacena en formato Parquet particionado por especie y año.

4.3 Tratamiento de la variable objetivo faltante

Como el conjunto cubre todos los días y no solo los días con aviso, hay que decidir qué valor toma la captura en los huecos. La semántica importa: un 0 afirma “no se pescó” y un valor faltante afirma “no sabemos”. La decisión adoptada distingue tres casos:

1. **Fuera de temporada** sin registro $\Rightarrow y = 0$. No es una imputación sino la consecuencia lógica de la veda.
2. **Dentro de temporada** sin registro $\Rightarrow y$ faltante. Puede ser un día sin pesca (clima, festivo) o un hueco de captura de datos, y no hay forma de distinguirlos, así que no se inventa un valor.
3. Cualquier imputación explícita queda marcada con una bandera, de modo que sea rastreable. No se hace por omisión.

Cada modelo decide cómo tratar el faltante en su propia capa de preparación —en los experimentos de este trabajo se rellena con cero dentro de temporada, bajo el supuesto de que un día en temporada sin registro es un día sin captura— pero el conjunto de datos preserva la distinción. La decisión está documentada como ADR en el repositorio.

4.4 Zona de cada unidad económica

La oceanografía se agrega espacialmente sobre la zona costera de cada unidad económica. Lo correcto sería recortar con el polígono TURF exacto de cada cooperativa, pero esos polígonos no son de acceso público y no fue posible obtenerlos. Se usa en su lugar un rectángulo costero (*bounding box*) por clúster de cooperativas. A la resolución de los productos satelitales empleados — 0.05° para la SST y 4 km para el color del océano— el rectángulo es una aproximación razonable, y es además lo que hacía la primera iteración del trabajo; el polígono exacto queda como mejora deseable y no bloqueante. La Figura 4.2 muestra las zonas sobre el campo medio de SST, y la Figura 4.1 el detalle de la zona de San Quintín.




Figura 4.1: Detalle de la zona costera (*bounding box*) asignada a la unidad económica LITORAL DE BAJA CALIFORNIA S DE PR DE RL, la cooperativa de San Quintín que sirve de serie insignia, sobre la SST media. El rectángulo cubre también tierra; los píxeles sobre tierra no tienen dato de SST y no entran al promedio espacial.

4.5 Índice de olas de calor marinas

Se implementó el índice de MHW siguiendo la metodología de Hobday et al. (2016): para cada día del año se calcula una climatología y su percentil 90 sobre el periodo base 1982-2011; un evento MHW es un tramo de al menos 5 días consecutivos con SST por encima de ese umbral (fusionando eventos separados por huecos de ≤ 2 días), y se clasifica en categorías I-IV según cuántos múltiplos de la diferencia (umbral – media) alcanza la anomalía. El dataset consolidado incorpora tres columnas nuevas: **sst_anomaly** (siempre), **mhw_category** (0-4) y **mhw_intensity** (definida durante eventos).

Como validación, el índice reproduce con nitidez los eventos conocidos del Pacífico nororiental: el llamado “Blob” de 2014-2016 (con 231, 293 y 102 días de MHW respectivamente en la zona de San Quintín) y el régimen cálido de 2019-2021 (Figura 4.3). Esta validación es relevante porque conecta directamente con el mecanismo documentado por Villaseñor-Derbez et al. (2024).




Figura 4.2: Zonas costeras asignadas a los clústeres de unidades económicas del conjunto consolidado, sobre la SST media de 2025. La península de Baja California aparece en blanco (sin dato de SST sobre tierra) y el agua cálida al oriente es el Golfo de California. El gradiente térmico a lo largo del rango es explícito: de $\sim 17^{\circ}\text{C}$ en San Quintín ($\sim 30.4^{\circ}\text{N}$) a $\sim 22^{\circ}\text{C}$ en Bahía Magdalena ($\sim 24.5^{\circ}\text{N}$).




Figura 4.3: Serie diaria de SST en el bbox de San Quintín (negro) contra su climatología (azul continuo) y el umbral del percentil 90 (azul discontinuo), con periodo base 1982-2011 (Hobday et al., 2016). Las áreas sombreadas marcan los eventos de ola de calor marina. Destacan el “Blob” de 2014-2016 y el régimen cálido de 2019-2021 que precede al colapso de la captura de langosta de la temporada 2021-2022.

4.6 Construcción de variables

A partir del conjunto consolidado se construye la matriz de variables explicativas de la ecuación (3.1), con tres bloques:

- **Calendario** (determinista en t): día del año codificado como $(\sin, \cos)$ e indicador de temporada.
- **Rezagos de la propia serie**: la captura de la misma fecha de uno y dos años atrás, que captura el ciclo anual.
- **Oceanografía desplazada**: cada covariable oceanográfica en $t - h$, más medias móviles de 90 y 365 días que terminan en $t - h$ —es decir, el estado del mar previo a la temporada y el calor acumulado del año anterior. El desplazamiento es el mecanismo ecológico que se quiere modelar y, a la vez, lo que garantiza que no haya fuga de información (Figura 4.4).

Con las seis variables de color del océano el conjunto crece a unas 35 variables, un número grande frente a las pocas temporadas disponibles; el Capítulo 5 muestra que ese desbalance importa y cómo se corrige con selección de variables.




Figura 4.4: El desplazamiento temporal de 90 días con la SST real de la zona de San Quintín (2019-2020): en azul la serie original y en amarillo la desplazada. La convención del proyecto usa el estado del océano en t para predecir la captura en $t + 90$ días.

4.7 El conjunto consolidado

El resultado cubre **2017-2026** y contiene **44 series** (especie $\times$ unidad económica) con al menos un día de captura registrado, que suman **10,465 toneladas** desembarcadas: 21 series de langosta roja (7,569 t), 14 de abulón azul, 6 de erizo rojo y 3 de otras especies de abulón. La mediana de días con captura por serie es de **70**, lo que ilustra el problema de fondo: aun con casi una década de cobertura, cada serie individual aporta pocas observaciones. La Tabla 4.1 desglosa cada serie.

Tabla 4.1: Series (especie $\times$ unidad económica) del conjunto consolidado 2017-2026. ‘Temp.’ cuenta las temporadas con al menos un día de captura; ‘Días’ son los días con captura; ‘Ton.’ las toneladas desembarcadas del periodo; la cobertura es la fracción de días con el valor oceanográfico disponible.

Especie	Zona (cooperativa)	Temp.	Días	Ton.	Cob. SST	Cob. CHL
Abulón negro	San Quintín (Litoral de BC)	5	51	2.5	100%	100%
Abulón negro	El Rosario (SCPP Ensenada)	5	20	2.3	100%	100%
Abulón azul	Vizcaíno (Pesc. Nac. de Abulón)	4	33	175.1	100%	100%
Abulón azul	El Rosario (SCPP Ensenada)	9	68	59.7	100%	100%
Abulón azul	Pacífico BCS (La Purísima)	4	28	24.8	100%	100%
Abulón azul	Bahía Magdalena (Puerto Chale)	4	15	16.2	100%	100%
Abulón azul	Vizcaíno (Bahía Tortugas)	1	8	9.3	100%	100%

Especie	Zona (cooperativa)	Temp.	Días	Ton.	Cob. SST	Cob. CHL
Abulón azul	Punta Canoas	9	31	7.8	100%	100%
Abulón azul	San Quintín (Litoral de BC)	5	62	5.5	100%	100%
Abulón azul	Pacífico BCS (Progreso)	4	17	5.1	100%	100%
Abulón azul	Bahía Magdalena	1	6	4.2	100%	100%
Abulón azul	Pacífico BCS (Calif. de San Ignacio)	1	5	2.6	100%	100%
Abulón azul	Vizcaíno (Buzos y Pescadores)	3	4	2.6	100%	100%
Abulón azul	Vizcaíno (Emancipación)	4	12	2.1	100%	100%
Abulón azul	Pacífico BCS (Punta Abreojos)	1	2	0.3	100%	100%
Abulón azul	El Rosario (Regasa)	1	1	0.0	100%	100%
Abulón rojo	San Quintín (Litoral de BC)	5	42	2.9	100%	100%
Langosta roja	El Rosario (SCPP Ensenada)	10	688	1,181.2	100%	100%
Langosta roja	Vizcaíno (Pesc. Nac. de Abulón)	10	307	904.2	100%	100%
Langosta roja	Vizcaíno (Bahía Tortugas)	5	193	767.1	100%	100%
Langosta roja	San Quintín (Litoral de BC)	9	1110	689.7	100%	100%
Langosta roja	Vizcaíno (Emancipación)	5	182	615.8	100%	100%
Langosta roja	Pacífico BCS (La Purísima)	5	78	532.9	100%	100%
Langosta roja	Vizcaíno (Leyes de Reforma)	6	148	493.8	100%	100%
Langosta roja	Pacífico BCS (Progreso)	6	133	366.5	100%	100%
Langosta roja	Vizcaíno (Buzos y Pescadores)	5	143	362.1	100%	100%
Langosta roja	El Rosario (El Chute)	10	307	282.4	100%	100%
Langosta roja	El Rosario (Mortera de Leyva)	10	269	267.7	100%	100%
Langosta roja	Pacífico BCS (Punta Abreojos)	5	109	260.2	100%	100%
Langosta roja	El Rosario (Regasa)	10	392	232.4	100%	100%
Langosta roja	El Rosario (Isla San Jerónimo)	10	316	162.3	100%	100%
Langosta roja	Pacífico BCS (Calif. de San Ignacio)	5	67	152.0	100%	100%
Langosta roja	Punta Canoas	10	208	82.6	100%	100%
Langosta roja	San Quintín (El Pabellón)	8	193	80.0	100%	100%
Langosta roja	San Quintín (Rocas de San Martín)	10	217	58.3	100%	100%
Langosta roja	Bahía Magdalena (Puerto Chalé)	5	44	34.2	100%	100%
Langosta roja	Bahía Magdalena	6	72	25.3	100%	100%
Langosta roja	Bahía Magdalena (Puerto San Carlos)	5	89	18.8	100%	100%
Erizo rojo	El Rosario (SCPP Ensenada)	10	490	1,483.3	100%	100%
Erizo rojo	El Rosario (Regasa)	10	487	644.6	100%	100%
Erizo rojo	El Rosario (Mortera de Leyva)	10	406	406.5	100%	100%
Erizo rojo	El Rosario (El Chute)	4	21	19.2	100%	100%
Erizo rojo	El Rosario (Isla San Jerónimo)	2	9	10.4	100%	100%
Erizo rojo	Punta Canoas	9	23	8.4	100%	100%

4.8 Origen de la información de las figuras heredadas

La primera iteración de este trabajo construyó su proceso de datos sobre GlobColour por FTP y sobre un intercambio directo de archivos con COBI. Ese proceso se muestra en la Figura 4.5 y se conserva porque documenta el punto de partida; el proceso vigente es el descrito en la Sección 4.2.



Figura 4.5: Proceso de datos de la primera iteración del trabajo: ingestión de GlobColour por FTP y de los archivos de COBI, transformación de .nc a tablas y consolidación. El proceso vigente, descrito en la Sección 4.2, sustituye la ingestión por FTP por el SDK de Copernicus con recorte del lado del servidor.

Capítulo 5

Resultados

Los resultados se presentan en el orden en que se produjeron, porque ese orden *es* el argumento: cada sección responde a una limitación descubierta en la anterior. Se parte de la comparación de modelos puntuales sobre una sola serie, que deja abierta la pregunta del año atípico; se identifica el mecanismo ambiental que lo explica; se intenta —sin éxito— resolver la escasez de datos con más variables, con selección de variables y con el agrupamiento directo; se reformula el pronóstico en términos probabilísticos; se pone a prueba la hipótesis de datos aumentando las series y las temporadas; y finalmente se contrasta contra una arquitectura de vanguardia.

5.1 Primera iteración: comparación de modelos puntuales

Después de la optimización de hiperparámetros y parámetros de cada modelo, y de la toma de decisión de arquitectura en el caso de LSTM, se llegó a los modelos representativos de la Tabla 5.1:

(*) La arquitectura y los hiperparámetros del modelo LSTM elegido son:

Arquitectura de la LSTM

- Capa de entrada con dimensiones de entrada (batch size, time steps, features) igual a (None, 10, 17).
 - Capa LSTM con 2700 unidades, activación 'relu', función de activación recurrente 'sigmoid', y una tasa de dropout del 30%. Esta capa regresa secuencias y no estados.
 - Capa de dropout con una tasa de dropout del 30%, aplicada a la salida de la capa LSTM.

Modelo	Arquitectura / Parámetros
LSTM	(*)
Prophet	changepoint prior scale: 0.016, seasonality prior scale: 750.108
LGBM	colsample bytree: 0.64, learning rate: 0.10, max depth: 6, n estimators: 63, num leaves: 67
XGBoost	colsample bytree: 0.37, learning rate: 0.02, max depth: 10, n estimators: 190
ARIMA	d: 0, p: 29, q: 24, trend: c

Tabla 5.1: Modelos seleccionados y su composición

- Capa LSTM con 800 unidades, activación 'relu', función de activación recurrente 'sigmoid', y una tasa de dropout del 30%. Esta capa no retorna secuencias, solo el estado final.

- Capa de dropout con una tasa de dropout del 30%, aplicada a la salida de la segunda capa LSTM.

- Capa densa con 1 unidad y activación 'relu'.

Hiperparámetros de la LSTM

- Unidades en la primera capa LSTM: 2700.

- Unidades en la segunda capa LSTM: 800.

- Tasa de dropout: 30%.

- Función de activación en las capas LSTM: 'relu'.

- Función de activación recurrente en las capas LSTM: 'sigmoid'.

- Se utiliza la inicialización de pesos GlorotUniform para las capas LSTM y Dense.

- Se utiliza la inicialización de pesos Orthogonal para los pesos recurrentes de las capas LSTM.

- Las capas LSTM no son stateful y no se desenrollan en el tiempo.

- Se utiliza la implementación 2 para las capas LSTM.

- La capa densa tiene 1 unidad de salida.

Los resultados de las métricas de cada modelo, tal como los reportó el borrador, se resumen en la Tabla 5.2; las gráficas de valores predichos contra valores reales de cada modelo están en el Apéndice A (Figuras A.1 a A.7).

Modelo	Err. temp. 2020-21	Err. temp. 2021-22	Err. ambas	RMSE	MAE
XGBoost + LSTM	8.7%	92%	12.9%	527.3	369.0
XGBoost	12%	16.3%	14.5%	450.7	312.6
LGBM	36%	36%	36.4%	494.9	380.2
LSTM	—	—	61%	183.1	104.9
Prophet	164%	1737%	761%	135.0	105.8
ARIMA	338%	142%	142%	467.5	344.1

Tabla 5.2: Resultados de la primera iteración (borrador de 2023) por modelo: error en la suma de temporada (2020-2021, 2021-2022 y ambas) y RMSE/MAE diarios en kg. *Nota:* las cifras se transcriben tal cual del borrador, cuyo proceso de datos dependía de fuentes hoy inaccesibles y no es reproducible; contienen inconsistencias internas menores de transcripción (algunos errores porcentuales no cuadran exactamente con las sumas que los acompañaban), por lo que deben leerse como el registro histórico del punto de partida y no como cifras verificadas. La re-corrida verificable de estos mismos modelos sobre el conjunto unido 2017-2026 está en la Tabla 5.9.

Se optó por ensamblar XGBoost, el mejor modelo para predecir la tendencia, junto con LSTM: primero se hace la predicción con XGBoost y ese vector de y se introduce en LSTM como un regresor más. Los resultados del ensamble son los mejores, con un error de captura del 8.7% para la primera temporada y un error global del 12.9%. A pesar de esto, los resultados para la segunda temporada no son nada favorables.

Además, los RMSE y MAE son elevados, lo cual implica que las predicciones diarias son poco precisas, a pesar de que la suma de toda la temporada se predice con poco error. Esto puede significar un reto para confiar en el modelo, pero es consecuencia de la falta de granularidad en los datos de entrenamiento.

En general, todos los modelos sobreestimaron la pesca de la segunda temporada debido a que podría tratarse de un caso atípico. Si comparamos esta temporada con el resto, el total de pesca es menos de la mitad. Por esta razón se decidió optar por predecir la temporada 2020-2021 también, pues es similar a las demás.

No obstante, debemos poner atención a la causa de la reducción de la pesca en la temporada 2021-2022. Inicialmente se planteó la hipótesis de un efecto económico externo (el último año de la pandemia de Covid-19); sin embargo, el índice de olas de calor marinas de la Sección 4.5 atribuye la caída a un mecanismo ambiental: las olas de calor marinas que afectaron a Baja California entre 2019 y 2021 (Villaseñor-Derbez et al., 2024). Esto explica

por qué los modelos que solo usan el historial de capturas —o las variables oceanográficas sin un índice de anomalía térmica de largo plazo— sobreestiman sistemáticamente esa temporada.

El paso siguiente que este planteamiento dejaba señalado —conseguir datos de otras regiones y de otras especies, replicar el procedimiento y verificar si los modelos elegidos sostienen sus resultados— es exactamente el que emprenden las secciones que siguen.

5.2 El bache de la temporada 2021-2022 se explica por olas de calor

Las sumas de captura de langosta en San Quintín, reconstruidas a partir de los arribos, muestran una caída pronunciada tras el régimen cálido 2019-2021: aproximadamente 173 t en 2019-2020, 106 t en 2020-2021 y 39.5 t en 2021-2022 (una reducción cercana al 77% respecto al máximo). Es más, la unión con CONAPESCA revela que la captura *no se recuperó* en las temporadas siguientes, sino que se estabilizó en niveles bajos: 24.4 t en 2022-2023, 18.5 t en 2023-2024 y 17.0 t en 2024-2025 (una décima parte del máximo). Esta magnitud iguala o supera el rango de 15-58% de reducción de capturas atribuido a las MHW en Baja California (Villaseñor-Derbez et al., 2024), coherente con que los impactos son mayores cerca de quiebres biogeográficos como San Quintín; y resuelve la pregunta abierta de la sección de Resultados: la caída no obedece principalmente a un efecto económico, sino a un forzamiento ambiental que los modelos originales no podían anticipar por carecer de una variable de anomalía térmica de largo plazo.

Un detalle de la reconstrucción merece mención, porque valida la unión de fuentes: el registro de COBI termina el 31-diciembre-2021, a mitad de la temporada 2021-2022, de modo que por sí solo la truncaba (solo ~31 t hasta diciembre). La unión con CONAPESCA recupera el tramo enero-febrero de 2022 y completa la temporada en 39.5 t. El empalme es limpio: no hay fechas duplicadas entre fuentes, y la transición es continua —diciembre de 2021 (COBI, 6.3 t) y enero de 2022 (CONAPESCA, 6.5 t) reportan a escalas compatibles—, lo que da confianza en que comparar temporadas anteriores (COBI) con posteriores (CONAPESCA) no introduce un artefacto de fuente.

5.3 Re-entrenamiento del baseline y modelo con covariables

Sobre los datos reales reconstruidos (langosta $\times$ San Quintín, corte de prueba 01-julio-2020) se re-entrenaron los modelos baseline y un modelo con las nuevas covariables oceanográficas (SST y MHW desplazadas 90 días, respetando la convención del proyecto y evitando fuga de datos). La Tabla 5.3 resume el desempeño.

Modelo	MAE	RMSE	sMAPE (%)	Err. 2020-21	Err. 2021-22
ARIMA(3,0,3)	345	463	138	−26%	+291%
Prophet	372	576	129	+62%	+418%
XGBoost (SST+MHW)	327	558	126	+53%	+368%

Tabla 5.3: Baseline re-derivado sobre datos reales y modelo con covariables SST/MHW. Todos sobreestiman fuertemente la temporada del bache (2021-2022). *Nota:* estas cifras son la fotografía *previa* a la unión con los avisos de CONAPESCA —tres temporadas de entrenamiento y dos de prueba, que era todo lo disponible en ese momento—; la Tabla 5.9 las refresca sobre el conjunto unido 2017-2026.

Los modelos autorregresivos (ARIMA, Prophet), que solo usan el historial de y , sobreestiman la temporada 2021-2022 por factores de 3 a 4, pues no “ven” la ola de calor. El modelo XGBoost con covariables sí selecciona las variables de MHW entre sus más importantes (por ejemplo, la media móvil de anomalía de SST y de categoría MHW del año previo), pero con únicamente tres temporadas de entrenamiento no logra aún corregir la sobreestimación. Esto confirma el diagnóstico del planteamiento inicial: el cuello de botella no es la complejidad del modelo, sino la escasez de temporadas.

5.4 Color del océano y selección de variables con SHAP

Para enriquecer el conjunto de regresoras se integraron seis variables ópticas y biológicas de color del océano, re-distribuidas por Copernicus Marine a partir del acervo GlobColour: clorofila (CHL), coeficiente de atenuación difusa (KD490), materia particulada en suspensión (SPM), profundidad de disco de Secchi (ZSD), retrodispersión de partículas (BBP) y materia orgánica coloreada disuelta y detritos (CDM). Al igual que la SST se desplazan 90 días y se agregan medias móviles, con lo que el conjunto crece a unas 35 variables. Sin embargo, añadirlas al modelo de una sola serie *empeora* el desempeño (MAE de 327 a 424;

error de la temporada 2021-2022 de +368% a +399%): un caso claro de sobreajuste con 35 variables y solo tres temporadas.

Para verificar si el problema era el exceso de variables, se aplicó una selección basada en valores SHAP (Lundberg and Lee, 2017) (*TreeExplainer*): se ordenaron las variables por su importancia media absoluta $|\text{SHAP}|$ y se conservaron las que aportaban al menos el 1% del total, reduciendo de 35 a 16. El ordenamiento es coherente y físicamente interpretable —dominan el calendario (*doy_sin*, *in_season*), seguido de la retrodispersión de partículas rezagada (*bbp_roll90_lag90*), el rezago anual de y y variables de SST/color del océano—, lo que indica que las variables tienen sentido. No obstante, podar *no* corrige el sobreajuste (Tabla 5.4): el modelo reducido es incluso ligeramente peor.

Modelo	N. variables	MAE	RMSE	sMAPE (%)	Error temp. 2021-22
Completo	35	423.6	659.7	116.0	+398.7%
Podado (SHAP)	16	444.7	695.5	120.3	+446.6%

Tabla 5.4: Selección de variables con SHAP sobre langosta $\times$ San Quintín (corte 01-julio-2020), *antes* de la unión con CONAPESCA. Podar a las 16 variables de mayor $|\text{SHAP}|$ no mejora el desempeño: con tres temporadas el cuello de botella no es *cuáles* variables se usan, sino el volumen de datos. Sobre el conjunto unido el signo se invierte y la poda sí ayuda (Tabla 5.9).

El mismo diagnóstico se puso a prueba por el lado contrario: en vez de podar, *enriquecer*. Se añadieron anomalías climatológicas por día del año —el valor observado menos su media histórica para esa fecha, con la climatología estimada únicamente con años de entrenamiento para no filtrar información— y tres interacciones con justificación ecológica explícita (calor acumulado del año previo por estar en temporada; anomalía térmica en su contexto de productividad; captura del año anterior modulada por la SST acumulada). Sobre el modelo global las siete variables nuevas resultan *neutras*: con el corte de 2024 mejoran el RMSE en 10 de 28 series y el promedio entre series empeora marginalmente (633.4 a 633.7 kg/día); con el corte de 2020 mejoran en 25 de 33 y el promedio baja apenas de 435.0 a 434.1. Ni podar ni enriquecer mueven la aguja, que es exactamente lo que se espera cuando el factor limitante es el número de temporadas y no el diseño de las variables.

La conclusión metodológica es importante: la selección de variables por sí sola no resuelve el sobreajuste, porque el factor limitante no es la dimensionalidad sino la cantidad de temporadas. Esto refuerza que la palanca real está en *sumar datos* —más unidades

económicas y más temporadas—, motivando el modelo global de la siguiente sección.

5.5 Modelo global multi-especie y multi-unidad económica

Para atacar la escasez de datos por serie se entrenó un único modelo global sobre varias series (especie, unidad económica), con codificación one-hot de especie y de unidad económica y la oceanografía compartida, y se comparó contra modelos específicos entrenados por serie. Se incorporó una segunda unidad económica, Isla Cedros ($\sim 28^\circ\text{N}$), además de San Quintín ($\sim 30.5^\circ\text{N}$), lo que introduce variación a lo largo del gradiente biogeográfico. La Tabla 5.5 muestra la comparación por serie.

Serie (especie @ unidad económica)	RMSE global	RMSE específico	Gana
langosta @ Isla Cedros	893.6	898.7	global
langosta @ San Quintín	618.9	558.3	específico
abulón negro @ San Quintín	24.6	52.8	global
abulón azul @ San Quintín	24.1	6.0	específico
abulón rojo @ San Quintín	24.0	8.9	específico

Tabla 5.5: Modelo global vs. modelos específicos, por serie (RMSE diario, kg). El global gana o empata en 2 de 5 series. *Nota:* esta tabla y la Tabla 5.6 son instantáneas de corridas sucesivas del proceso en evolución, registradas en la bitácora del repositorio; la matriz de variables cambió entre ambas corridas, por lo que las celdas que comparten difieren ligeramente. La comparación válida es *dentro* de cada tabla, con pool, variables y semilla idénticos entre columnas.

De aquí surgen dos hallazgos. Primero, hay *transferencia positiva dentro de una misma especie entre unidades económicas*: la langosta de Isla Cedros, con menos datos, mejora ligeramente al agruparse con la de San Quintín. Segundo, el agrupamiento indiscriminado de todas las especies en un solo modelo se ve *confundido por la escala*: la langosta (capturas de cientos de kilogramos) domina la función de pérdida frente al abulón (unidades de kilogramos), degradando las predicciones de este último. La conclusión metodológica es que conviene agrupar por especie entre unidades económicas —o normalizar la variable objetivo por serie— en lugar de un pooling total, es decir, avanzar hacia un modelo jerárquico o de *partial pooling*.

5.6 Normalización de la variable objetivo por serie

La hipótesis anterior se puso a prueba directamente. Antes de agrupar, se transformó la variable objetivo de cada serie con $\log(1 + y)$ —una transformación global, invertible y sin parámetros estimados— de modo que las series de mayor volumen dejaran de dominar la función de pérdida; también se probó una estandarización (z -score) por serie con media y desviación calculadas únicamente sobre el conjunto de entrenamiento, para evitar fuga de información. La Tabla 5.6 compara, por serie, el modelo específico contra el pooling sobre la variable cruda y contra el pooling sobre $\log(1 + y)$; todas las predicciones se invierten a kilogramos antes de medir el RMSE.

Serie (especie @ UE)	específico	pooling crudo	pooling $\log(1+y)$
abulón negro @ San Quintín	52.0	35.4	7.0
abulón azul @ San Quintín	6.7	32.7	4.6
abulón rojo @ San Quintín	7.3	34.9	3.5
langosta @ Isla Cedros	914.1	889.0	1131.4
langosta @ San Quintín	659.7	742.2	544.4

Tabla 5.6: Pooling con la variable objetivo normalizada por serie vs. modelos específicos (RMSE diario, kg, tras invertir la transformación). El pooling sobre $\log(1 + y)$ gana o empata en 4 de 5 series; la estandarización por serie (z -score, no mostrada) queda por detrás del logaritmo en las series clave. En negrita, la mejor de cada fila. *Nota:* instantánea de una corrida posterior a la de la Tabla 5.5 (ver la nota de aquella); las columnas de esta tabla sí son directamente comparables entre sí.

El resultado confirma la hipótesis: al normalizar el objetivo, el pooling *sí* supera a los modelos específicos, ganando o empatando en 4 de 5 series con la transformación $\log(1 + y)$, frente a solo 2 de 5 del pooling crudo. El efecto es más marcado en las series de escala pequeña —el abulón, cuyo RMSE cae de ~ 33 – 35 (pooling crudo, dominado por la langosta) a 3.5 – 7.0 kg, por debajo incluso de su modelo específico— y también mejora la serie insignia de langosta en San Quintín (544 vs. 659 kg). La única serie que empeora es la langosta de Isla Cedros, la de mayor escala, donde el logaritmo comprime en exceso. La estandarización por serie queda por detrás del logaritmo, previsiblemente porque con pocas temporadas las estadísticas de escala por serie son ruidosas. La conclusión operativa es que el *partial pooling con la variable objetivo en escala logarítmica* es el modelo global a consolidar y el candidato natural a envolver en un esquema de predicción probabilística (regresión cuantílica conformalizada) en la siguiente fase.

5.7 ¿Un modelo global o veintiocho modelos disfrazados?

Agrupar todas las series en un solo modelo con codificación one-hot de identidad plantea una objeción legítima: nada impide que los árboles usen esa identidad para partirse internamente y aprender, de hecho, un submodelo por serie —en cuyo caso el *pooling* no estaría transfiriendo nada y solo sería una forma cara de entrenar modelos específicos. La pregunta se contesta descomponiendo la atribución SHAP del modelo de producción *condicionada al grupo*: se mide qué fracción de la importancia media absoluta se lleva la identidad, y cuánto difiere el perfil de importancias de una especie o unidad económica a otra (distancia de Jensen-Shannon entre los vectores de cuota por variable; 0 significa lógica idéntica).

La respuesta es un término medio informativo, y con una tendencia clara. La identidad concentra el 38.4% de la atribución con el corte de 2020 y baja al 33.5% con el de 2024: al añadir temporadas, el modelo se apoya *menos* en saber qué serie está prediciendo y más en la señal compartida —calendario, rezago anual de la captura y las variables oceanográficas rezagadas, con la retrodispersión de partículas (`bbp_roll190_lag90`) y la SST acumulada del año previo a la cabeza. El contraste entre especies es nítido: en langosta —la especie con más historia— la identidad pesa 27.5% (corte 2024), mientras que en las tres series de abulón, con una fracción de los datos, sube a 46–55%; es decir, el modelo aprende una lógica ambiental donde tiene datos para hacerlo y se apoya en el efecto fijo de la serie donde no los tiene. Entre las veintiuna unidades económicas de langosta los perfiles son bastante homogéneos (Jensen-Shannon media de 0.22, con las mismas tres variables al frente en casi todas), con una excepción interpretable: San Quintín frente a La Purísima alcanza 0.47, las dos zonas de los extremos del gradiente térmico del pool.

La lectura para la tesis es doble. El *pooling* sí comparte estructura —dos tercios de la atribución van a variables comunes— y por eso mejora a las series pequeñas, tal como mostró la sección anterior; pero la dependencia de la identidad, mayor justo donde hay menos datos, es una firma más de la misma limitación de fondo: el modelo compensa la falta de temporadas memorizando el nivel de cada serie. Que esa cuota caiga cinco puntos al mover el corte cuatro años hacia adelante es evidencia directa de que acumular temporadas —y no cambiar de arquitectura— es lo que convierte al global en un modelo genuinamente compartido.

5.8 Pronóstico probabilístico con regresión cuantílica conformalizada

Con tres temporadas, cualquier pronóstico puntual es ruidoso; lo honesto —y lo útil para una cooperativa que planea insumos— es entregar un *rango* calibrado en lugar de un solo número. Se envolvió el modelo global $\log(1 + y)$ en una regresión cuantílica conformalizada (CQR, Romano et al., 2019): regresores cuantílicos de gradient boosting en escala logarítmica y una corrección conformal de conjunto de calibración, con las cotas invertidas a kilogramos. La calibración se hace *por serie* (variante de Mondrian) y *solo con días en temporada*: los días fuera de temporada, con captura nula y cuantiles base cercanos a cero, tienen residuo de conformidad nulo y, por su abundancia, anulaban la corrección; restringir la calibración a la temporada la vuelve informativa. La partición temporal es estricta: el conjunto de calibración es anterior al corte de prueba, y se reportan los dos cortes.

La Tabla 5.7 muestra la cobertura empírica y el ancho de los intervalos en los dos cortes. La cobertura marginal queda por encima del nivel nominal en ambos —96.7% y 95.8% para el intervalo nominal del 90%—, es decir, el procedimiento es *conservador*: cubre de más antes que de menos, que es el sentido correcto del error para una cooperativa que planea insumos. La variante *normalizada* (ensanchamiento proporcional a la dispersión local) resulta ligeramente mejor que la de corrección constante. Lo más relevante es que la cobertura se sostiene durante las olas de calor marinas —95.9% frente a 96.8% fuera en el corte de 2020, y 92.5% frente a 96.1% en el de 2024—: el intervalo sigue siendo honesto precisamente en el régimen anómalo que hacía fracasar al pronóstico puntual, que era la razón de reformular el pronóstico en términos probabilísticos.

Corte	Intervalo nominal	Cobertura empírica	Cobertura en días de MHW
01-julio-2020	80%	93.5%	—
	90%	96.7%	95.9% (vs. 96.8% fuera)
01-junio-2024	80%	90.9%	—
	90%	95.8%	92.5% (vs. 96.1% fuera)

Tabla 5.7: Cobertura empírica de la CQR sobre el modelo global $\log(1 + y)$, calibrada por serie (Mondrian) y solo con días en temporada, para las 21 series de langosta más las de abulón y erizo. La cobertura queda por encima del nominal en ambos cortes —el procedimiento es conservador— y se sostiene durante las olas de calor marinas.

La cobertura marginal, sin embargo, promedia series heterogéneas y hay que leerla junto con la cobertura por serie. En el corte de 2024 la langosta de San Quintín cubre 96.2%, muy cerca del nominal; en el de 2020 cubre 99.9%, una sobre-cobertura severa. Esa diferencia no es ruido: la Sección 5.9 muestra que la calibración de esa serie en el corte de 2020 es *irreproducible* —oscila con la composición del pool— mientras que en el de 2024 es invariante. El corte de referencia es, por tanto, el de 2024.

La limitación honesta del método es el ancho de la cota superior en los días de apertura: el percentil 90 del ancho llega a $\sim 9\,553$ kg en el corte de 2024. Eso lo determina el modelo cuantílico base —el cuantil alto en escala logarítmica, amplificado al exponenciar— y no la envoltura conformal, que solo lo desplaza. Un intento de endurecer los cuantílicos base con optimización bayesiana (40 ensayos de Optuna sobre la pérdida pinball) ilustra el punto de forma contundente: la pérdida de *validación* mejora ($0.146 \rightarrow 0.139$) mientras el *test* empeora en todo lo que importa —el ancho del percentil 90 pasa de $\sim 9\,776$ a $\sim 47\,039$ kg y la cobertura marginal baja de 85.9% a 84.7%—. Es sobreajuste del periodo de validación, y confirma que estrechar el intervalo requiere *más temporadas*, no más maquinaria. Aun así, el producto —un rango calibrado de captura por especie y unidad económica— es directamente entregable a las cooperativas y constituye el resultado operativo de esta fase (Capítulo 6).

5.9 La hipótesis de datos, puesta a prueba: más unidades y más temporadas

Todos los experimentos anteriores convergen en el mismo diagnóstico —el factor limitante es el volumen de datos, no la sofisticación del modelo—, pero lo enuncian sin demostrarlo causalmente. La forma directa de ponerlo a prueba es *sumar datos* y medir si la calibración mejora. Se hizo en dos frentes.

Primero, se amplió la cobertura espacial en dos tandas. Un clúster de cinco cooperativas de El Rosario ($\sim 29.6\text{--}30.4^\circ\text{N}$) llevó la langosta de 2 a 7 series (especie, unidad económica): con el corte canónico de 01-julio-2020 el RMSE del *pooling* de langosta en San Quintín cae de 659 a 313 kg y el ancho del percentil 90 de los días pico se estrecha de $\sim 9\,776$ a $\sim 3\,812$ kg —transferencia positiva dentro de la especie. Una segunda tanda añadió tres cooperativas de la costa norte con historia completa 2017-2026 —Punta Canoas ($\sim 29.4^\circ\text{N}$), El Pabellón de San Quintín y Rocas de San Martín ($\sim 30.4\text{--}30.5^\circ\text{N}$)—, llevando la langosta a 10 series: en el corte de 2024 el CRPS marginal baja de 150 a 123 kg y el de la propia langosta de San Quintín de 124 a 95 kg. Sumar zonas vecinas y de régimen

térmico parecido —la señal más clara de transferencia positiva dentro de la especie— afina el pronóstico; más adelante se verá que sumar zonas del extremo cálido del rango ya no lo hace.

Segundo, y de mayor impacto, se desbloquearon las temporadas 2022-2026 mediante la unión con los avisos de cosecha de CONAPESCA (Sección 4.2), lo que permite mover el corte de prueba a 01-junio-2024 y dejar el bache post-MHW y las temporadas posteriores de captura reducida *dentro* del entrenamiento y la calibración. Con ese corte la CQR queda bien calibrada y —lo crucial— de forma *estable*: la langosta de San Quintín cubre 96.2% (cobertura marginal 96.6% para el intervalo nominal del 90%), las series de langosta cubren entre 96% y 100%, y el intervalo sigue honesto durante las olas de calor (92.5% en días de MHW frente a 96.1% fuera). La Tabla 5.8 resume la progresión completa de 7 a 21 series en los dos cortes.

Pool de langosta	Langosta @ SQ, cob. 90%		Marginal	CRPS
	Corte 2020 (bache fuera)	Corte 2024 (bache dentro)	2024 cob. 90%	marg. 2024
7 series (El Rosario)	40.6%	96.7%	96.1%	149.8
10 series (+costa norte)	40.6%	96.2%	96.6%	123.0
14 series (+Vizcaíno)	40.6%	96.2%	96.1%	229.6
18 series (+Abreojos– Purísima)	40.5%	96.2%	96.0%	239.4
21 series (+Bahía Mag- dalena)	99.9%	96.2%	95.8%	216.8

Tabla 5.8: Estabilidad de la calibración de la langosta de San Quintín frente al corte de prueba y a la composición del pool, al expandir de 7 a 21 series. Con el corte de 2024 (el bache post-ola-de-calor *dentro* del entrenamiento) la cobertura del buque insignia es *invariante* a añadir zonas: se mantiene en 96.2% a lo largo de toda la expansión, y la cobertura marginal cerca del nominal ($\sim 96\%$). Con el corte de 2020 (bache *fuera* del entrenamiento) la cobertura es en cambio *inestable* respecto a la composición del pool —se mantuvo en $\sim 41\%$ hasta 18 series y saltó a $\sim 100\%$ solo al añadir Bahía Magdalena—, lo que confirma que ese corte es poco fiable (régimen fuera de distribución) y que el corte de referencia es el de 2024. El CRPS marginal sube al añadir las cooperativas de Vizcaíno y del Pacífico BCS —las de mayor tonelaje, y el CRPS está en kg— por un efecto de *escala*, no de calidad: la cobertura por serie de las nuevas se mantiene alta (Bahía Magdalena 95–97%).

Una tercera tanda puso a prueba la *robustez* del producto ante la composición del pool. Se añadieron cuatro grandes cooperativas FEDECOOP de la península de Vizcaíno (Bahía Tortugas, Punta Eugenia, Isla Natividad y Bahía Asunción, $\sim 27.1\text{--}27.9^\circ\text{N}$, unos 2° al sur de San Quintín), llevando la langosta a 14 series. Como estas solo tienen historia de CONAPESCA (2022–2026, apenas dos temporadas de entrenamiento antes del corte de 2024), lo que se mide es estabilidad: la calibración de la langosta de San Quintín quedó *intacta* (96.2% en el corte de 2024, idéntica a la del pool de 10 series). La cobertura marginal se mantuvo cerca del nominal (96.1% en 2024). Las nuevas series, de historia corta, se calibran razonablemente (91–93% en el corte de 2024) y elevan el CRPS *marginal* por su gran escala en kilogramos —son las de mayor tonelaje del pool, con Bahía Tortugas en ~ 767 t—, no por peor calidad probabilística. Es, una vez más, la firma de que la palanca es acumular temporadas, no añadir zonas de historia corta.

Una cuarta tanda extendió el pool $\sim 1^\circ$ más al sur, al clúster de Punta Abreojos–La Purísima ($\sim 26.2\text{--}27.0^\circ\text{N}$, cuatro cooperativas), lo que obligó a ampliar la descarga oceanográfica de Copernicus hacia el sur y el este. Con ello la langosta llegó a 18 series y el patrón de *estabilidad* se repitió: la calibración de la langosta de San Quintín siguió intacta (96.2% en el corte de 2024), la cobertura marginal cerca del nominal (96.0%), y las nuevas cooperativas se calibraron entre 89% y 100%.

Una quinta tanda llevó el pool al extremo sur del rango de la langosta roja: tres cooperativas de Bahía Magdalena (Puerto San Carlos, Bahía Magdalena y Puerto Chalé, $\sim 24.1\text{--}25.0^\circ\text{N}$), en el borde biogeográfico cálido donde la SST media supera en $\sim 4^\circ\text{C}$ a la de San Quintín; incorporarlas obligó a extender de nuevo la descarga de Copernicus hacia el sur (hasta 24°N). Con ellas la langosta llegó a 21 series. De nuevo la calibración de San Quintín quedó intacta en el corte de 2024 (96.2%) y las nuevas series —pese a su historia corta— se calibraron bien (95–97%). Pero esta tanda marca también el *límite honesto* de la transferencia entre zonas: añadir el borde térmico cálido *no* afina el pronóstico de San Quintín —su CRPS incluso empeora, de 90 a 123 kg en el corte de 2024—, a diferencia de las zonas vecinas y de régimen similar de las primeras tandas. La transferencia positiva dentro de la especie opera entre regímenes parecidos, no desde el extremo cálido del rango. El hallazgo refuerza el diagnóstico central: lo que estabiliza la calibración es acumular *temporadas* (llevar el bache al entrenamiento), más que sumar *zonas* indiscriminadamente. La Figura 5.1 lo muestra serie por serie para las veintiuna unidades.

El contraste con el corte de 2020 es revelador, pero no como un simple “antes mal, después bien”. Cuando el bache queda *fuera* del entrenamiento, la cobertura por serie de la langosta de San Quintín es sencillamente *poco fiable*: a lo largo de la expansión se mantuvo



Figura 5.1: Intervalos de la CQR (bandas 80% y 90% + mediana) frente al observado (puntos) para las veintiuna series de langosta, en el corte 01-junio-2024. Con el bache post-ola-de-calor dentro del entrenamiento y la calibración, el observado cae dentro de las bandas de forma consistente (cobertura empírica anotada por panel, 88–100%; las cooperativas nuevas de Vizcaíno, de solo dos temporadas de entrenamiento, en el extremo inferior), incluida la langosta de San Quintín (96.2%). El eje y de cada panel se recorta a $3\times$ su máximo observado, pues la cota superior del 90% se dispara en los días pico al invertir la transformación logarítmica.

en $\sim 41\%$ desde 7 hasta 18 series y saltó a 99.9% solo con 21 —de la sub-cobertura severa a la sobre-cobertura severa— sin que la serie ni su conjunto de calibración cambien, solo la composición del pool que fija el ancho del cuantil base. Es la firma de un régimen fuera de distribución: el intervalo se apoya sobre el filo de la navaja respecto a las capturas del crash. Con el bache *dentro* del entrenamiento (corte 2024) la cobertura es estable (96.7% con 7 series y 96.2% con 10, 14, 18 y 21). Lo que compran las temporadas adicionales, entonces, no es solo un buen número de cobertura sino una calibración *reproducible* —invariante a cuántas zonas haya en el pool—, y ese es el argumento de fondo: ni la poda por SHAP ni la optimización bayesiana de los cuantílicos dieron una calibración fiable de la serie insignia; llevar el régimen anómalo al entrenamiento sí.

5.10 Comparativa de modelos puntuales sobre datos unidos: el efecto de las temporadas de entrenamiento

Las tablas anteriores del piso (Tablas 5.3 y 5.4) son una fotografía *previa* a la unión con CONAPESCA: se calcularon con tres temporadas de entrenamiento y solo dos de prueba (2020-2022), que era todo lo que había. Con el conjunto unido 2017-2026 podemos re-entrenar los modelos puntuales de una sola serie (langosta $\times$ San Quintín) y, sobre todo, comparar de frente los dos cortes: el canónico 01-julio-2020 (~ 3 temporadas de entrenamiento, prueba 2020-2026 abarcando el bache y las temporadas posteriores de baja captura) contra 01-junio-2024 (~ 7 temporadas, con el bache *dentro* del entrenamiento, prueba = temporadas recientes de baja captura). La diferencia entre columnas aísla el efecto de *cuántas temporadas* ve el modelo. La Tabla 5.9 lo resume.

Cuatro lecturas se desprenden de la comparación (visibles en la Figura 5.2). Primero, mover el corte de 2020 a 2024 —es decir, meter el bache post-ola-de-calor al entrenamiento— reduce el MAE diario a la mitad en todos los modelos *tabulares* (ARIMA $331 \rightarrow 178$, Prophet $455 \rightarrow 190$, XGBoost $459 \rightarrow 145$, LGBM $402 \rightarrow 154$): al dejar de extrapolar un régimen pre-bache sobre las temporadas posteriores, los pronósticos dejan de dispararse. Es el análogo puntual del salto de cobertura de la CQR.

Segundo, el orden de los modelos se invierte. Con tres temporadas, el XGBoost con covariables (459) es *peor* que ARIMA (331): 35 variables sobreajustan tan poco dato. Con siete temporadas, el mismo XGBoost (145) *supera* a ambos baselines autorregresivos: las covariables de SST/MHW por fin rinden cuando hay suficientes temporadas para aprender la relación ola-de-calor $\rightarrow$ captura.

Modelo	Corte 2020-07-01 (~ 3 temp.)			Corte 2024-06-01 (~ 7 temp.)		
	MAE	RMSE	sMAPE	MAE	RMSE	sMAPE
ARIMA	330.8	383.8	153.3	177.8	191.5	147.1
Prophet	454.7	685.1	158.8	190.3	332.0	64.4
LGBM	401.9	668.8	136.7	153.8	236.2	124.0
XGBoost (35 vars)	459.0	712.3	153.0	145.4	212.0	97.1
XGBoost (SHAP, ~ 16 vars)	387.5	673.0	132.1	103.5	155.6	64.1
LSTM	290.7	457.7	78.4	499.4	628.7	131.5
XGBoost+LSTM (ensamble)	236.4	408.7	59.2	561.7	746.6	115.2

Tabla 5.9: Modelos puntuales de langosta $\times$ San Quintín re-entrenados sobre el conjunto unido 2017-2026, en los dos cortes de prueba (MAE, RMSE y sMAPE diarios, kg). En negrita, el mejor modelo de cada corte. Pasar de 3 a 7 temporadas de entrenamiento reduce el error diario a aproximadamente la mitad en los modelos tabulares —y *invierte* el orden entre ellos y los recurrentes. El ensamble XGBoost+LSTM es el de la primera iteración original (la predicción de XGBoost entra a la LSTM como regresor extra), aquí con esa columna construida fuera de muestra en el entrenamiento.

Tercero, y de forma reveladora, la poda por SHAP cambia de signo. En la fotografía previa a la unión (Tabla 5.4) podar de 35 a 16 variables *empeoraba* el modelo (MAE 424 $\rightarrow$ 445); sobre los datos unidos *ayuda* en ambos cortes, y de forma marcada en el de 2024 (145 $\rightarrow$ 104, un 29% menos de MAE). La misma regularización que era contraproducente con tres temporadas generaliza bien con siete: evidencia directa de que el sobreajuste original era un problema de *volumen de datos*, no de selección de variables. El mejor modelo puntual refrescado —XGBoost con variables seleccionadas por SHAP en el corte de 2024, MAE 103.5 y sMAPE 64.1%— es un salto cualitativo frente a los baselines ciegos al bache del planteamiento inicial, y complementa a los intervalos calibrados de la CQR como entregable.

Cuarto, y es la lectura que más corrige al planteamiento inicial: *el ensamble XGBoost+LSTM —el mejor modelo de la primera iteración— no sobrevive al refresco*. Con el corte de 2020 sigue encabezando la tabla (MAE 236.4 frente a 459.0 del XGBoost), pero la Figura 5.3 muestra que esa ventaja no viene de acertar la forma de la serie sino de *amortiguarla*: con tres temporadas de entrenamiento todos los modelos extrapolan el régimen previo al bache y sobre-predicen las temporadas posteriores, y los recurrentes —que producen una meseta suave en vez de los picos de apertura— simplemente sobre-predicen




Figura 5.2: Langosta × San Quintín, observado (negro) vs. pronosticado por el XGBoost completo (35 vars, rojo) y el podado por SHAP (~ 16 vars, verde), en los dos cortes. Con el entrenamiento corto (arriba, hasta jun-2020) el modelo extrapola el régimen pre-bache y sobre-predice todas las temporadas post-2021; con el entrenamiento largo (abajo, hasta may-2024, con el bache incluido) sigue las temporadas recientes de captura reducida. Eje y recortado a $3 \times$ el máximo observado.

menos. La razón entre la desviación del pronóstico y la del observado lo cuantifica: 1.58 para la LSTM y el ensamble frente a 2.37 del XGBoost, con una correlación con el observado que *no* es mejor (0.61–0.67 en los cuatro modelos). Es el mismo diagnóstico que la primera iteración ya había anotado cualitativamente —que el ajuste de la LSTM “no seguía la tendencia de los datos reales” pese a tener el menor error— ahora medido.

Con el bache *dentro* del entrenamiento el orden se invierte por completo: la LSTM pasa a MAE 499.4 y el ensamble a 561.7, ambos peores que el ARIMA (177.8) y casi cinco veces peores que el XGBoost podado por SHAP (103.5); y ahora sobre-reaccionan (razón de desviaciones 3.26 y 4.06). Es más, ambos predicen captura durante agosto, con la veda todavía vigente y semanas antes del arranque de la temporada: la LSTM aprende una rampa suave hacia el pico en lugar del salto del 15 de septiembre, y ni siquiera respeta la estructura de temporada que el calendario le da como covariable. El error en la suma de la temporada 2024-2025, la métrica que le importa a la cooperativa, es de

+626% y +704% para los recurrentes frente a +174% del XGBoost. La conclusión de la primera iteración —que la combinación de LSTM y XGBoost era el modelo a seguir, con un error de temporada del 12.9%— estaba condicionada a una partición con tres temporadas y dos de prueba; con siete temporadas no se sostiene. Cabe la objeción de que la red recurrente re-entrenada aquí (128 y 64 unidades) no es la del borrador original, que declaraba 2 700 y 800 unidades; se re-entrenó también esa arquitectura fiel, de 40.8 millones de parámetros, sobre las mismas 2 295 ventanas de entrenamiento. El resultado es el caso de manual de por qué las métricas de forma son obligatorias: con el corte de 2024 la red original *colapsa a una constante* —predice exactamente cero todos los días del periodo de prueba—, lo que le da el mejor MAE de la tabla (79.8, que no es otra cosa que la media de la captura observada) con desviación y correlación nulas y un error de temporada de −100%. Juzgada solo por MAE habría sido coronada como el mejor modelo del capítulo. Con el corte de 2020 no colapsa pero es netamente peor que la red pequeña (MAE 435.3 frente a 290.7, con una sobre-dispersión de 2.99 contra 1.58). Cuarenta millones de parámetros sobre mil observaciones no producen un modelo mejor: producen uno degenerado, que es precisamente el argumento. Las $\sim 10^3$ observaciones por serie siguen siendo uno o dos órdenes de magnitud menos de lo que una red recurrente necesita, y el veredicto anticipa exactamente el de la prueba de techo con el TFT de la Sección 5.11: la palanca no es la arquitectura.

5.11 Prueba de techo: un Transformer de fusión temporal (TFT)

Todo el trabajo sostiene que el cuello de botella es el volumen de datos y no la sofisticación del modelo. La prueba más exigente de esa tesis es enfrentar al producto —XGBoost con envoltura conformal— contra una arquitectura de vanguardia y comprobar si la complejidad adicional *compra* algo. Se eligió el Temporal Fusion Transformer (TFT, Lim et al., 2021), un modelo de atención multi-horizonte con *gating* de variables diseñado precisamente para series con covariables estáticas, conocidas y observadas. Se entrenó un TFT global cuantílico (`pytorch-forecasting`) sobre el pool completo de series especie×unidad económica, con las mismas covariables de color del océano y de olas de calor marinas y la misma rejilla de 11 cuantiles de la CQR. Para una comparación de cobertura *manzana con manzana* sus cuantiles se envolvieron en la *misma* corrección conformal de la Sección anterior (Mondrian por serie, calibrada en temporada, en escala logarítmica), previo reordenamiento monótono por fila para eliminar el cruce de cuantiles (Chernozhukov et al.,




Figura 5.3: Langosta $\times$ San Quintín en el corte 01-julio-2020: observado (negro) contra los cuatro modelos de aprendizaje de la primera iteración. Los cuatro sobre-predicen las temporadas posteriores al bache; la LSTM y el ensamble lo hacen menos porque aplanan la serie en una meseta suave, no porque sigan mejor su forma —de ahí su menor MAE con una correlación equivalente. Eje y recortado a $3\times$ el máximo observado.

2010). Así lo que se mide es “TFT + conformal” frente a “XGBoost + conformal”, en los dos cortes de prueba. La prueba se re-corrió sobre el *pool final* —las mismas 33 series del corte de 2020 y las mismas 28 del de 2024 que sirve el producto—, de modo que sus cifras son directamente comparables con las de la Tabla 5.7 y no solo entre sí.

El resultado es matizado y honesto (Tabla 5.10). *Marginalmente*, el TFT+conformal es competitivo en nitidez: su CRPS global supera por poco al del XGBoost en ambos cortes (116.2 vs. 132.8 en 2020; 210.9 vs. 216.8 en 2024), y en la serie insignia la diferencia es mayor (CRPS de 102 vs. 457 en el corte de 2020 y de 71 vs. 123 en el de 2024). El reordenamiento monótono importó: sin él los cuantiles del TFT se cruzaban y la cobertura resultaba no-monótona. Es decir, la *nitidez* probabilística cruda del Transformer no es peor que la del *gradient boosting*; si acaso, es algo mejor. Pero la nitidez se paga con calibración: el TFT sub-cubre en los dos cortes (70.8% y 79.1% para un intervalo nominal

Método	Corte 2020-07-01 (bache fuera)			Corte 2024-06-01 (bache dentro)		
	Cob. 90%	Ancho (kg)	CRPS	Cob. 90%	Ancho (kg)	CRPS
TFT + conformal	70.8%	3.0	116.2	79.1%	1.0	210.9
XGBoost + CQR	96.7%	1.8	132.8	95.8%	29.4	216.8

Tabla 5.10: Prueba de techo: TFT y XGBoost, ambos con la misma envoltura conformal y sobre el *mismo pool final* (33 series en el corte de 2020, 28 en el de 2024), con intervalo nominal del 90%: cobertura empírica, ancho mediano y CRPS global. El TFT gana el CRPS por poco en ambos cortes (116.2 vs. 132.8 y 210.9 vs. 216.8) pero *sub-cubre* en los dos (70.8% y 79.1% frente al 90% nominal), mientras que la CQR sobre XGBoost *sobre-cubre* de forma controlada (96.7% y 95.8%). Los anchos medianos son minúsculos porque la mayoría de los días son fuera de temporada, con captura nula.

del 90%) mientras el XGBoost *sobre-cubre* de forma controlada (96.7% y 95.8%). Para una cooperativa que planea insumos con la banda alta, un intervalo que promete 90% y entrega 71% no es una herramienta utilizable: promete una seguridad que no tiene.

A la sub-cobertura se suma lo que termina de descalificar al TFT como producto: su *irreproducibilidad*. Una corrida anterior de este mismo experimento, con la misma configuración pero sobre el pool de 22 series de aquel momento, daba a la langosta de San Quintín coberturas de 40.6% y 62.0%; en la corrida sobre el pool final la misma serie sale en 99.6% y 95.8%. Cambiar la composición del pool y volver a entrenar reordena el diagnóstico por serie de un extremo al otro, mientras que el XGBoost se mantiene estable entre corridas y composiciones (99.8–99.9% y 96.2%). Peor aún, el desborde numérico persiste: en el corte de 2020 la serie de erizo de El Regasa vuelve a reventar, con un ancho mediano del orden de 10^7 kg, por invertir la transformación logarítmica sobre un cuantil base mal condicionado —un fallo que la envoltura conformal no cura porque hereda el cuantil del modelo base—. Cada corrida entrena un TFT nuevo y el ruido corrida a corrida en las series pequeñas es alto; entrenar más (8 vs. 30 épocas) no cambia el veredicto, la firma inconfundible de un problema limitado por *datos*, no por capacidad del modelo.

El veredicto de la prueba de techo confirma la tesis de fondo. Con entre ~ 200 y $\sim 1\,100$ días de captura por serie —uno a dos órdenes de magnitud por debajo del umbral (del orden de 10^4 observaciones por grupo) donde los Transformers suelen empezar a pagar— el TFT *no supera* al XGBoost+CQR: es algo más nítido en CRPS, pero lo consigue sub-cubriendo, y para una cooperativa lo que importa es una calibración *estable y segura* por unidad económica —y ahí el XGBoost+CQR gana claramente, por reproducibilidad y

sobre-cobertura controlada. La capa conformal —no la arquitectura— es la que entrega la calibración. La palanca sigue siendo acumular temporadas y series, no añadir maquinaria. La justificación de diseño y esta hipótesis, enunciada *antes* de correr el experimento, quedan registradas en `docs/decisions/ADR-0002-tft.md`.

Capítulo 6

El producto operativo

Un modelo que vive en un cuaderno de trabajo no le sirve a una cooperativa pesquera. Este capítulo describe cómo se entrega el resultado del Capítulo 5: una aplicación de inferencia que sirve, por especie y unidad económica, el intervalo calibrado de captura diaria.

6.1 Qué entrega y por qué así

El producto **no es un total puntual por temporada**, y la decisión es deliberada. Como la captura se concentra en pocos días alrededor de la apertura, la suma de las medianas diarias es un mal estimador del total: subestima las series con picos grandes y sobreestima las de nivel bajo. Lo que sí está calibrado —y es lo que el sistema entrega— es el **intervalo diario** con su cobertura empírica verificada, más un resumen por temporada que muestra la captura observada y la cobertura alcanzada, con la estimación central únicamente como referencia. Es una diferencia de honestidad, no de presentación: se entrega la cantidad cuya garantía se puede sostener.

6.2 Arquitectura

El sistema tiene tres piezas:

- Una **API** (FastAPI) que, al arrancar, entrena una sola vez el modelo de producción —el mismo de la Sección 5.8: *gradient boosting* cuantílico en escala logarítmica con conformalización Mondrian por serie— y deja en memoria, por serie, el pronóstico diario calibrado (mediana y bandas de 80 y 90%). Los endpoints solo leen esa memoria, de modo que la consulta es inmediata. El entrenamiento inicial tarda entre

30 y 60 segundos y el estado se expone en un endpoint de salud. Para despliegues reproducibles ese resultado puede además serializarse como **artefacto versionado** (`models/final/store.json`, unos 0.8 MB): es el pronóstico ya calculado —no un *pickle* del modelo, que ataría el despliegue a versiones exactas de las bibliotecas— acompañado de un manifiesto con el corte, la semilla, la versión del formato y la huella del conjunto de datos con el que se generó. Si el artefacto está presente la API arranca al instante y sirve exactamente las cifras reportadas aquí; si no, entrena en caliente y lo advierte en la bitácora.

- Un **front** estático mínimo: selector de especie y de zona, gráfico de abanico diario (observado contra las bandas calibradas) y un panel de *backtest* por temporada con la captura observada y la cobertura empírica del intervalo del 90% en temporada.
- Un **empaquetado** en Docker, de modo que el despliegue completo es un solo comando y no depende del entorno de desarrollo de quien lo corre.

El corte de prueba que define el horizonte servido es un parámetro de despliegue; por omisión se usa 01-junio-2024, que es el corte con la calibración estable (Sección 5.9). En su configuración actual sirve **28 series**: las 21 de langosta roja más las de abulón y erizo.

6.3 Lo que ve una cooperativa

La Figura 6.1 muestra la salida de la API para tres series de langosta elegidas por contraste, en la temporada 2024-2025.

Los tres paneles ilustran el rango de comportamiento del sistema. San Quintín, con el bache dentro del entrenamiento, queda bien calibrada (92.5% en esa temporada; 96.2% sobre todo el periodo de prueba). El Rosario, con historia completa 2017-2026, alcanza 95.1% y sus bandas siguen la estructura de picos de la temporada. Bahía Tortugas, incorporada solo con avisos de CONAPESCA y con apenas dos temporadas de entrenamiento, alcanza 93.2% pero con bandas notoriamente más anchas: el sistema *sabe* que sabe menos de esa zona, y lo comunica ensanchando el intervalo en lugar de dar un número falsamente preciso. Esa es exactamente la propiedad que se buscaba al reformular el pronóstico en términos probabilísticos.




Figura 6.1: Intervalos calibrados servidos por la API para tres series de langosta roja en la temporada 2024-2025: la serie insignia de San Quintín, una zona de historia larga (El Rosario) y una de historia corta, incorporada solo con los avisos de CONAPESCA (Bahía Tortugas, Vizcaíno). Los puntos son la captura observada; las bandas, los intervalos del 80 y 90%; la línea, la mediana. La cobertura empírica en temporada se anota en cada panel. El ancho de la banda superior en los días de apertura es la limitación conocida del método: el cuantil alto en escala logarítmica se amplifica al invertir la transformación.

6.4 Advertencias que el sistema declara

Tres advertencias están documentadas y se muestran junto al resultado, porque un producto de pronóstico que no declara sus límites induce confianza injustificada:

1. La cobertura que reporta la interfaz es **en temporada**. Fuera de temporada la captura es cero y cualquier intervalo la cubre trivialmente, lo que inflaría el número.
2. Las zonas de **historia corta** (Vizcaíno, Abreojos–La Purísima, incorporadas solo con datos de 2022 en adelante) están peor calibradas que las de historia larga. Su calibración depende de acumular temporadas, que es la conclusión de fondo de este trabajo.

3. El sistema **no pronostica la oceanografía futura**. El horizonte llega hasta la última fecha con covariables disponibles: es una herramienta de pronóstico calibrado sobre el periodo con datos, no un oráculo de temporadas futuras arbitrarias.

Capítulo 7

Conclusiones

7.1 Respuesta a las preguntas de investigación

La evaluación de diversos modelos para predecir el volumen de capturas pesqueras en la temporada arrojó los siguientes resultados:

ARIMA, utilizado inicialmente en el contexto de todas las especies antes de ser descartado para la langosta, mostró un desempeño desfavorable y quedó fuera de la selección final.

Entre los modelos restantes, LSTM destacó como el más prometedor, exhibiendo el menor error absoluto medio y un error en la suma total de capturas de la temporada menor a los demás. Sin embargo, al visualizar los valores predichos frente a los reales, se observó que el ajuste de LSTM no seguía la tendencia de los datos reales. En contraste, XGBoost y LGBM se aproximaron mejor a dicha tendencia, a pesar de tener errores más grandes. Prophet y ARIMA, con ajustes simples que no siguen la tendencia ni se acercan a los valores reales, resultaron ininterpretables.

El desempeño de los dos mejores modelos (LSTM y XGBoost) combinado superó a todos los demás, con un error porcentual en la suma total de pesca por temporada de 12.9%.

La escasez de datos de entrenamiento juega un papel importante en el mal desempeño de todos los modelos propuestos, por lo que no podemos pensar en modelos más complejos para mejorar los resultados, sino en aumentar la cantidad de datos y utilizar el mismo método para mejorar los resultados actuales.

En ese sentido, alcanzar un modelo aplicable a varias zonas de pesca y a varias especies depende de la disponibilidad de los datos para esos contextos; difícilmente los resultados de este trabajo nos acercan al resultado deseado, pero nos arrojan pistas de qué debemos

hacer para alcanzarlo.

El trabajo desarrollado en esta tesis refuerza y precisa esas conclusiones iniciales. En primer lugar, la caída atípica de la temporada 2021-2022 —que el planteamiento inicial no lograba explicar y que sesgaba la evaluación de los modelos— se atribuye ahora a las olas de calor marinas de 2019-2021, un mecanismo ambiental documentado para Baja California (Villaseñor-Derbez et al., 2024) y reproducible con el índice de MHW que se incorporó al pipeline. De aquí se desprende una recomendación concreta: incluir siempre una variable de anomalía térmica de largo plazo (idealmente un índice de MHW) entre las covariables, pues es la señal que permite anticipar los años atípicos.

En segundo lugar, los experimentos con modelos multivariados y con un modelo global multi-especie confirman que el factor limitante sigue siendo la cantidad de temporadas y de series disponibles, no la sofisticación del modelo. La evidencia de transferencia positiva dentro de una misma especie entre unidades económicas es alentadora, y el enfoque jerárquico de *partial pooling* que señalaba el camino a seguir quedó validado: al normalizar la variable objetivo por serie con $\log(1 + y)$ —evitando que las series de mayor volumen dominen el ajuste— el modelo global pasa a ganar o empatar contra los modelos específicos en 4 de 5 series, rescatando en particular a las especies de escala pequeña. Escalar a más unidades económicas y acumular más temporadas —junto con el índice de MHW como covariable estándar y el objetivo en escala logarítmica— constituye la ruta más prometedora hacia un modelo operativo y transferible.

En tercer lugar, y como respuesta directa a esa escasez de datos, el pronóstico se reformuló en términos probabilísticos: una regresión cuantílica conformalizada sobre el modelo global entrega intervalos con cobertura cercana a la nominal y estable incluso durante las olas de calor marinas. Para una cooperativa pesquera, un rango calibrado de captura esperada es más accionable —y más honesto— que un único número puntual, y es el producto operativo concreto de este trabajo (Capítulo 6).

Finalmente, la hipótesis que recorre todo el trabajo —que el cuello de botella es el volumen de datos y no la sofisticación del modelo— dejó de ser una conjetura y se puso a prueba. Al sumar diecinueve cooperativas de langosta (El Rosario, la costa norte, la península de Vizcaíno, el Pacífico de BCS y Bahía Magdalena, de 2 a 21 series) y desbloquear las temporadas 2022-2026 mediante la unión con los avisos de cosecha de CONAPESCA, la langosta de San Quintín —cuya calibración ni la selección de variables por SHAP ni la optimización bayesiana de los cuantílicos habían hecho fiable— pasó a estar bien calibrada de forma *estable* (cobertura $\sim 96\%$) al llevar el bache post-ola-de-calor de 2021-2022 dentro del entrenamiento, e *invariante* a añadir zonas al pool; con el bache fuera del entrenamiento su cobertura era irreproducible, oscilando entre 40.6% y 99.9% según la

composición del pool. La expansión también fijó el límite de esa transferencia: sumar zonas vecinas y de régimen térmico parecido afina el pronóstico, pero el extremo cálido del rango (Bahía Magdalena, $\sim 24^\circ\text{N}$) ya no lo hace —la palanca de fondo sigue siendo acumular temporadas, no zonas. Es la demostración más concreta de la tesis de fondo: la ruta hacia un modelo operativo y transferible pasa por acumular temporadas y unidades económicas —junto con el índice de MHW como covariable estándar y el objetivo en escala logarítmica— y no por más maquinaria estadística.

Esa hipótesis obligó también a revisar la conclusión del propio planteamiento inicial. Al re-entrenar sobre el conjunto unido los modelos que allí ganaban —la LSTM y el ensemble XGBoost+LSTM— su ventaja se disuelve: con tres temporadas de entrenamiento encabezan la tabla, pero por amortiguar la serie (razón de desviaciones 1.58 frente a 2.37 del XGBoost, con la misma correlación), no por seguir su forma; y con siete temporadas quedan cerca de cinco veces por detrás del XGBoost podado por SHAP, con errores de suma de temporada de +626% y +704%. El error del 12.9% que la primera iteración reportaba para el ensemble era, entonces, un artefacto de aquella partición corta y no una propiedad del modelo.

Como prueba de techo de esa afirmación se enfrentó al producto contra un Transformer de fusión temporal (TFT) con idénticas covariables y envuelto en la misma corrección conformal. El TFT resultó marginalmente algo más nítido (CRPS ligeramente a su favor en ambos cortes) pero *mal calibrado*: sub-cubre en los dos cortes (70.8% y 79.1% para un intervalo nominal del 90%, frente a la sobre-cobertura controlada del 96.7% y 95.8% del XGBoost), su diagnóstico por serie cambia de un extremo al otro al re-entrenar sobre otro pool, arrastra desbordes numéricos ocasionales y no gana nada al entrenar más épocas. Que la arquitectura de vanguardia no supere al gradient boosting con estos datos, mientras que sumar temporadas sí volvió fiable la calibración, es la confirmación más nítida de que la complejidad del modelo no es el factor limitante: lo es el volumen de datos.

7.2 Limitaciones

Las limitaciones se enuncian en orden de gravedad para el uso del pronóstico.

La captura no es abundancia. La variable objetivo es el volumen desembarcado, que es el producto de la abundancia del recurso *y* del esfuerzo pesquero: número de embarcaciones, días efectivos de salida, precio de venta, decisiones de la cooperativa. No se dispone de datos de esfuerzo, de modo que no es posible normalizar a captura por unidad de esfuerzo (CPUE), que es la medida estándar en evaluación pesquera. Una parte de lo

que el modelo aprende es, por tanto, comportamiento humano y no dinámica poblacional, y una caída puede reflejar menos salidas y no menos langosta. Esta es la limitación más importante para interpretar los resultados en clave biológica.

Pocas temporadas de calibración. Es la limitación que el propio trabajo documenta como el cuello de botella. Con una a dos temporadas de calibración por serie, un cambio de régimen queda fuera de la distribución aprendida: con el corte de 2020 la cobertura de la serie insignia resulta irreproducible, oscilando según la composición del pool. El corte de 2024 es el fiable, y lo es porque el bache está dentro del entrenamiento.

Zonas aproximadas por rectángulos. La oceanografía se agrega sobre un rectángulo costero y no sobre el polígono TURF real de cada cooperativa, que no es de acceso público. A la resolución de los productos satelitales la aproximación es razonable, pero las cooperativas que comparten rectángulo comparten también, por construcción, sus covariables oceanográficas.

Empalme de fuentes sin periodo de solape. La unión COBI-CONAPESCA se apoya en la continuidad del traspaso de diciembre de 2021 a enero de 2022. No existe un periodo en el que ambas fuentes reporten simultáneamente, así que no fue posible validar exhaustivamente que las escalas coincidan.

No se pronostica la oceanografía. El horizonte útil llega hasta la última fecha con covariables disponibles. El sistema es una herramienta de pronóstico calibrado sobre el periodo con datos, no un oráculo de temporadas futuras arbitrarias; extenderlo exigiría alimentar pronósticos oceanográficos, con su propia incertidumbre.

Dependencia de terceros. Salvo los datos de COBI, obtenidos por convenio, las fuentes son públicas pero externas: el trabajo depende de que Copernicus y CONAPESCA sostengan sus procesos de publicación. Durante este trabajo, de hecho, el cliente `motuclient` de Copernicus fue descontinuado y hubo que reescribir la ingesta.

Una sola especie con evidencia sólida. Las conclusiones sobre transferencia entre zonas están respaldadas para la langosta roja, con 21 series. Las de abulón y erizo tienen menos series y menos temporadas, y sus resultados deben leerse como indicativos.

7.3 Trabajo futuro

1. **Incorporar esfuerzo pesquero.** Es la mejora de mayor impacto científico: permitiría modelar CPUE y separar la señal ambiental del comportamiento de la flota. Requiere datos de salidas por embarcación, que las cooperativas sí registran.
2. **Acumular temporadas.** Es la conclusión que atraviesa todo el trabajo. Cada temporada adicional vale más que cualquier refinamiento de modelo, y el sistema ya está construido para incorporarlas con un solo comando.
3. **Conformal adaptativo por régimen.** Calibrar por separado los días con y sin ola de calor daría intervalos que se ensanchan automáticamente en régimen anómalo. Con una sola temporada de calibración por serie hoy no es robusto, pero lo será al acumular temporadas.
4. **Polígonos TURF reales** y, con ellos, covariables oceanográficas distintas por cooperativa dentro de un mismo clúster.
5. **Extender el catálogo de especies** a las que hoy tienen series cortas, aprovechando que el modelo global ya está diseñado para agruparlas.
6. **Validar el producto con las cooperativas.** La utilidad real del intervalo calibrado solo puede evaluarse con quienes toman la decisión de compra de insumos; el siguiente paso natural es una temporada de uso acompañado.

Apéndice A

Gráficas de pronóstico de la primera iteración

A continuación se muestran las gráficas de valores predichos contra los valores reales en cada uno de los modelos.




Figura A.1: ARIMA: Predicción de ambas temporadas | Valores reales (azul) contra valores predichos (rojo)




Figura A.2: Prophet: Predicción de ambas temporadas | Valores reales (azul) contra valores predichos (rojo)




Figura A.3: XGBoost: Predicción de ambas temporadas | Valores reales (azul) contra valores predichos (naranja)




Figura A.4: LGBM: Predicción de ambas temporadas | Valores reales (azul) contra valores predichos (naranja)




Figura A.5: XGBoost + LSTM | Predicción temporada 2020-2021: Valores reales (azul) contra valores predichos (rojo)




Figura A.6: XGBoost + LSTM | Predicción temporada 2021-2022: Valores reales (azul) contra valores predichos (rojo)




Figura A.7: XGBoost + LSTM | Predicción temporadas 2020-2021 y 2021-2022: Valores reales (azul) contra valores predichos (rojo). Nota: Aquí no aparecen las fechas consideradas como veda (periodo entre temporadas)

Apéndice B

Descripción de las variables

Este apéndice documenta el conjunto de datos de la *primera iteración* del trabajo: las 16 variables regresoras del acervo GlobColour descargadas por FTP, tal como las usaba el borrador de 2023. Varias de ellas (aerosoles, nubosidad, POC, PIC, PAR) ya no están disponibles por la vía de Copernicus y se omiten en el conjunto vigente, cuyas variables —SST y su anomalía, el índice de olas de calor marinas y las seis variables de color del océano con sus rezagos— se describen en las Secciones 4.1, 4.5 y 4.6.

El conjunto de datos utilizado está compuesto de fecha 'ds', variable objetivo 'y' y 16 variables regresoras 'xi', como se muestra en la Tabla B.1.

Tabla B.1: Muestra de conjunto de datos

ds	y	x1	x2	x3	...	x16
15/12/17	500	0.1556	0.2067	17.6501	...	11.3717
16/12/17	598	0.2126	0.2732	12.5639	...	10.0574
17/12/17	1018	0.0677	0.1281	22.6158	...	14.8350
18/12/17	0	0.0520	0.0985	7.8426	...	12.2488
19/12/17	1568	0.0726	0.1186	9.8166	...	11.8934
...	...	...	...	...	...	...
31/12/21	60	0.0648	0.1079	99.7545	...	12.0536

A continuación se describe cada una de las variables:

- **Variable ds | Fecha:** El conjunto de datos cuenta con observaciones diarias desde el 01 de enero de 2017 hasta el 31 de diciembre de 2021. La fecha tiene el formato d-m-y

- **Variable y | Volumen total de pesca:** Es la variable objetivo. Se trata del volumen total de pesca para la fecha dada; el valor es flotante y representa kilogramos.
- **Variable x1 | Aerosol Optical Thickness over Water:** Medida de la cantidad de aerosoles en la atmósfera sobre cuerpos de agua.
- **Variable x2 | Aerosol Optical Thickness over Water+Land:** Similar a la anterior, pero considera tanto agua como tierra en la medición de aerosoles atmosféricos.
- **Variable x3 | Cloud Fraction:** Fracción del cielo cubierta por nubes, expresada como un valor entre 0 y 1.
- **Variable x4 | Depth of the Bottom of the Euphotic Layer:** Profundidad a la que la luz del sol es suficiente para la fotosíntesis en el océano.
- **Variable x5 | Secchi Disk Depth:** Profundidad a la que un disco blanco (Secchi) es visible en el agua y se utiliza para medir la transparencia del agua.
- **Variable x6 | Heated Layer Depth:** Profundidad de la capa calentada en el agua, que puede afectar las propiedades térmicas.
- **Variable x7 | Particulate Backscattering Coefficient:** Medida de la cantidad de luz dispersada por partículas en el agua en dirección opuesta a la fuente de luz.
- **Variable x8 | Coloured Dissolved Detrital Organic Materials Absorption Coefficient:** Coeficiente de absorción de materiales orgánicos disueltos y detritales que dan color al agua.
- **Variable x9 | Diffuse Attenuation Coefficient:** Tasa de disminución de la luz a medida que se propaga a través del agua debido a la dispersión y absorción.
- **Variable x10 | Relative Excess of Radiance:** Diferencia entre la radiación observada y la radiación esperada en un entorno dado.
- **Variable x11 | Normalised Remote Sensing Reflectance:** Reflectancia normalizada utilizada en teledetección para caracterizar la cantidad de luz reflejada por una superficie.
- **Variable x12 | Normalised Fluorescence Line Height:** Altura normalizada de la línea de fluorescencia, que puede indicar la actividad biológica en el agua.

- **Variable x13 | Particulate Organic Carbon:** Concentración de carbono orgánico en partículas suspendidas en el agua.
- **Variable x14 | Particulate Inorganic Carbon:** Concentración de carbono inorgánico en partículas suspendidas en el agua.
- **Variable x15 | Inorganic Suspended Particulate Matter Concentration:** Concentración de materia particulada inorgánica suspendida en el agua.
- **Variable x16 | Photosynthetically Available Radiation:** Radiación disponible para la fotosíntesis, es decir, la cantidad de luz que puede ser utilizada por los organismos fotosintéticos.

En el documento de GlobColour (Glo, 2020) se proporciona información detallada sobre el procesamiento de cada variable.

Referencias

- Peyman Adibi, Fabio Pranovi, Alessandra Raffaetà, Emanuele Russo, Claudio Silvestri, Marta Simeoni, Andrea Torsello, and Stan Matwin. Predicting fishing effort and catch using semantic trajectories and machine learning. In *Multiple-Aspect Analysis of Semantic Trajectories (MASTER 2019)*, volume 11889 of *Lecture Notes in Computer Science*. Springer, Cham, 2020. doi: 10.1007/978-3-030-38081-6_7.
- Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019. doi: 10.1145/3292500.3330701.
- Anastasios N. Angelopoulos and Stephen Bates. Conformal prediction: A gentle introduction. *Foundations and Trends in Machine Learning*, 16(4):494–591, 2023. doi: 10.1561/22000000101.
- Christoph Bergmeir and José M. Benítez. On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191:192–213, 2012. doi: 10.1016/j.ins.2011.12.028.
- George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, and Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. Wiley, 5 edition, 2015.
- Letícia M. Cavole, Alyssa M. Demko, Rachel E. Diner, et al. Biological impacts of the 2013–2015 warm-water anomaly in the northeast Pacific: winners, losers, and the future. *Oceanography*, 29(2):273–285, 2016. doi: 10.5670/oceanog.2016.32.
- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016. doi: 10.1145/2939672.2939785.
- Victor Chernozhukov, Iván Fernández-Val, and Alfred Galichon. Quantile and probability curves without crossing. *Econometrica*, 78(3):1093–1125, 2010. doi: 10.3982/ECTA7880.

- Comisión Nacional de Acuacultura y Pesca. Avisos de arribo, cosecha y producción. datos abiertos, 2026. URL https://conapesca.gob.mx/wb/cona/avisos_arribo_cosecha_produccion. Consultado en 2026.
- Emanuele Di Lorenzo and Nathan Mantua. Multi-year persistence of the 2014/15 North Pacific marine heatwave. *Nature Climate Change*, 6:1042–1047, 2016. doi: 10.1038/nclimate3082.
- Craig J. Donlon, Matthew Martin, John Stark, Jonah Roberts-Jones, Emma Fiedler, and Werenfrid Wimmer. The operational sea surface temperature and sea ice analysis (OSTIA) system. *Remote Sensing of Environment*, 116:140–158, 2012. doi: 10.1016/j.rse.2010.10.017.
- Christopher M. Free, James T. Thorson, Malin L. Pinsky, Kiva L. Oken, John Wiedenmann, and Olaf P. Jensen. Impacts of historical warming on marine fisheries production. *Science*, 363(6430):979–983, 2019. doi: 10.1126/science.aau1758.
- Thomas L. Frölicher, Erich M. Fischer, and Nicolas Gruber. Marine heatwaves under global warming. *Nature*, 560:360–364, 2018. doi: 10.1038/s41586-018-0383-9.
- Product User Guide*. GlobColour, 2020. URL https://www.globcolour.info/CDR_Docs/GlobCOLOUR_PUG.pdf. Ref: GC-UM-ACR-PUG-01, versión 4.2.1.
- Tilman Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437.
- Simon Good, Emma Fiedler, Chongyuan Mao, et al. The current configuration of the OSTIA system for operational production of foundation sea surface temperature and ice concentration analyses. *Remote Sensing*, 12(4):720, 2020. doi: 10.3390/rs12040720.
- Klaus Greff, Rupesh K. Srivastava, Jan Koutník, Bas R. Steunebrink, and Jürgen Schmidhuber. LSTM: A search space odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, 28(10):2222–2232, 2017. doi: 10.1109/TNNLS.2016.2582924.
- Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, et al. Array programming with NumPy. *Nature*, 585:357–362, 2020. doi: 10.1038/s41586-020-2649-2.
- Sofía Hernández-Casas, Luis Felipe Beltrán-Morales, Victor Gerardo Vargas-López, Francisco Vergara-Solana, and Juan Carlos Seijo. Price forecast for mexican red spiny lobster

- (Panulirus spp.) using artificial neural networks (ANNs). *Applied Sciences*, 12(12):6044, 2022. doi: 10.3390/app12126044.
- S. L. Ho and M. Xie. The use of ARIMA models for reliability forecasting and analysis. *Computers & Industrial Engineering*, 37(1–2):213–216, 1999. doi: 10.1016/S0360-8352(98)00066-7.
- Alistair J. Hobday, Lisa V. Alexander, Sarah E. Perkins, et al. A hierarchical approach to defining marine heatwaves. *Progress in Oceanography*, 141:227–238, 2016. doi: 10.1016/j.pocean.2015.12.014.
- Alistair J. Hobday, Eric C. J. Oliver, Alex Sen Gupta, et al. Categorizing and naming marine heatwaves. *Oceanography*, 31(2):162–173, 2018. doi: 10.5670/oceanog.2018.205.
- Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.
- Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 3 edition, 2021. URL <https://otexts.com/fpp3/>.
- Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. doi: 10.1016/j.ijforecast.2006.03.001.
- Instituto Mexicano de Investigación en Pesca y Acuacultura Sustentables. Acuerdo por el que se da a conocer la actualización de la carta nacional pesquera. Diario Oficial de la Federación, 10 de marzo de 2025, 2025. URL https://www.gob.mx/cms/uploads/attachment/file/982574/CNP_2025.pdf.
- Guolin Ke, Qi Meng, Thomas Finley, et al. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017. URL <https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>.
- Roger Koenker and Gilbert Bassett. Regression quantiles. *Econometrica*, 46(1):33–50, 1978. doi: 10.2307/1913643.
- Bryan Lim, Sercan Ö. Arık, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021. doi: 10.1016/j.ijforecast.2021.03.012.

- Benjamin Lindemann, Timo Müller, Hannes Vietz, Nasser Jazdi, and Michael Weyrich. A survey on long short-term memory networks for time series prediction. *Procedia CIRP*, 99:650–655, 2021. doi: 10.1016/j.procir.2021.03.088.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017. URL <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- Rodgers Makwinja, Emmanuel Kaunda, Seyoum Mengistou, and Tena Alamirew. Modeling of lake malombe annual fish landings and catch per unit effort (CPUE). *Forecasting*, 3(1):39–55, 2021. doi: 10.3390/forecast3010004.
- Wes McKinney. Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61, 2010. doi: 10.25080/Majora-92bf1922-00a.
- Pablo Montero-Manso and Rob J. Hyndman. Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting*, 37(4):1632–1653, 2021. doi: 10.1016/j.ijforecast.2021.03.004.
- Eric C. J. Oliver, Markus G. Donat, Michael T. Burrows, et al. Longer and more frequent marine heatwaves over the past century. *Nature Communications*, 9:1324, 2018. doi: 10.1038/s41467-018-03732-9.
- Adam Paszke, Sam Gross, Francisco Massa, et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*, 2019. doi: 10.48550/arXiv.1912.01703.
- Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- Fotios Petropoulos, Daniele Apiletti, Vassilios Assimakopoulos, et al. Forecasting: theory and practice. *International Journal of Forecasting*, 38(3):705–871, 2022. doi: 10.1016/j.ijforecast.2021.11.001.
- Yaniv Romano, Evan Patterson, and Emmanuel J. Candès. Conformalized quantile regression. In *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*, 2019. doi: 10.48550/arXiv.1905.03222.

- Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación. Norma oficial mexicana NOM-006-SAG/PESC-2016, para regular el aprovechamiento de todas las especies de langosta en las aguas de jurisdicción federal del golfo de México y mar Caribe, así como del océano Pacífico incluyendo el golfo de California. Diario Oficial de la Federación, 7 de septiembre de 2016, 2016. URL https://dof.gob.mx/nota_detalle.php?codigo=5451782&fecha=07/09/2016.
- Zhuangwei Shi, Yang Hu, Guangliang Mo, and Jianguo Wu. Attention-based CNN-LSTM and XGBoost hybrid model for stock prediction. *arXiv preprint arXiv:2204.02623*, 2022. doi: 10.48550/arXiv.2204.02623.
- Kathryn E. Smith, Michael T. Burrows, Alistair J. Hobday, et al. Socioeconomic impacts of marine heatwaves: Global issues and opportunities. *Science*, 374(6566):eabj3593, 2021. doi: 10.1126/science.abj3593.
- Ralf C. Staudemeyer and Eric R. Morris. Understanding LSTM – a tutorial into long short-term memory recurrent neural networks. *arXiv preprint arXiv:1909.09586*, 2019. doi: 10.48550/arXiv.1909.09586.
- Leonard J. Tashman. Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4):437–450, 2000. doi: 10.1016/S0169-2070(00)00065-0.
- Sean J. Taylor and Benjamin Letham. Forecasting at scale. *PeerJ Preprints*, 5:e3190v2, 2017. doi: 10.7287/peerj.preprints.3190v2.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, et al. Attention is all you need. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017. doi: 10.48550/arXiv.1706.03762.
- Armando Vega Velázquez. Reproductive strategies of the spiny lobster *Panulirus interruptus* related to the marine environmental variability off central Baja California, Mexico: management implications. *Fisheries Research*, 65(1–3):123–135, 2003. doi: 10.1016/j.fishres.2003.09.011.
- Juan Carlos Villaseñor-Derbez, Nur Arafteh-Dalmau, and Fiorenza Micheli. Past and future impacts of marine heatwaves on small-scale fisheries in Baja California, Mexico. *Communications Earth & Environment*, 5:623, 2024. doi: 10.1038/s43247-024-01696-x.
- Vladimir Vovk, Alexander Gammerman, and Glenn Shafer. *Algorithmic Learning in a Random World*. Springer, 2005. doi: 10.1007/b106715.

- Yu-Jin Yoon, Tae-Ho Kim, Seung-Il Baek, et al. An artificial intelligence method for the prediction of near- and off-shore fish catch using satellite and numerical model data. *Korean Journal of Remote Sensing*, 36(1):41–53, 2020. doi: 10.7780/KJRS.2020.36.1.4.
- Zhixin Zhao, Fenfang Hu, Wenbin Wang, et al. Short-term prediction of fishing effort distributions by discovering fishing chronology among trawlers based on VMS dataset. *Expert Systems with Applications*, 184:115512, 2021. doi: 10.1016/j.eswa.2021.115512.